

Bausteine Computergestützter Datenanalyse

Lukas Arnold Simone Arnold Florian Bagemihl
Matthias Baitsch Marc Fehr Franca Hollmann
Maik Poetzsch Sebastian Seipel

2026-01-21

Inhaltsverzeichnis

Methodenbaustein Einlesen strukturierter Datensätze	5
Voraussetzungen	6
Lernziele	8
1 Einleitung	9
2 Grundlagen: Merkmale von Datensätzen	11
2.1 Technisches Format	11
2.2 Struktur	12
2.2.1 Eindimensionale Datensätze	12
2.2.2 Eindimensionale Daten einlesen mit Python	13
2.2.3 Zweidimensionale Datensätze	15
2.2.4 long- und wide-Format	17
2.2.5 Übung zweidimensionale Datensätze	23
2.2.6 Drei- und mehrdimensionale Datensätze	24
2.2.7 Übung dreidimensionale Datensätze	26
2.3 Datentyp	28
2.3.1 Fehlende Werte	31
2.3.2 Fehlende Werte in der Praxis	34
2.4 Metadaten	35
2.5 Tidy data	36
3 Die Module NumPy und Pandas	37
3.1 Datentypen	38
3.2 Dateien lesen und schreiben	38
3.3 NumPy	39
3.4 Pandas	39
3.5 Datentypen erkennen und festlegen	40
3.5.1 NumPy	40
3.5.2 Pandas	41
3.5.3 Aufgabe Datentypen	45
3.6 Umgang mit fehlenden Werten	48
3.6.1 NumPy	48
3.6.2 Pandas	58

3.6.3	Aufgabe fehlende Werte	66
4	Zeitreihen	69
4.1	Datum und Zeit in NumPy und Pandas	69
4.2	NumPy	69
4.3	Pandas	70
4.4	NumPy	73
4.5	Pandas	73
4.6	Zeitreihen einlesen	75
4.6.1	NumPy	76
4.6.2	Pandas	81
4.7	Zugriff auf Zeitreihen	86
4.8	Fehlende Werte in Zeitreihen	90
4.9	Übungen: Zeitreihen einlesen	91
5	Zugriff auf mehrere lokale Dateien: Modul glob	122
5.1	Übungen Modul glob	125
5.2	Jahreszahlen und Spaltennamen auslesen	131
5.3	DataFrame der Spaltennamen	131
5.4	Spaltennamen finden	132
6	Maskierte Arrays	139
6.1	Maskierte Arrays erzeugen	142
6.2	Übung maskierte Arrays erzeugen	144
6.3	unmasking, soft und hard masks	146
6.4	Operationen mit maskierten Arrays	149
6.5	Übungen Operationen mit maskierten Arrays	151
7	Wissenschaftliche Dateiformate	156
7.1	HDF5	156
7.1.1	PyTables	158
7.1.2	h5py	162
7.1.3	Übung Zugriff auf H5P-Datasets	164
7.2	netCDF4	166
7.3	Datensatz	166
7.4	Dimensionen	174
7.5	globale Attribute	174
7.6	Attribute einer Variablen	176
7.6.1	Daten in netCDF4-Dateien schreiben	176
7.6.2	Übung Zugriff auf netCDF-Datasets	180
8	Das Wichtigste	182

9	Lernzielkontrolle	183
9.1	Kompetenzquiz	183
9.2	Übungsaufgaben	187

Methodenbaustein Einlesen strukturierter Datensätze



Bausteine Computergestützter Datenanalyse von Lukas Arnold, Simone Arnold, Florian Bagemihl, Matthias Baitsch, Marc Fehr, Franca Hollmann, Maik Poetzsch und Sebastian Seipel. Methodenbaustein Einlesen strukturierter Datensätze von Maik Poetzsch ist lizenziert unter [CC BY 4.0](#). Das Werk ist abrufbar auf [GitHub](#). Ausgenommen von der Lizenz sind alle Logos Dritter und anders gekennzeichneten Inhalte. 2025

Zitiervorschlag

Arnold, Lukas, Simone Arnold, Florian Bagemihl, Matthias Baitsch, Marc Fehr, Franca Hollmann, Maik Poetzsch, und Sebastian Seipel. 2025. „Bausteine Computergestützter Datenanalyse. Methodenbaustein Einlesen strukturierter Datensätze”. <https://github.com/bausteine-der-datenanalyse/m-einlesen-strukturierter-datensaetze>.

BibTeX-Vorlage

```
@misc{BCD-m-esd-2025,  
  title={Bausteine Computergestützter Datenanalyse. Methodenbaustein Einlesen strukturierter  
  author={Arnold, Lukas and Arnold, Simone and Bagemihl, Florian and Baitsch, Matthias and Fehr,  
  year={2025},  
  url={https://github.com/bausteine-der-datenanalyse/m-einlesen-strukturierter-  
  datensaetze}}
```

Voraussetzungen

Die Bearbeitungszeit dieses Bausteins beträgt circa **Platzhalter**. Für die Bearbeitung dieses Bausteins werden folgende Bausteine vorausgesetzt und die genannten Bibliotheken verwendet:

Bausteine:

- Werkzeugbausteine Python, NumPy, Pandas

Module:

- Modul os
- Module NumPy, numpy.ma
- Modul Pandas
 - openpyxl `pip install openpyxl`
 - xlrd `pip install xlrd`
 - pytables `pip install tables`
- Modul h5py `pip install h5py`
- Modul netCDF4 `pip install netCDF4`
- Modul Matplotlib
- Modul re (optional)
- Module datetime, time, pytz, zoneinfo (optional)

Im Baustein werden folgende Daten verwendet:

- Zahnwachstum bei Meerschweinchen [CSV-Datei](#)
- Strommarktdaten der Bundesnetzagentur [hier verfügbar](#) und der Austrian Power Grid AG (APG) [hier verfügbar](#)
- Industriestrompreise in den Mitgliedsländern der Internationalen Energieagentur [XLS-Datei](#)
- Kursdaten des amerikanischen Aktienindexes S&P500 [XLS-Datei](#).

- US State Facts and Figures, die in R abgerufen werden können.
- DSB Unfallatlas der [statistischen Ämter des Bundes und der Länder](#)
- Europäische Gaspreise von Eurostat [XLSX-Datei](#)
- Baugenehmigungen, verfügbar beim [Statistischen Bundesamt](#)
- Eisdicke in der Arktis und Antarktis [kostenlose Registrierung bei NASA Earth erforderlich](#)
- Blitzdichte [kostenlose Registrierung bei NASA Earth erforderlich](#)

Lernziele

In diesem Baustein lernen Sie ...

- Datensätze unterschiedlicher Struktur und Formate einzulesen, zu bearbeiten und zu speichern.
- den Unterschied zwischen identifizierenden und gemessenen Variablen kennen sowie Datensätze ins long- und wide-Format zu konvertieren.
- das System tidy data kennen.
- typische Probleme beim Einlesen von Datensätzen und Strategien zu deren Lösung kennen.

1 Einleitung

2016 stellte eine Studie fest, dass ein Fünftel aller wissenschaftlichen Artikel im Bereich der Genetik auf der Grundlage von durch die Tabellenkalkulation Excel verfälschten Daten durchgeführt wurde (Ziemann, Eren und El-Osta [2016](#)). Genbezeichnungen wie “MARCH1” wurden fälschlicherweise in ein Datumsformat umgewandelt. 2021 wurde diese Schätzung des Anteils betroffener Arbeiten sogar auf 30 Prozent angehoben. ([heise online](#))

Am Beginn der computergestützten Datenanalyse steht das Einlesen von Daten aus Dateien. In der Praxis ist das Einlesen von Daten alles andere als trivial. Daten werden in einer Vielzahl von Dateiformaten gespeichert. Deshalb ist es in der Datenanalyse erforderlich, mit verschiedenen Dateiformaten umgehen zu können: mit wenigen Kilobyte großen Textdateien, offenen und proprietären Formaten gängiger Büroanwendungen und mehreren hundert Megabyte großen Dateien in speziell für den Austausch wissenschaftlicher Daten entwickelten Formaten. Programmiersprachen wie Python und R bringen verschiedene Werkzeuge zum Lesen, Bearbeiten und Speichern von verschiedenen Dateiformaten mit. Spezialisierte Pakete ergänzen den Werkzeugkasten.

Die praktischen Herausforderungen der Datenanalyse beschränken sich jedoch nicht nur auf technische Aspekte. Oftmals bereitet der innere Aufbau von Datensätzen die größten Schwierigkeiten. Ein wichtiger Bestandteil des Einlesens strukturierter Datensätze besteht darin, Fehler im Datensatz zu suchen und ggf. zu bereinigen. Dasu und Johnson schreiben:

“Unfortunately, the data set is usually dirty, composed of many tables, and has unknown properties. Before any results can be produced, the data must be cleaned and explored—often a long and difficult task. [...] In our experience, the tasks of exploratory data mining and data cleaning constitute 80% of the effort that determines 80% of the value of the ultimate data mining results.” (Dasu und Johnson ([2003](#)), S. ix)

Das Einlesen strukturierter Datensätze umfasst somit den gesamten Prozess des technischen Zugriffs auf Dateien, der Organisation, Fehlersuche und -korrektur sowie des Abspeicherns der Daten in einer für die weitere Bearbeitung geeigneten Form.

In der praktischen Datenanalyse helfen zwei einfache Tipps beim Einlesen strukturierter Datensätze:

💡 Tipp 1

Schauen Sie sich Ihre Daten an, bevor Sie diese mit Python einlesen! Dafür reicht ein Texteditor oder ein Tabellenkalkulationsprogramm (hier die automatische Erkennung und Umwandlung von Datumsformaten beachten). Ein kurzer Blick genügt, um die verwendeten Zeichentrenner, Tausendertrennzeichen, Datumsformate, die Kodierung fehlender Werte und die Unicode-Kodierung (wie UTF-8) zu identifizieren.

Dies ist aber nicht immer möglich, beispielsweise wenn Ihr Datensatz aus hunderten Spalten und zehntausenden Zeilen besteht. Dieser Baustein vermittelt deshalb die Handwerkszeuge, um Datensätze ausschließlich mit den in Python verfügbaren Mitteln einzulesen.

Es ist nicht erforderlich, die Besonderheiten aller hier vorgestellten Pakete und Funktionen auswendig zu beherrschen. Dafür ist das Themenfeld zu komplex und nicht selten ändert sich das Verhalten von Funktionen mit der Weiterentwicklung der Programmiersprache. Die hier vorgestellten Besonderheiten von Funktionen dienen jedoch als mentale Ankerpunkte, die als Anknüpfungspunkt dienen sollen, wenn Sie in der Praxis auf Probleme stoßen.

💡 Tipp 2

Benutzen Sie die Dokumentation! Auf diese Weise erhalten Sie einen vollständigen Überblick über standardmäßig gesetzte und optional verfügbare Parameter. Außerdem erkennen Sie Änderungen in der Programmausführung und vermeiden so unerwartete Fehler.

➡ **Added in version 1.5.0:** Support for `defaultdict` was added. Specify a `defaultdict` as input where the default determines the `dtype` of the columns which are not explicitly listed.

(a) Neuerung in Python

⚠ **Deprecated since version 2.0.0:** A strict version of this argument is now the default, passing it has no effect.

(a) Abkündigung in Python

2 Grundlagen: Merkmale von Datensätzen

Bevor wir uns mit den praktischen Herausforderungen des Einlesens strukturierter Datensätze beschäftigen, werden zunächst einige Merkmale von Datensätzen behandelt, um ein grundlegendes Verständnis der Begrifflichkeiten zu schaffen und den Umgang der in der Basis von Python enthaltenen Werkzeuge zu vermitteln. Am Ende dieses Kapitels wird mit tidy data ein grundlegendes Konzept zur Organisation von Datensätzen vorgestellt.

! Wichtig 1: Datensatz

Ein Datensatz ist eine Sammlung zusammengehöriger Daten. Datensätze enthalten einer oder mehreren Variablen zugeordnete Werte. Jeder Datensatz besitzt ein technisches Format, eine Struktur, mindestens eine Variable und mindestens einen Wert.

2.1 Technisches Format

Das technische Format eines Datensatzes gibt vor, mit welchen Mitteln Daten eingelesen, bearbeitet und gespeichert werden können. Einige Beispiele sind:

- Druckerzeugnis, z. B. Telefonbuch: manuelles Ablesen von Name und Telefonnummer, irreversible Bearbeitung per Stift
- Lochkarte, z. B. Parkschein: Lesegerät erkennt Lochung und gewährt eine Freistunde, irreversible Bearbeitung mit Stanzgerät
- Textdatei, z. B. Einwohnerzahl nach Bundesländern: Kann mit einer Vielzahl von Computerprogrammen wie Texteditor, Tabellenkalkulationsprogramm oder Programmierumgebung eingelesen, bearbeitet und gespeichert werden.
- Hierarchical Data Format HDF5, z. B. räumliche Daten zur Blitzdichte: benötigt spezialisierte Programme oder Pakete

2.2 Struktur

Datensätze speichern Daten in einer definierten n-dimensionalen Struktur.




Abbildung 2.1: n-dimensionale Datensätze

slicing von Marc Fehr ist lizenziert unter [CC-BY-4.0](#) und abrufbar auf [GitHub](#). 2024

2.2.1 Eindimensionale Datensätze

Die einfachste Form sind eindimensionale Datensätze, die Werte einer einzigen Variablen zuordnen. Eindimensionale Datensätze mit Werten des gleichen Typs (bspw. Zahlen) werden **Vektor** genannt. Eindimensionale Datensätze, die unterschiedliche Datentypen enthalten können, heißen **Liste**. Eindimensionale Datensätze verfügen lediglich über eine Achse: den Index, über den Elemente angesprochen werden können.




Abbildung 2.2: eindimensionale Datensätze

slicing von Marc Fehr ist lizenziert unter [CC-BY-4.0](#) und abrufbar auf [GitHub](#). Die Grafik wurde auf den gezeigten Teil beschnitten und die obenstehende Beschriftung entfernt. 2024

Beispiele eindimensionaler Datensätze sind ein Einkaufszettel oder die Urliste eines Würfel-experiments. Über den Index kann beispielsweise das Würfelergebnis an der Indexposition 2 ausgegeben werden.

```
print( *( Augen := [6, 2, 1, 2] ) )  
  
print(f"Das Würfelergebnis an Indexposition 2 lautet: {Augen[2]}")
```

```
6 2 1 2  
Das Würfelergebnis an Indexposition 2 lautet: 1
```

2.2.2 Eindimensionale Daten einlesen mit Python

An dieser Stelle eine kleine Wiederholung aus dem [Werkzeugbaustein Python](#):

Die Pythonbasis greift über Dateiobjekte auf Dateien zu. Die Funktionen und Methoden haben Sie im Werkzeugbaustein Python kennengelernt. Der Zugriff auf Dateien über die Pythonbasis ist eine verlässliche Rückfalloption und darüber hinaus nützlich, um die Encodierung einer Datei zu bestimmen.

Tipp 3: Kleine Wiederholung: Funktionen und Methoden der Pythonbasis

- Die Funktion `os.getcwd()` aus dem Modul `os` gibt das aktuelle Arbeitsverzeichnis aus, mit der Funktion `os.chdir(pfad)` kann es gewechselt werden.
- Die Funktion `open(dateipfad, mode = 'r')` öffnet eine Datei im Lesemodus und gibt ein Dateiobjekt zurück.
- Informationen zum Dateiobjekt können durch Ausgabe verschiedener Attribute abgerufen werden: `dateiobjekt.name`, `os.path.basename(dateiobjekt.name)`, `dateiobjekt.closed`, `dateiobjekt.mode`, `dateiobjekt.encoding`
- Das Dateiobjekt kann mit Methoden wie `dateiobjekt.read()`, `dateiobjekt.readline()`, `dateiobjekt.readlines()` oder der Funktion `list(dateiobjekt)` ausgelesen werden.
- Die Methode `dateiobjekt.close()` schließt die Datei und gibt sie somit wieder für andere Programme frei.

Lesen Sie die Datei “python.txt” unter dem dateipfad “skript/01-daten/” ein.

- Bestimmen Sie die Encodierung der Datei.
- Entfernen Sie die erste Zeile aus dem Text und geben Sie den Text mit Python aus.
- Wie kann der Text korrekt dargestellt werden?

💡 Tipp 4: Musterlösung python.txt

```
dateipfad = "01-daten/" + "python.txt"
dateiobjekt = open(dateipfad, mode = 'r')

# Enkodierung der Datei bestimmen
print(f"Die Enkodierung der Datei lautet: {dateiobjekt.encoding}")

# Text ausgeben
text_als_liste = list(dateiobjekt)

for i in range(1, len(text_als_liste)):
    print(text_als_liste[i])

# Datei schließen.
dateiobjekt.close()
```

Die Enkodierung der Datei lautet: UTF-8

Python ist eine universell nutzbare, üblicherweise interpretierte, höhere Programmiersprache.

Python wurde mit dem Ziel größter Einfachheit und Übersichtlichkeit entworfen. Dies wird von objektorientierter Programmierung und Skripten deutlich knapper formulieren als in anderen Sprachen.[50]

Van Rossum legte bei der Entwicklung großen Wert auf eine Standardbibliothek, die überschaubar ist.

Auszug aus [https://de.wikipedia.org/wiki/Python_\(Programmiersprache\)](https://de.wikipedia.org/wiki/Python_(Programmiersprache)), abgerufen am 20.02.2020

Enkodierung UTF-8 auswählen.

```
# Mit europäischen Sonderzeichen kompatible Enkodierung UTF-8 wählen
dateiobjekt = open(dateipfad, mode = 'r', encoding = 'utf-8')

# Text ausgeben
text_als_liste = list(dateiobjekt)

for i in range(1, len(text_als_liste)):
    print(text_als_liste[i])

# Datei schließen.
dateiobjekt.close()
```

Python ist eine universell nutzbare, üblicherweise interpretierte, höhere Programmiersprache.

Python wurde mit dem Ziel größter Einfachheit und Übersichtlichkeit entworfen. Dies wird von Python-basierte Skripte deutlich knapper formulieren als in anderen Sprachen.[50]

Van Rossum legte bei der Entwicklung großen Wert auf eine Standardbibliothek, die überschaubar ist.

Auszug aus [https://de.wikipedia.org/wiki/Python_\(Programmiersprache\)](https://de.wikipedia.org/wiki/Python_(Programmiersprache)), abgerufen am 20.02.2020

2.2.3 Zweidimensionale Datensätze

Zweidimensionale Datensätze organisieren Werte in einer aus Zeilen und Spalten bestehenden **Matrix** oder einem **Dataframe**. Eine Matrix enthält nur einen Datentyp (bspw. Zahlen), ein Dataframe kann unterschiedliche Datentypen enthalten (bspw. Zahlen und Wahrheitswerte). In Python stellt das Modul Pandas die DataFrame-Struktur bereit (siehe [Werkzeugbaustein Pandas](#)).




Abbildung 2.3: zweidimensionaler Datensatz

slicing von Marc Fehr ist lizenziert unter [CC-BY-4.0](#) und abrufbar auf [GitHub](#). Die Grafik wurde auf den gezeigten Teil beschnitten und die obenstehende Beschriftung entfernt. 2024

Typischerweise entspricht in zweidimensionalen Datensätzen jede Spalte einer **Variablen** und jede Zeile einer **Beobachtung**. Variablen speichern alle Werte eines Merkmals, zum Beispiel des Würfelergebnisses. Beobachtungen speichern alle Werte, die für eine Beobachtungseinheit gemessen wurden, z. B. für eine Person. (Wickham 2014, S. 3)

```
import pandas as pd

messung1 = pd.DataFrame({'Name': ['Hans', 'Elke', 'Jean', 'Maya'], 'Geburtstag': ['26.02.',
messung1
```

	Name	Geburtstag	Würfelfarbe	Summe Augen
0	Hans	26.02.	rosa	17
1	Elke	14.03.	rosa	12
2	Jean	30.12.	blau	8
3	Maya	07.09.	gelb	23

Über die Angabe der Indizes entlang der 0. (Zeilen) und der 1. Achse (Spalten) kann die Summe der gewürfelten Augen einer Person ausgegeben werden.

```
print(f"Jean würfelte {messung1.iloc[2, 3]} Augen")
```

Jean würfelte 8 Augen

Es ist aber auch möglich, zunächst eine Spalte auszuwählen und dann wie bei einem eindimensionalen Datensatz den Wert an einer Indexposition aufzurufen. Dies wird verkettete Indexierung genannt.

```
print(f"Jean würfelte {messung1['Summe Augen'][2]} Augen")
```

Jean würfelte 8 Augen

⚠ Warning 1: Verkettete Indexierung

Die verkettete Indexierung erzeugt in Pandas abhängig vom Kontext eine Kopie des Objekts oder greift auf den Speicherbereich des Objekts zu. Mit Pandas 3.0 wird die verkettete Indexierung nicht mehr unterstützt, das Anlegen einer Kopie wird zum Standard werden. Weitere Informationen erhalten Sie im zitierten Link.

“Whether a copy or a reference is returned for a setting operation, may depend on the context. This is sometimes called **chained assignment** and should be avoided. See [Returning a View versus Copy](#).”

([Pandas Dokumentation](#))

2.2.4 long- und wide-Format

Zweidimensionale Datensätze werden zumeist in einer aus Zeilen und Spalten bestehenden Matrix dargestellt. Den zeilenweise eingetragenen Beobachtungen werden Werte für die in den Spalten organisierten Variablen zugeordnet. Diese Art Daten darzustellen, wird wide-Format genannt: Mit jeder zusätzlich gemessenen Variablen wird der Datensatz breiter.

Eine andere Art Daten zu organisieren und über Daten nachzudenken, ist die Darstellung im long-Format. Einige Programme und Pakete erfordern Daten im long-Format oder profitieren zumindest davon beispielsweise bei der Erstellung von Grafiken. Schauen wir uns zunächst noch einmal den Datensatz `messung1` im wide-Format an. Welche Beobachtungseinheiten gibt es? Welche Variablen wurden erhoben?

	Name	Geburtstag	Würfelfarbe	Summe Augen
0	Hans	26.02.	rosa	17
1	Elke	14.03.	rosa	12
2	Jean	30.12.	blau	8
3	Maya	07.09.	gelb	23

Vermutlich werden Sie davon ausgehen, dass die Beobachtungseinheiten Hans, Elke, Jean und Maya sind und die Variablen Geburtstag, Würfelfarbe und Summe Augen. Es ist aber auch denkbar, dass die Beobachtungseinheit Person mit 0, 1, 2 und 3 kodiert wurde (dem Zeilenindex des Datensatzes) und die Spalte Name ebenfalls eine der erhobenen Variablen ist. Ebenso könnte es nur zwei Variablen, Würfelfarbe und Summe Augen, geben, während die Spalten Name und Geburtstag die beobachteten Personen kodieren. Stellen Sie sich vor, es gäbe eine zweite Person mit dem Namen Hans. Dann könnten die Würfelergebnisse der Personen mit dem Namen Hans nur über den Geburtstag am 26.02. oder 11.11. korrekt zugeordnet werden.

```
messung1 = pd.DataFrame({'Name': ['Hans', 'Elke', 'Jean', 'Maya', 'Hans'], 'Geburtstag': ['26.02.', '14.03.', '30.12.', '07.09.', '11.11.'], 'Würfelfarbe': ['rosa', 'rosa', 'blau', 'gelb', 'rosa'], 'Summe Augen': [17, 12, 8, 23, 7]})
messung1
```

	Name	Geburtstag	Würfelfarbe	Summe Augen
0	Hans	26.02.	rosa	12
1	Elke	14.03.	rosa	17
2	Jean	30.12.	blau	8
3	Maya	07.09.	gelb	23
4	Hans	11.11.	rosa	7

Das long-Format macht diese Überlegungen explizit, indem identifizierende Variablen (identification variables, kurz: id vars) und gemessene Variablen (measure variables oder value vars) unterschieden werden. Die Transformation eines Datensatzes aus dem wide-Format ins long-Format wird melting (schmelzen) genannt. Das Modul Pandas bietet die Funktion `pd.melt(frame, id_vars = None)`. Diese erwartet einen DataFrame. Im optionalen Argument `id_vars` wird angegeben, welche Spalten die identifizierenden Variablen sind.

```
messung1_long = pd.melt(messung1, id_vars = ['Name', 'Geburtstag'])
messung1_long
```

	Name	Geburtstag	variable	value
0	Hans	26.02.	Würfelfarbe	rosa
1	Elke	14.03.	Würfelfarbe	rosa
2	Jean	30.12.	Würfelfarbe	blau
3	Maya	07.09.	Würfelfarbe	gelb
4	Hans	11.11.	Würfelfarbe	rosa
5	Hans	26.02.	Summe Augen	12
6	Elke	14.03.	Summe Augen	17
7	Jean	30.12.	Summe Augen	8
8	Maya	07.09.	Summe Augen	23
9	Hans	11.11.	Summe Augen	7


Im long-Format werden die gemessenen Variablen in der Spalte variable aufgeführt und deren Wert in der Spalte value eingetragen. Mit jeder zusätzlich erhobenen Variablen wird der Datensatz länger.

Wenn Sie die Unterscheidung von identifizierenden und gemessenen Variablen zu Ende denken, kann der Variablenname selbst als eine identifizierende Variable für den Wert in der Spalte value aufgefasst werden. Ein Datensatz kann als eine Struktur verstanden werden, die genau eine gemessene Variable, nämlich value, und eine Anzahl identifizierender Variablen besitzt. Dies kann im long-Format wie folgt dargestellt werden.

```
messung1_all_id = pd.melt(messung1, id_vars = ['Name', 'Geburtstag', 'Würfelfarbe'])
messung1_all_id
```

In dieser Darstellung wird beispielsweise der erste Wert 12 durch Name = Hans, Geburtstag = 26.02., Würfelfarbe = rosa und variable = Summe Augen identifiziert.

	Name	Geburtstag	Würfelfarbe	variable	value
0	Hans	26.02.	rosa	Summe Augen	12
1	Elke	14.03.	rosa	Summe Augen	17
2	Jean	30.12.	blau	Summe Augen	8
3	Maya	07.09.	gelb	Summe Augen	23
4	Hans	11.11.	rosa	Summe Augen	7



Much wow. Such architecture. von Dmitry Kudryavtsev ist verfügbar unter <https://yieldcode.blog/post/bloat-in-software-engineering/>.

Was passiert, wenn auch die Variable `Summe Augen` dem Argument `id_vars` übergeben wird?

💡 Tipp 5: Antwort

Der Befehl `messung1_all_id = pd.melt(messung1, id_vars = ['Name', 'Geburtstag', 'Würfelfarbe', 'Summe Augen'])` produziert einen leeren Dataframe, weil keine gemessenen Werte verbleiben.

Auch der umgekehrte Fall ist möglich: Werden beim melting keine `id_vars` angegeben, werden alle Spalten als gemessene Variablen behandelt.

```
messung1_no_id = pd.melt(messung1)
```

```
messung1_no_id
```

	variable	value
0	Name	Hans
1	Name	Elke
2	Name	Jean
3	Name	Maya
4	Name	Hans
5	Geburtstag	26.02.
6	Geburtstag	14.03.
7	Geburtstag	30.12.
8	Geburtstag	07.09.
9	Geburtstag	11.11.
10	Würfelfarbe	rosa
11	Würfelfarbe	rosa
12	Würfelfarbe	blau
13	Würfelfarbe	gelb
14	Würfelfarbe	rosa
15	Summe Augen	12
16	Summe Augen	17
17	Summe Augen	8
18	Summe Augen	23
19	Summe Augen	7

Die Umkehroperation zum melting wird casting (gießen) oder pivoting (schwenken) genannt. Dabei wird ein im long-Format vorliegender Datensatz in das wide-Format konvertiert. Die Pandas Funktion `pd.pivot(data, columns, index)` nimmt einen melted DataFrame entgegen und konvertiert diesen aus den einzigartigen Werten in columns (= Spaltennamen des DataFrame im wide-Format) und den einzigartigen Werten in index (= Zeilenindex des DataFrame im wide-Format). Wird der Funktion keine Spalte für index übergeben, wird der bestehende Index des melted DataFrame verwendet (der mit 20 Zeilen natürlich viel zu lang ist.) Da das Objekt `messung1_no_id` keine geeignete Indexspalte besitzt, muss diese vor dem casting erzeugt werden. Dies ist mit der Methode `messung1_no_id.groupby('variable').cumcount()` möglich, die die Anzahl jeder Ausprägung in der übergebenen Spalte bei 0 beginnend durchzählt. (Ein direktes Ersetzen des Index ist auf diese Weise nicht möglich, da der Index des an `pd.pivot(data, columns, index)` übergebenen DataFrames keine Doppelungen enthalten darf.)

```
# pd.pivot() benötigt einen Index oder benutzt den bestehenden Index, des melted_df, der zu 1
# Deshalb eine zusätzliche Spalte in messung1_no_id einfügen
## einfach: messung1_no_id['new_index'] = list(range(0, 5)) * 4
## allgemein: messung1_no_id['new_index'] = messung1_no_id.groupby('variable').cumcount()

# Spalte new_index einfügen
messung1_no_id['new_index'] = messung1_no_id.groupby('variable').cumcount()
print (f"Der Datensatz im long-Format mit zusätzlicher Spalte new_index:\n{messung1_no_id}")

# casting
messung1_cast = pd.pivot(messung1_no_id, index = 'new_index', columns = 'variable', values = 
print(f"\nDer Datensatz im wide-Format:\n{messung1_cast}")
```

Der Datensatz im long-Format mit zusätzlicher Spalte new_index:

	variable	value	new_index
0	Name	Hans	0
1	Name	Elke	1
2	Name	Jean	2
3	Name	Maya	3
4	Name	Hans	4
5	Geburtstag	26.02.	0
6	Geburtstag	14.03.	1
7	Geburtstag	30.12.	2
8	Geburtstag	07.09.	3
9	Geburtstag	11.11.	4
10	Würfelfarbe	rosa	0
11	Würfelfarbe	rosa	1
12	Würfelfarbe	blau	2
13	Würfelfarbe	gelb	3

14	Würfelfarbe	rosa	4
15	Summe Augen	12	0
16	Summe Augen	17	1
17	Summe Augen	8	2
18	Summe Augen	23	3
19	Summe Augen	7	4

Der Datensatz im wide-Format:

variable	Geburtstag	Name	Summe Augen	Würfelfarbe
new_index				
0	26.02.	Hans	12	rosa
1	14.03.	Elke	17	rosa
2	30.12.	Jean	8	blau
3	07.09.	Maya	23	gelb
4	11.11.	Hans	7	rosa

Das Ergebnis entspricht noch nicht dem ursprünglichen Datensatz im wide-Format. Um das Ausgangsformat wiederherzustellen, müssen die Spalten in die ursprüngliche Reihenfolge gebracht sowie der Index und dessen Beschriftung zurückgesetzt werden.

```
# Spalten anordnen, Index zurücksetzen
messung1_cast = messung1_cast[['Name', 'Geburtstag', 'Würfelfarbe', 'Summe Augen']]
messung1_cast.reset_index(drop = True, inplace = True)
messung1_cast.rename_axis(None, axis = 1, inplace = True)

print(f"\nDer Datensatz im wide-Format mit zurückgesetztem Index:\n\n{messung1_cast}")
```

Der Datensatz im wide-Format mit zurückgesetztem Index:

	Name	Geburtstag	Würfelfarbe	Summe Augen
0	Hans	26.02.	rosa	12
1	Elke	14.03.	rosa	17
2	Jean	30.12.	blau	8
3	Maya	07.09.	gelb	23
4	Hans	11.11.	rosa	7

Tipp 6: identifizierende und gemessene Variablen

Auch wenn Sie mit Datensätzen im wide-Format arbeiten, ist die Unterscheidung identifizierender und gemessener Variablen nützlich, um Datensätze zu organisieren. siehe [2.5](#)

2.2.5 Übung zweidimensionale Datensätze

Oben wurde das Objekt `messung1_long` mit dem Befehl `messung1_long = pd.melt(messung1, id_vars = ['Name', 'Geburtstag'])` angelegt.

Benutzen Sie die Funktion `pd.DataFrame.pivot()`, um den Datensatz `messung1` wieder ins wide-Format zu transformieren.

	Name	Geburtstag	variable	value
0	Hans	26.02.	Würfelfarbe	rosa
1	Elke	14.03.	Würfelfarbe	rosa
2	Jean	30.12.	Würfelfarbe	blau
3	Maya	07.09.	Würfelfarbe	gelb
4	Hans	11.11.	Würfelfarbe	rosa
5	Hans	26.02.	Summe Augen	12
6	Elke	14.03.	Summe Augen	17
7	Jean	30.12.	Summe Augen	8
8	Maya	07.09.	Summe Augen	23
9	Hans	11.11.	Summe Augen	7

💡 Tipp 7: Musterlösung zweidimensionale Datensätze

```
# Spalte new_index einfügen
messung1_long['new_index'] = messung1_long.groupby('variable').cumcount()

# casting
messung1_long_cast = pd.pivot(messung1_long, index = 'new_index', columns = 'variable', values = 'value')

# Spalten anordnen, Index zurücksetzen
messung1_long_cast = messung1_long_cast[['Name', 'Geburtstag', 'Würfelfarbe', 'Summe Augen']]
messung1_long_cast.reset_index(drop = True, inplace = True)
messung1_long_cast.rename_axis(None, axis = 1, inplace = True)

messung1_long_cast
```

	Name	Geburtstag	Würfelfarbe	Summe Augen
0	Hans	26.02.	rosa	12
1	Elke	14.03.	rosa	17
2	Jean	30.12.	blau	8
3	Maya	07.09.	gelb	23
4	Hans	11.11.	rosa	7

2.2.6 Drei- und mehrdimensionale Datensätze

Drei- oder mehrdimensionale Datensätze organisieren komplexe Datenstrukturen in sogenannten **Arrays**. Arrays sind n-dimensionale Datenstrukturen und damit zugleich ein Oberbegriff. So ist eine Liste ein eindimensionales Array, eine Matrix ein zweidimensionales Array und eine Excel-Datei mit mehreren Arbeitsblättern für jährlich erhobene Umfragedaten ein 3-dimensionales Array (Arbeitsblätter, Zeilen, Spalten). Abhängig vom verwendeten Modul können Arrays ein oder mehrere Datentypen enthalten.




Abbildung 2.4: dreidimensionale Datensätze

slicing von Marc Fehr ist lizenziert unter [CC-BY-4.0](#) und abrufbar auf [GitHub](#). Die Grafik wurde auf den gezeigten Teil beschnitten und die obenstehende Beschriftung entfernt. 2024

Für drei- und mehrdimensionale Datenstrukturen werden häufig spezialisierte Datenformate verwendet, die im Abschnitt Kapitel 7 behandelt werden. Dies hat unter anderem den Grund, dass so leichter verschiedene Datentypen verarbeitet und mit Metadaten (siehe Kapitel 2.4) dokumentiert werden können.

Bilddaten einlesen

Digitale Bilder liegen in Form eines dreidimensionalen Datensatzes vor. In Zeilen und Spalten liegen für jeden Pixel Farbwerte (Rot, Grün, Blau) und gegebenenfalls ein Alphawert vor (Rot, Grün, Blau, Alpha). Die Farbwerte liegen entweder im Bereich von 0 bis 1 oder von 0 bis 255 (8-Bit).

```
# Farbwerte für einen Pixel
[Rotwert, Grünwert, Blauwert]
```

```
# Eine Bildzeile mit drei Pixeln
[[Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert]]


# Ein Bild aus drei Zeilen und Spalten
[[[Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert],
  [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert],
  [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert], [Rotwert, Grünwert, Blauwert]]]
```

Bilddateien können mit der Funktion `plt.imread()` aus dem Modul `matplotlib.pyplot` eingelesen werden.

```
import matplotlib.pyplot as plt

logo = plt.imread(fname = '00-bilder/python-logo-and-wordmark-cc0-tm.png')

plt.imshow(logo)
```



Python Logo von Python Software Foundation steht unter der [GPLv3](https://www.gnu.org/licenses/gpl-3.0.de.html). Die Wort-Bild-Marke ist markenrechtlich geschützt: <https://www.python.org/psf/trademarks/>. Das Werk ist abrufbar auf [wikimedia](https://commons.wikimedia.org/wiki/File:Python_logo_and_wordmark.png). 2008

Die Struktur des Datensatzes kann mit dem Attribut `.shape` abgerufen werden.

```
print(type(logo), "\n")

print(logo.shape)
```

```
<class 'numpy.ndarray'>
```

```
(144, 486, 4)
```

Die Daten wurden als NumPy.ndarray eingelesen. Das Logo hat 144 Zeilen, 486 Spalten und liegt im RGBA-Farbraum vor. Ein Ausschnitt der Daten sieht so aus:

```
print(logo[50:52, 50:52, : ])
```

```
[[[0.21568628 0.44705883 0.63529414 1.          ]
   [0.21568628 0.44705883 0.63529414 1.          ]

  [[0.21568628 0.44705883 0.63529414 1.          ]
   [0.21176471 0.44313726 0.6313726  1.          ]]]
```

(Arnold [2023b](#))

2.2.7 Übung dreidimensionale Datensätze

Über den Index der dritten Dimension können die Farbkanäle Rot, Grün und Blau ausgewählt und mit der Funktion `plt.imshow(cmap = 'Greys_r')` einzeln dargestellt werden. Das Argument `cmap = 'Greys_r'` weist die Funktion an, die invertierte Grauskala benutzen. Dadurch werden hohe Farbwerte hell und niedrige Farbwerte dunkel dargestellt. **Stellen Sie die Farbkanäle Rot, Grün und Blau des Pythonlogos einzeln mit der Funktion `plt.imshow(cmap = 'Greys_r')` dar.**

💡 Tipp 8: Musterlösung dreidimensionale Datensätze

```
kanal = ["Rotkanal", "Grünkanal", "Blaukanal"]

plt.figure(figsize = (9, 6))

for i in range(3):

    plt.subplot(1, 4, i + 1)
    plt.imshow(logo[ :, :, i], cmap = 'Greys_r')
    plt.title(label = kanal[i])

plt.colorbar(shrink = 0.15)

plt.tight_layout()
plt.show()
```




Abbildung 2.5: Farbkanäle des Pythonlogos

Möglicherweise wundern Sie sich, warum der Bildhintergrund in jedem Farbkanal schwarz ist. Die Ursache finden Sie im nächsten Tipp.

Tipp 2.6: Erklärung Bildhintergrund

Der Bildhintergrund hat in allen Kanälen, auch im Alphakanal, den Farbwert 0. Dieser Teil des Bildes ist deshalb vollständig transparent und wird vom Hintergrund der Internetseite ausgefüllt. Der Bildhintergrund des Logos wirkt deshalb weiß.

```
# Alphakanal
plt.imshow(logo[:, :, 3], cmap = 'Greys_r')
plt.title(label = 'Alphakanal')
plt.colorbar(shrink = 0.4)

plt.show()

# Die ersten zwei Zeilen und Spalten des Logos
print(logo[0:2, 0:2, :])
```




Abbildung 2.6: Alphakanal des Pythonlogos

```
[[[0. 0. 0. 0.]
  [0. 0. 0. 0.]
```

```
[[0. 0. 0. 0.]  
 [0. 0. 0. 0.]]
```

2.3 Datentyp

Der Datentyp gibt an, wie die in einem Datensatz enthaltenen Werte von Python interpretiert werden sollen. Beispielsweise kann der Wert “1” ein Zeichen, eine Ganzzahl, einen Wahrheitswert, den Monat Januar oder die Ausprägung einer kategorialen Variablen repräsentieren. Python unterstützt als vielseitig einsetzbare Programmiersprache zahlreiche Datentypen, die den Kategorien: numerics, sequences, mappings, classes, instances and exceptions zugeordnet sind. Nähere Informationen dazu finden Sie in der [Dokumentation](#).




Abbildung 2.7: Datentypen in Python

Python 3. The standard type hierarchy. von [wikimedia](#). 2018 ist lizenziert unter [CC BY SA 4.0](#) und abrufbar auf [wikimedia](#).

Durch Module werden weitere Datentypen hinzugefügt. In der Datenanalyse häufig verwendete Datentypen sind:

- Zahlen: Ganzzahl, Fließkommazahlen
- Wahrheitswerte
- Zeichenketten

- Datums- und Uhrzeitangaben
- Kategorie (aus dem Modul [Pandas](#))

Der Datentyp bestimmt zum einen den zulässigen Wertebereich einer Variablen. Beispielsweise sind 0 und 13 zulässige Ganzzahlen, aber keine gültigen Kodierungen des Monats. Zum anderen definiert der Datentyp, welche Operationen mit den Werten zulässig sind und wie diese von Python ausgeführt werden. Dies betrifft Operatoren und Funktionen. Python enthält Funktionen, um den Datentyp eines Werts zu bestimmen und ggf. umzuwandeln (siehe w-Python).

Hinweis 1: Datentypabhängige Operationen und Funktionen

```
# Der Operator + bewirkt die Addition von Zahlen
```

```
print(1 + 13)
```

```
# Der Operator + bewirkt auch das Verketteten von strings
```

```
print(str(1) + str(13))
```

```
14
```

```
113
```

Die Sortierfunktion arbeitet abhängig vom Datentyp.

```
# Liste von Monatskürzeln erstellen
```

```
dates = pd.Series([ '07.06.2000', '12.01.2000', '11.02.2000', '04.09.2000', '10.03.2000',  
dates = pd.to_datetime(dates, format = '%d.%m.%Y');
```

```
print(f"Eine unsortierte Liste von Monatskürzeln:\n{list(dates.dt.strftime('%b'))}")
```

```
print(f"\nDie Liste alphabetisch sortiert:\n{sorted(list(dates.dt.strftime('%b')))}")
```

```
print(f"\nDie Liste als datetime-Objekt sortiert:\n{list(dates.sort_values().dt.strftime('%b'))}")
```

```
Eine unsortierte Liste von Monatskürzeln:
```

```
['Jun', 'Jan', 'Feb', 'Sep', 'Mar', 'Oct', 'Apr', 'May', 'Jul', 'Aug', 'Nov', 'Dec']
```

```
Die Liste alphabetisch sortiert:
```

```
['Apr', 'Aug', 'Dec', 'Feb', 'Jan', 'Jul', 'Jun', 'Mar', 'May', 'Nov', 'Oct', 'Sep']
```

```
Die Liste als datetime-Objekt sortiert:
```

```
['Jan', 'Feb', 'Mar', 'Apr', 'May', 'Jun', 'Jul', 'Aug', 'Sep', 'Oct', 'Nov', 'Dec']
```

Tipp 9: Datentyp kontrollieren und plausibilisieren

Beim Einlesen von Datensätzen ist es wichtig, die korrekte Erkennung der Datentypen zu kontrollieren bzw. aktiv zu steuern. Weitere Methoden für die formale Prüfung des Datentyps und für die Kontrolle des Wertebereichs werden in Kapitel 3 vorgestellt.

2.3.1 Fehlende Werte

Ein besonderer Datentyp ist der zur Repräsentation fehlender Werte. In Python wird zwischen nicht existenten und nicht definierten Werten unterschieden.

Nullwert None

Der sogenannte Nullwert in Python ist **None**, das zu den definierten Schlüsselwörtern in Python gehört.

```
print(type(None))
```

```
<class 'NoneType'>
```

None repräsentiert nicht existente Werte und Objekte. Leere (aber existente) Objekte gehören nicht zum Datentyp **None**.

```
leere_liste = []  
leere_liste == None
```

False

None kann Funktionen als Argument übergeben oder von diesen als Rückgabewert ausgegeben werden. Operationen sind mit **None** jedoch nicht möglich.

```
# Operationen mit None führen zu Fehlermeldungen  
try:  
    print(None + 1)  
except TypeError as error:  
    print("Der übergebene Wert führt zu der Fehlermeldung:\n", error)  
else:  
    print(None + 1)
```

Der übergebene Wert führt zu der Fehlermeldung:
unsupported operand type(s) for +: 'NoneType' and 'int'

Eine Ausnahme ist die Umwandlung in eine Zeichenkette.

```
# Eine Ausnahme ist die Umwandlung in strings
a = None
print("\nprint(a) gibt den Nullwert zurück:\n", a, sep = "")

print("\nstr(a) gibt eine Zeichenkette zurück:")
str(a)
```

```
print(a) gibt den Nullwert zurück:
None
```

```
str(a) gibt eine Zeichenkette zurück:
```

```
'None'
```

NaN

Um mit fehlenden Werten innerhalb eines Datensatzes arbeiten zu können, gibt es den Wert NaN, der zur Klasse der Fließkommazahlen gehört. NaN steht für Not a Number und repräsentiert undefinierte oder nicht darstellbare Werte. Beispielsweise berechnet die Methode `pd.diff()` die Differenz jedes Werts zu seinem Vorgänger. Da der erste Wert keinen Vorgänger hat, wird NaN erzeugt.

```
my_series = pd.Series([1, 2, 4, 8])
my_series.diff()
```

```
0    NaN
1    1.0
2    2.0
3    4.0
dtype: float64
```

Anders als None ist NaN kein Standardschlüsselwort in Python. Der Wert NaN wird erzeugt mit `float('nan')` oder `float('NaN')`, die Groß- und Kleinschreibung spielt keine Rolle. NaN hat also den Datentyp Fließkommazahl. Die Module `math` und `NumPy` bieten mit `math.nan` und `np.nan` ebenfalls Funktionen, um NaN zu erzeugen.

```
print(type(float('NaN')))
```

```
<class 'float'>
```

Mit dem Wert 'NaN' können Operationen ausgeführt werden. Das Ergebnis ist immer NaN.

```
print(float('NaN') + 1)
```

```
nan
```

Einige Funktionen können mit NaN als Platzhalter für fehlende Werte umgehen.

```
# Python-Basis
print("sum():", sum([1, 2, float('NaN'), 4]), "\n")
print("max():", max([1, 2, float('NaN'), 4]), "\n")
print("any():", any([1, 2, float('NaN'), 4]), "\n")

# Pandas
daten_mit_nan = pd.Series([1, 2, float('NaN'), 4])
print(daten_mit_nan + 1)
print("\nSumme des Datensates:", daten_mit_nan.sum())
```

```
sum(): nan
```

```
max(): 4
```

```
any(): True
```

```
0    2.0
```

```
1    3.0
```

```
2    NaN
```

```
3    5.0
```

```
dtype: float64
```

```
Summe des Datensates: 7.0
```

⚠ Warning 2: Achtung Logik!

Die logische Abfrage fehlender Werte unterscheidet sich für `None` und `NaN`.

```
bool_values = [None, float('NaN')]

for element in bool_values:
    bool_value = bool(element)
    print("Wahrheitswert von", element, "ist", bool_value)
```

Wahrheitswert von `None` ist `False`

Wahrheitswert von `nan` ist `True`

Dies gilt auch für die Wertgleichheit.

```
for element in bool_values:
    result = element == element
    print("Wertgleichheit von", element, "ist", result)
```

Wertgleichheit von `None` ist `True`

Wertgleichheit von `nan` ist `False`

2.3.2 Fehlende Werte in der Praxis

`None` und `NaN` sind python-spezifische Repräsentationen für nicht existente oder nicht definierte Werte. In der Praxis werden fehlende Werte in Datensätzen auf unterschiedliche Weise gekennzeichnet.

In Datensätzen übliche Werte sind:

- kein Eintrag, beispielsweise in kommaseparierten Dateien eine leere Zeichenkette `""`
- definierte Zeichenfolge: `NA` in der Programmiersprache R, `NULL` in der Datenbanksprache SQL, `.` in der Statistik-Software Stata
- (mehrere) manuell gewählte Zeichen oder Ziffern außerhalb des zulässigen Wertebereichs wie `-1`, `-88`, `-99` (häufig bei Umfragedaten)

Die Art der Kennzeichnung ist jeweils mit Vor- und Nachteilen verbunden. Eine definierte Zeichenfolge für fehlende Werte hilft dabei, Lücken im Datensatz von Fehlern bei der Datenerfassung zu unterscheiden. Dazu ist eine definierte Zeichenfolge wie `"NA"` besser als eine leere Zeichenkette geeignet. Manuell gewählte Werte erlauben es, bei der automatischen Auswertung eines Datensatzes abhängig von der Situation ein bestimmtes Verhalten für jede Variable

festzulegen (z. B. Unterscheidung von nicht zutreffend, Aussage verweigert, weiß nicht, Interview abgebrochen keine Antwort).

Tipp 10: fehlende Werte

Die Identifizierung und ggf. Bereinigung fehlender Werte ist ein wichtiger Schritt beim Einlesen strukturierter Datensätze. Dabei hilft es, die gängigen Kennzeichnungen für fehlende Werte zu kennen und sich über die Konventionen des jeweiligen Dateiformats bzw. der jeweiligen Disziplin zu informieren. Dennoch ist manchmal ein gewisser Spürsinn unerlässlich. Geeignete Funktionen zur Identifizierung fehlender Werte werden in Kapitel 3 vorgestellt.

2.4 Metadaten

Metadaten sind beschreibende Informationen eines Datensatzes. Metadaten geben beispielsweise an:

- welche Datentypen ein Datensatz enthält,
- verwendete Kodierschemen, Skalen oder minimal und maximal zulässige Werte,
- die Bedingungen, unter denen die Daten erhoben wurden,
- Herkunft der Daten,
- Beziehungen zwischen Variablen und Datensätzen,
- urheberrechtliche Informationen und Lizenzhinweise.

(vgl. [The HDF Group Help Desk](#))

Spezialisierte Dateiformate wie netCDF oder HDF deklarieren Metadaten explizit in dafür vorgesehenen Feldern. Vielen Dateiformaten fehlt eine solche Funktion. Relevante Metadaten stehen deshalb häufig im Dateinamen, in Spaltenbeschriftungen, in zusätzlichen Tabellenblättern oder in separaten Dokumenten (die nicht immer zur Verfügung stehen).

Tipp 11: Metadaten

Insbesondere vor dem Einlesen komplexer Datensätze sollten Begleitmaterialien, sofern vorhanden, studiert werden.

2.5 Tidy data

Datensätze werden mit verschiedenen Zielstellungen angelegt, etwa dass eine bequeme Dateneingabe möglich ist. Dies führt aber häufig dazu, dass Datensätze für die skriptbasierte Datenanalyse zunächst aufwändig aufgeräumt werden müssen.

“Tidy datasets are all alike, but every messy dataset is messy in its own way.” (Wickham, Çetinkaya-Rundel und Grolemund 2023, Kapitel 5 Data tidying)

Tidy data ist ein System von Hadley Wickham, das dabei hilft, Datensätze in ein aufgeräumtes (tidy) Format zu bringen. Das Aufräumen von Datensätzen ist eine vorbereitende Tätigkeit mit dem Ziel, während der eigentlichen Datenanalyse möglichst wenig Zeit für das Umformen von Datenstrukturen aufwenden zu müssen. Dadurch soll ein größerer Fokus auf den inhaltlichen Aspekt der Datenanalyse ermöglicht werden. (Wickham, Çetinkaya-Rundel und Grolemund 2023, Kapitel 5 Data tidying)

! Wichtig 2: tidy data

“Das System tidy data besteht aus drei Regeln:

1. Jede Variable ist eine Spalte; jede Spalte ist eine Variable.
2. Jede Beobachtung ist eine Zeile; jede Zeile ist eine Beobachtung.
3. Jeder Wert ist eine Zelle; jede Zelle ist ein einzelner Wert.”

(Wickham, Çetinkaya-Rundel und Grolemund 2023, Kapitel 5 Data tidying, eigene Übersetzung)

Tidy data bezieht sich auf zweidimensionale Datensätze, bietet aber auch darüber hinaus eine Orientierung, um unterschiedlich aufgebaute Datensätze strukturiert einzulesen und für die Datenanalyse vorzubereiten. Tidy data ist kein strikt zu befolgendes Regelwerk. Es ist völlig in Ordnung, eine andere Struktur zu wählen, wenn die Datenanalyse damit leichter durchgeführt werden kann.

3 Die Module NumPy und Pandas

Die Module NumPy und Pandas erlauben ein effizientes Arbeiten mit Datensätzen. Insbesondere das Lesen- und Schreiben von Dateien und die Verwaltung von Datentypen ist erheblich einfacher als mit der Python-Basis. Außerdem sind die vektorisierten Operationen vielfach schneller als Operationen mit Python. Das Modul Pandas basiert auf NumPy. In den folgenden Abschnitten werden beide Module behandelt.

Eine kurze Übersicht der Vor- und Nachteile:

- **NumPy**: n-dimensionale Array-Struktur mit Unterstützung der am häufigsten verwendeten Datentypen sowie zahlreicher numerischer Formate für spezialisierte wissenschaftliche Berechnungen ([siehe Dokumentation](#)). Ein Array kann immer nur einen Datentyp haben und die Größe von Arrays ist unveränderlich. Dafür werden Operationen etwas schneller als in der DataFrame-Struktur von Pandas ausgeführt.
 - Spaltennamen sind mit einem strukturierten dtype möglich ([siehe Dokumentation](#))
- **Pandas**: 2-dimensionale DataFrame-Struktur im long- und wide-Format. DataFrames können mehrere Datentypen enthalten und die Größe von DataFrames ist veränderlich. Unterstützung von alphanummerischen Spalten- und Indexbeschriftungen. Direktes Abrufen von Dateien aus dem Internet möglich.
 - dreidimensionale DataFrames sind mit einem Multiindex möglich –> das widerspricht aber dem Konzept von Tidy Data

Für beide Module haben sich diese Kürzel etabliert:

```
import numpy as np
import pandas as pd

# Deklarieren der Anzahl der Nachkommastellen
pd.set_option("display.precision", 2)
```

Tipp 12: Arbeiten mit NumPy und Pandas

Ob Sie mit NumPy oder mit Pandas arbeiten, hängt von dem vorliegenden Datensatz und persönlichen Präferenzen ab.

Das Paket Pandas erlaubt es, Daten aus verschiedenen Quellen wie CSV-Dateien oder Excel-Tabellen und mit unterschiedlichen Datentypen in einen DataFrame zu laden. Anschließend können diese mit wenigen Befehlen untersucht und umstrukturiert werden. Komplexe Operationen wie das Umformen von Datensätzen, das Gruppieren und Aggregieren von Daten sowie das Filtern und Sortieren sind effizient möglich. Bis auf wenige Ausnahmen sind Pandas und NumPy zueinander kompatibel. Es spricht nichts dagegen, Ihre Daten mit Pandas vorzubereiten und anschließend mit NumPy auszuwerten.

3.1 Datentypen

NumPy unterstützt folgende Datentypen:

Datentyp NumPy-Array	Datentyp in Python
int_	int
double	float
cdouble	complex
bytes_	bytes
str_	str
bool_	bool
datetime64	datetime.datetime
timedelta64	datetime.timedelta

Dokumentation NumPy

In den meisten Fällen verwendet das Modul Pandas die NumPy-Datentypen. Pandas führt aber auch einige zusätzliche Datentypen ein. Eine vollständige Liste finden Sie in der [Pandas Dokumentation](#). Die wichtigsten zusätzlichen Datentypen sind:

- [Kategorie](#) dtype = 'category'
- [Zeitzonebewusstes Datumsformat](#) dtype = 'datetime64[ns, US/Eastern]'

3.2 Dateien lesen und schreiben

In den Werkzeugbausteinen NumPy und Pandas haben Sie die Funktionen zum Lesen und Schreiben von Dateien kennengelernt.

3.3 NumPy

In NumPy können Dateien mit der Funktion `np.loadtxt()` gelesen und mit der Funktion `np.savetxt()` geschrieben werden.

- `np.loadtxt(fname = data.txt, delimiter = ";", skiprows= #Reihen)`
- `np.savetxt(fname = dateipfad, X = daten, header = kommentar, fmt='%5.2f')`

3.4 Pandas

In Pandas werden Dateien mit einer Reihe spezialisierter Funktionen gelesen und geschrieben, die einem einheitlichen Schema folgen. Funktionen zum Lesen von Dateien werden in der Form `pd.read_csv` und Funktionen zum Schreiben in der Form `pd.to_csv` aufgerufen. Mit Pandas können auch Dateien aus dem Internet abgerufen werden `pd.read_csv(URL)`.

Format	Type	Data Description	Reader	Writer
	text	CSV	<code>read_csv</code>	<code>to_csv</code>
	text	Fixed-Width Text File	<code>read_fwf</code>	NA
	text	JSON	<code>read_json</code>	<code>to_json</code>
	text	HTML	<code>read_html</code>	<code>to_html</code>
	text	LaTeX	<code>Styler.to_latex</code>	NA
	text	XML	<code>read_xml</code>	<code>to_xml</code>
	text	Local clipboard	<code>read_clipboard</code>	<code>to_clipboard</code>
binary		MS Excel	<code>read_excel</code>	<code>to_excel</code>
binary		OpenDocument	<code>read_excel</code>	NA
binary		HDF5 Format	<code>read_hdf</code>	<code>to_hdf</code>
binary		Feather Format	<code>read_feather</code>	<code>to_feather</code>
binary		Parquet Format	<code>read_parquet</code>	<code>to_parquet</code>
binary		ORC Format	<code>read_orc</code>	<code>to_orc</code>
binary		Stata	<code>read_stata</code>	<code>to_stata</code>
binary		SAS	<code>read_sas</code>	NA
binary		SPSS	<code>read_spss</code>	NA
binary		Python Pickle Format	<code>read_pickle</code>	<code>to_pickle</code>
	SQL	SQL	<code>read_sql</code>	<code>to_sql</code>

([Pandas Dokumentation](#))

3.5 Datentypen erkennen und festlegen

Der Datentyp bestimmt, wie bereits ausgeführt, den zulässigen Wertebereich einer Variablen, zulässige Operationen und die Ausführung von Operatoren und Funktionen in Python. Die Module NumPy und Pandas bieten eine Reihe von Funktionen, um den Datentyp von Variablen zu kontrollieren und festzulegen.

Hinweis: Der Datentyp `datetime` wird in Kapitel 4 behandelt.

3.5.1 NumPy

Mit NumPy kann der Datentyp eines Arrays beim Einlesen einer Datei mit dem Argument `dtype` festgelegt werden `np.loadtxt(fname = data.txt, dtype = 'float')`. Das Argument `dtype` akzeptiert die Angabe eines Datentyps, Schlüsselwörter oder Kürzel. Weiter Informationen erhalten Sie in der [NumPy Dokumentation](#).

Datentyp	Schlüsselwort	Kürzel	dtype
Fließkommazahl	float	f8	float64
Ganzzahl	int	i	int32
Wahrheitswert	bool	?	bool
Datum	datetime64	M	datetime64
Zeichenkette	str	U	U + Ziffer zur Angabe der benötigten Bytes

Der Datentyp eines Arrays kann mit dem Attribut `np.dtype` bestimmt werden. Der Datentyp eines Objekts kann mit der Methode `np.array = np.array.astype()` geändert werden.

Folgende Datei ist Ihnen aus dem w-NumPy bekannt.

```
dateipfad = '01-daten/TC01.csv'
daten = np.loadtxt(dateipfad)
```

Prüfen Sie den `dtype` der Datei und legen Sie eine Kopie des Objekts mit Datentyp `Ganzzahl` an. Wie kann überprüft werden, ob bei der Umwandlung in `Ganzzahlen` Nachkommastellen abgeschnitten wurden?

Tipp 13: Musterlösung Datentypumwandlung

```
# Ausgabe des Datentyps
print(daten.dtype)

# Umwandlung in Ganzzahl
daten_int = daten.astype('int')

# Prüfen auf Datenverlust
prüfsumme = daten - daten_int
print(f"Differenz daten - daten_int: {prüfsumme.sum()}")

float64
Differenz daten - daten_int: 664.0
```

3.5.2 Pandas

Das Modul Pandas ist auf den Umgang mit unterschiedlichen Datentypen spezialisiert. Den Funktionen zum Einlesen von Daten kann mit dem Argument `dtype` der Datentyp übergeben werden. Für mehrere Spalten ist dies in Form eines Dictionaries in der Form `{'Spaltenname': 'dtype'}` möglich.

Das Attribut zur Ausgabe des Datentyps heißt passenderweise `pd.DataFrame.dtypes` (angefügte `s` beachten). Der Datentyp eines Pandas-Datenobjekts kann analog zu NumPy mit `pd.Series = pd.Series.astype()` geändert werden.

Zahnwachstum bei Meerschweinchen

In einer Gruppe von 60 Meerschweinchen (**1. Spalte ohne Beschriftung**) wurde die Länge der zahnbildenden Zellen (Odontoblasten) in Micron gemessen (**len**). Den Tieren wurde zuvor Vitamin C in Form von Ascorbinsäure (VC) oder Orangensaft (VC) verabreicht (**supp**). Die Meerschweinchen erhielten Dosen von 0.5, 1 oder 2 Milligramm Vitamin C pro Tag (**dose**). Die Messdaten sind in der Datei `ToothGrowth.csv` gespeichert (Crampton 1947.)

Crampton, E. W. 1947. „THE GROWTH OF THE ODONTOBLASTS OF THE INCISOR TOOTH AS A CRITERION OF THE VITAMIN C INTAKE OF THE GUINEA PIG“. The Journal of Nutrition 33 (5): 491–504. <https://doi.org/10.1093/jn/33.5.491>

Lesen Sie die Datei wie folgt ein:

- Die Spaltenbeschriftung der 1. Spalte soll mit der Beschriftung 'ID' ersetzt werden (ohne Anführungszeichen).
- Die Spalten len und dose sollen mit geeigneten numerischen Datentypen, die Spalte supp als Kategorie eingelesen werden.

💡 Tipp 14: Musterlösung Meerschweinchen

```
dateipfad = "01-daten/ToothGrowth.csv"
meerschweinchen = pd.read_csv(filepath_or_buffer = dateipfad, sep = ',', header = 0, \
    names = ['ID', 'len', 'supp', 'dose'], dtype = {'ID': 'int', 'len': 'float', 'dose': 'flo

# Ausgabe jedes sechsten Werts
meerschweinchen.iloc[meerschweinchen.index % 6 == 0]
```

	ID	len	supp	dose
0	1	4.2	VC	0.5
6	7	11.2	VC	0.5
12	13	15.2	VC	1.0
18	19	18.8	VC	1.0
24	25	26.4	VC	2.0
30	31	15.2	OJ	0.5
36	37	8.2	OJ	0.5
42	43	23.6	OJ	1.0
48	49	14.5	OJ	1.0
54	55	24.8	OJ	2.0

```
print(meerschweinchen.dtypes)
```

```
ID          int64
len         float64
supp        category
dose        float64
dtype: object
```

Nützliche Funktionen für die deskriptive Datenanalyse

Pandas bietet einige praktische Funktionen, um den Aufbau eines Datensatzes zu beschreiben.

Das Attribut `.columns` gibt die Spaltenbeschriftungen als Liste zurück. Ebenfalls ist darüber ein Schreibzugriff möglich.

```
print(meerschweinchen.columns)
meerschweinchen.columns = ['ID', 'Länge', 'Verabreichung', 'Dosis']
print(meerschweinchen.columns)
```

```
Index(['ID', 'len', 'supp', 'dose'], dtype='object')
Index(['ID', 'Länge', 'Verabreichung', 'Dosis'], dtype='object')
```

Die Methode `pd.DataFrame.describe()` erzeugt eine beschreibende Statistik für einen DataFrame. Standardmäßig werden alle numerischen Spalten berücksichtigt. Mit dem Argument `include` können die zu berücksichtigenden Spalten vorgegeben werden. `include = all` berücksichtigt alle Spalten, was nicht unbedingt sinnvoll ist. Alternativ kann eine Liste zu berücksichtigender Datentypen übergeben werden. Das Argument `exclude` schließt auf die gleiche Weise Datentypen von der Ausgabe aus.

```
print(meerschweinchen.describe(), "\n")

print(meerschweinchen.describe(include = 'all'), "\n")

print(meerschweinchen.describe(include = ['float']), "\n")
```

	ID	Länge	Dosis
count	60.00	60.00	60.00
mean	30.50	18.81	1.17
std	17.46	7.65	0.63
min	1.00	4.20	0.50
25%	15.75	13.07	0.50
50%	30.50	19.25	1.00
75%	45.25	25.27	2.00
max	60.00	33.90	2.00

	ID	Länge	Verabreichung	Dosis
count	60.00	60.00	60	60.00
unique	NaN	NaN	2	NaN
top	NaN	NaN	OJ	NaN
freq	NaN	NaN	30	NaN
mean	30.50	18.81	NaN	1.17
std	17.46	7.65	NaN	0.63
min	1.00	4.20	NaN	0.50

25%	15.75	13.07	NaN	0.50
50%	30.50	19.25	NaN	1.00
75%	45.25	25.27	NaN	2.00
max	60.00	33.90	NaN	2.00

	Länge	Dosis
count	60.00	60.00
mean	18.81	1.17
std	7.65	0.63
min	4.20	0.50
25%	13.07	0.50
50%	19.25	1.00
75%	25.27	2.00
max	33.90	2.00

Die Methode `pd.DataFrame.count()` zählt alle vorhandenen Werte in jeder Spalte oder mit `pd.DataFrame.count(axis = 'columns')` in jeder Zeile.

```
meerschweinchen.count(axis = 'rows') # der Standardwert von axis ist 'rows'
```

```
ID          60
Länge       60
Verabreichung 60
Dosis       60
dtype: int64
```

Die Methode `pd.DataFrame.info()` erzeugt eine Beschreibung des Datensatzes.

```
meerschweinchen.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 60 entries, 0 to 59
Data columns (total 4 columns):
#   Column          Non-Null Count  Dtype
---  -
0   ID              60 non-null    int64
1   Länge          60 non-null    float64
2   Verabreichung  60 non-null    category
3   Dosis          60 non-null    float64
dtypes: category(1), float64(2), int64(1)
memory usage: 1.7 KB
```

Die Methode `pd.unique()` listet alle einzigartigen Werte auf.

```
meerschweinchen['Dosis'].unique()
```

```
array([0.5, 1. , 2. ])
```

Tipp 15: Nützliche Funktionen

Pandas bietet einige praktische Funktionen, um eine eingelesene Datei zu kontrollieren. Machen Sie sich die Verwendung von `pd.dtypes` oder `pd.DataFrame.info()` zur Angelegenheit.

3.5.3 Aufgabe Datentypen

Das britische Energieministerium veröffentlicht Daten zu den Industriestrompreisen in den Mitgliedsändern der Internationalen Energieagentur.

Lesen Sie Tabellenblatt “5.3.1 (excl. taxes)” aus der Excel-Datei ‘skript/01-daten/table_531.xlsx’ mit Pandas ein. Schauen Sie in der Dokumentation der Funktion `pd.read_excel` nach, wie Sie das korrekte Tabellenblatt auswählen können. Stellen Sie sicher, dass alle Spalten mit einem numerischen Datentyp eingelesen werden.

Department for Energy Security & Net Zero. 2024. Energy Prices International Comparisons. Industrial electricity prices in the IEA. https://www.gov.uk/government/uploads/system/uploads/attachment_data/file/670121/table_531.xls

Tipp 16: Musterlösung 5.3.1 (excl. taxes)

Überspringen der führenden Zeilen mit dem Argument `header = 8`. Auswahl des Tabellenblatts mit `sheet_name = "5.3.1 (excl. taxes)"` und Kontrolle der erkannten Datentypen mit `taxes.dtypes`

```
dateipfad = '01-daten/table_531.xlsx'

taxes = pd.read_excel(io = dateipfad, sheet_name = "5.3.1 (excl. taxes)", \
    header = 8)

taxes.dtypes
```

Year	int64
Austria	float64

Belgium	float64
Denmark	float64
Finland	float64
France	float64
Germany	float64
Greece	float64
Ireland	float64
Italy	float64
Luxembourg	float64
Netherlands	float64
Portugal	float64
Spain	float64
Sweden	float64
United Kingdom	float64
Australia	float64
Canada	float64
Czech Republic	float64
Hungary	float64
Japan	float64
Korea	float64
New Zealand	float64
Norway	float64
Poland	float64
Slovakia	float64
Switzerland	float64
Republic of Türkiye	object
USA	float64
IEA median	float64
UK relative to IEA median%	float64
UK relative to IEA rank	int64
UK relative to G7 rank	int64
dtype: object	

Werte in Spalte 'Republic of Türkiye' mit `pd.unique()` ansehen.

```
taxes['Republic of Türkiye'].unique()
```

```
array(['...', 2.0436081749999997, 3.3248584439999993, 3.2947581129644483,
      3.5628243387317866, 3.998334312, 3.838962582401693,
      4.2138469457789975, 3.775503630575527, 3.2804905218375238,
      3.783413840344277, 4.139259596071514, 4.196890742949158,
      4.658509330911754, 5.552842625063031, 4.316920402166109,
```

```
4.1586205264300675, 4.765321921741988, 4.060617948410105,
3.9191433658651307, 4.223710389549368, 4.481407237836746,
4.629981488840797, 5.2657882806931235, 5.109009847145703,
4.585007793872617, 4.769921255774284, 4.419433670846949,
4.428906151745361, 6.171573537217762, 7.192920543071899,
7.962417550086158, 7.035941949054445, 7.622058781522502,
7.644892388451444, 6.47006818181818, 5.968380462724936,
6.379514692256784, 5.537541821623266, 5.248709303933227,
6.9100519994521274, 6.670900808798327, 5.864171132090749,
13.928251887312259, 11.123594768114717], dtype=object)
```

Zeichenkette '.' entfernen und Datentyp mit Methode `pd.astype('float64')` ändern.

- Variante 1: als fehlenden Wert beim Einlesen deklarieren.
- Variante 2: Nach dem Einlesen Indexposition bestimmen und Wert ersetzen. Das verkettete Slicing `df["col"][row_indexer] = value` wird mit der Pandas Version 3.0 nicht mehr unterstützt und gibt deshalb eine Fehlermeldung aus. Künftig ist folgende Syntax zu verwenden: `df.loc[row_indexer, "col"] = value`.

```
# Variante 1: '..' als fehlenden Wert deklarieren
# taxes = pd.read_excel(io = dateipfad, sheet_name = "5.3.1 (excl. taxes)", \
#   header = 8, na_values = ['..'])

# Variante 2: Index des Werts bestimmen und mit np.nan überschreiben
indexposition = taxes['Republic of Türkiye'] == '..'

taxes.loc[indexposition, 'Republic of Türkiye'] = np.nan
taxes['Republic of Türkiye'] = taxes['Republic of Türkiye'].astype('float64')

taxes.dtypes
```

Year	int64
Austria	float64
Belgium	float64
Denmark	float64
Finland	float64
France	float64
Germany	float64
Greece	float64
Ireland	float64
Italy	float64

Luxembourg	float64
Netherlands	float64
Portugal	float64
Spain	float64
Sweden	float64
United Kingdom	float64
Australia	float64
Canada	float64
Czech Republic	float64
Hungary	float64
Japan	float64
Korea	float64
New Zealand	float64
Norway	float64
Poland	float64
Slovakia	float64
Switzerland	float64
Republic of Türkiye	float64
USA	float64
IEA median	float64
UK relative to IEA median%	float64
UK relative to IEA rank	int64
UK relative to G7 rank	int64
dtype:	object

3.6 Umgang mit fehlenden Werten

Eine unerwartet als string oder object eingelesene Spalte weist häufig auf fehlende Werte hin, die durch Sonderzeichen gekennzeichnet sind. Die Module NumPy und Pandas bieten Funktionen, um fehlende Werte bereits beim Einlesen zu erkennen und umzuwandeln.

Hinweis: Maskierte NumPy-Arrays werden in Kapitel 6 behandelt.

3.6.1 NumPy

Die NumPy-Funktion `np.loadtxt()` wird verwendet, um vollständige Datensätze einzulesen. Fehlende Werte im Datensatz können problematisch sein, da diese entweder zu Fehlermeldungen bezüglich des Datentyps führen oder übersprungen werden, sodass das NumPy-Array kürzer als der eingelesene Datensatz ist. Da NumPy-Arrays immer nur einen Datentyp und eine feste

Länge haben, kann das bei der Durchführung von Operationen mit mehreren Arrays zu Fehlern führen.

Folgende Datei ist Ihnen aus dem w-NumPy bekannt.

```
dateipfad = '01-daten/TC01.csv'
daten_ohne_fehlende_werte = np.loadtxt(dateipfad)

print("Daten:", daten_ohne_fehlende_werte)
print("Struktur:", daten_ohne_fehlende_werte.shape, "dtype:", daten_ohne_fehlende_werte.dtype)
```

```
Daten: [20.1 20.1 20.1 ... 24.3 24.2 24.2]
Struktur: (1513,) dtype: float64
```

Angenommen, Sie haben eine zweite Messung durchgeführt und möchten die Differenz beider Datensätze berechnen. In der zweiten Messung haben Sensorfehler zu fehlenden Werten geführt, die mit -- markiert sind. Die Funktion `np.loadtxt()` kann jedoch mit fehlenden Werten nicht umgehen und gibt eine Fehlermeldung zurück.

```
dateipfad = '01-daten/TC01_double_hyphen.csv'

try:
    daten_double_hyphen = np.loadtxt(dateipfad)
except ValueError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print("Daten mit fehlenden Werten '--':", daten_double_hyphen, "dtype:", daten_double_hyphen.dtype)
```

```
Die Eingabe führt zu der Fehlermeldung:
could not convert string '--' to float64 at row 1, column 1.
```

Die Funktion `np.genfromtxt()`

Um Datensätze mit fehlenden Werten einzulesen, wird die Funktion `np.genfromtxt(fname, delimiter = None, missing_values = None, filling_values = None)` verwendet. Dieses durchläuft den Datensatz `fname` in zwei Schleifen, weshalb die Funktion langsamer als `np.loadtxt()` ist. Die erste Schleife teilt den Datensatz zeilenweise am optional übergebenen Trennzeichen `delimiter` in eine Zeichenkette auf. Die zweite Schleife konvertiert jede Zeichenkette in den passenden Datentyp. Mit den optionalen Argumenten `missing_values` und `filling_values` können der Funktion Zeichenfolgen übergeben werden, mit der fehlende Werte markiert sind bzw. ersetzt werden sollen. ([NumPy Dokumentation](#))

```

dateipfad = '01-daten/TC01_double_hyphen.csv'
daten_double_hyphen = np.genfromtxt(dateipfad, missing_values = '--', filling_values = np.nan)

print("\nDaten mit fehlenden Werten '--':", daten_double_hyphen)
print("Struktur:", daten_double_hyphen.shape, "dtype:", daten_double_hyphen.dtype)

```

```

Daten mit fehlenden Werten '--': [20.1  nan 20.1 ... 24.3 24.2 24.2]
Struktur: (1513,) dtype: float64

```

Durch die Umwandlung fehlender Werte in `nan`, sind Operationen mit gleichlangen NumPy-Arrays möglich.

```

daten_differenz = daten_ohne_fehlende_werte - daten_double_hyphen
print(daten_differenz)

```

```
[ 0. nan  0. ...  0.  0.  0.]
```

Die Funktion `np.genfromtxt()` kann beliebige Zeichenketten als fehlenden Wert verarbeiten. Lediglich leere Zellen können problematisch sein, da deren Inhalt `'\n'` als Zeilentrenner verarbeitet wird.

Hinweis 3: Leere Zellen mit `np.genfromtxt()`

Enthält eine Datei leere Zellen, können diese nicht eingelesen werden, da diese automatisch übersprungen werden.

```

# Datei ohne Markierung fehlender Werte
dateipfad = '01-daten/TC01_empty_lines.csv'
daten_empty_lines = np.genfromtxt(dateipfad, missing_values = '', filling_values = np.nan)

print("\nDaten mit fehlenden Werten '':", daten_empty_lines)
print("Struktur:", daten_empty_lines.shape, "dtype:", daten_empty_lines.dtype)

```

```

Daten mit fehlenden Werten '': [20.1 20.1 20.1 ... 24.3 24.2 24.2]
Struktur: (1511,) dtype: float64

```

Das Array ist zwei Elemente kürzer. Die Subtraktion von einem längeren NumPy-Array scheitert mit einer Fehlermeldung.

```

try:
    result = daten_ohne_fehlende_werte - daten_empty_lines
except ValueError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(result)

```

Die Eingabe führt zu der Fehlermeldung:

```
operands could not be broadcast together with shapes (1513,) (1511,)
```

In diesem Fall muss auf die Stringbearbeitung aus der Python-Basis zurückgegriffen werden. Die bearbeitete Liste kann wie gewohnt mit `np.genfromtxt()` eingelesen werden.

```

# Einlesen über Datenobjekt
datenobjekt_empty_lines = open(dateipfad, 'r', encoding = 'utf-8')
daten_empty_lines = datenobjekt_empty_lines.readlines()
datenobjekt_empty_lines.close()

print("Das ausgelesene Datenobjekt (Ausschnitt):\n", daten_empty_lines[0:10])

# Stringbearbeitung mit replace('\n', '')
for i in range(len(daten_empty_lines)):

    if daten_empty_lines[i] == '\n':
        daten_empty_lines[i] = 'platzhalter'
    else:
        daten_empty_lines[i] = daten_empty_lines[i].replace('\n', '')

print("\nNach der Stringbearbeitung (Ausschnitt):\n", daten_empty_lines[0:10])

# Einlesen mit np.genfromtxt
daten_empty_lines = np.genfromtxt(daten_empty_lines, missing_values = 'platzhalter', filling
print("\nDaten mit fehlenden Werten '':", daten_empty_lines)
print("Struktur:", daten_empty_lines.shape, "dtype:", daten_empty_lines.dtype)

```

Das ausgelesene Datenobjekt (Ausschnitt):

```
['# Temperatur in C\n', '20.1\n', '\n', '20.1\n', '20.1\n', '20.1\n', '\n', '20.1\n', '20.1\n', '20.1\n']
```

Nach der Stringbearbeitung (Ausschnitt):

```
['# Temperatur in C', '20.1', 'platzhalter', '20.1', '20.1', '20.1', 'platzhalter', '20.1', '20.1', '20.1']
```

Daten mit fehlenden Werten '': [20.1 nan 20.1 ... 24.3 24.2 24.2]

```
Struktur: (1513,) dtype: float64
```

Besonders bei Dateien mit mehreren Spalten führen leere Zellen schnell zu Fehlern. Hier ist es erforderlich, den Zeichentrenner mit dem Argument `delimiter` zu spezifizieren. Aus der Dokumentation:

“When spaces are used as delimiters, or when no delimiter has been given as input, there should not be any missing data between two fields.” ([NumPy Dokumentation](#))

i Hinweis 3: Leere Zellen in mehreren Spalten mit `np.genfromtxt()`

Ohne Spezifikation des Arguments `delimiter` wird nur eine Spalte eingelesen, die ausschließlich `np.nan` enthält.

```
# ohne Spezifikation von delimiter
dateipfad = '01-daten/TC01_missing_values_multi_column.csv'
daten_empty_lines2 = np.genfromtxt(dateipfad, missing_values = '', filling_values = np.nan)

print("Struktur:", daten_empty_lines2.shape, "dtype:", daten_empty_lines2.dtype)
print("Die ersten drei Zeilen:\n", daten_empty_lines2[0:3])
```

```
Struktur: (1513, 1) dtype: float64
```

Die ersten drei Zeilen:

```
[[nan]
 [nan]
 [nan]]
```

Wird das Argument `delimiter = ','` übergeben, wird die Datei korrekt eingelesen.

```
# mit Spezifikation von delimiter
daten_empty_lines2 = np.genfromtxt(dateipfad, delimiter = ',', missing_values = '', filling

print("Struktur:", daten_empty_lines2.shape, "dtype:", daten_empty_lines2.dtype)
print("\nDaten mit fehlenden Werten '':\n", daten_empty_lines2)
```

```
Struktur: (1513, 2) dtype: float64
```

Daten mit fehlenden Werten '':

```
[[20.1 20.1]
 [ nan  nan]
 [20.1 20.1]
 ...
 [24.3 24.3]
```

```
[24.2 24.2]
[24.2 24.2]]
```

Fehlende Werte in NumPy erzeugen, prüfen, finden, ersetzen, löschen

Das Modul NumPy bietet Funktionen, um mit fehlenden Werten zu arbeiten.

- `np.nan` erzeugt einen fehlenden Wert.
- `np.isnan()` prüft auf einen fehlenden Wert und gibt einen Wahrheitswert bzw. ein NumPy-Array mit dtype bool zurück.
- `np.nonzero(np.isnan(array))` gibt ein Tuple zurück, das ein Array mit den Indexpositionen der Elemente mit dem Wert 'nan' enthält. Auf das Array kann mit `np.nonzero(np.isnan(array))[0]` zugegriffen werden. Je nach Situation kann die Umwandlung in eine Liste nützlich sein `np.nonzero(np.isnan(array))[0].tolist()`. Eine ähnliche Funktion ist `np.argwhere(np.isnan(array))`, deren Ausgabe aber nicht für das Slicing mehrdimensionaler Arrays geeignet ist (siehe folgendes Beispiel).

i Hinweis 4: Die Funktion `np.argwhere()`

Eine andere Funktion, um die Indexposition eines Werts zu bestimmen, ist die Funktion `np.argwhere()`. Der Aufruf der Funktion `np.argwhere(np.isnan(array))` gibt ein NumPy-Array mit den Indexposition Elemente mit dem Wert `nan` zurück.

```
array = np.array([[1, np.nan, np.nan], [4, 5, np.nan]])
print(array)

np.argwhere(np.isnan(array))
```

```
[[ 1. nan nan]
 [ 4.  5. nan]]
```

```
array([[0, 1],
       [0, 2],
       [1, 2]])
```

Das mit `np.argwhere()` erzeugte Array ist aber nicht geeignet, um Arraybereiche auszuwählen.

```
try:
    array[np.argwhere(np.isnan(array))]
except IndexError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(array[np.argwhere(np.isnan(array))])
```

Die Eingabe führt zu der Fehlermeldung:
index 2 is out of bounds for axis 0 with size 2

Zum Vergleich mit `np.nonzero()`

```
try:
    array[np.nonzero(np.isnan(array))]
except IndexError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(array[np.nonzero(np.isnan(array))])
```

[nan nan nan]

Hinweis 3.1: Die Funktion `np.argwhere()`

Die Auswahl von Array-Bereichen mit `np.argwhere()` funktioniert für eindimensionale Arrays.

```
array = np.array([1, np.nan, np.nan, 4, 5])

try:
    array[np.argwhere(np.isnan(array))]
except IndexError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(array[np.argwhere(np.isnan(array))])
```

[[nan]
[nan]]

- `nan_to_num(x = array, nan = 0.0)` ersetzt im Array `x` `nan` durch den Wert 0.0 oder durch den im Argument `nan` übergebenen Wert. (Hinweis: `nan_to_num()` ersetzt standardmäßig auch `np.inf` durch große positive sowie `-np.inf` durch große negative Zahlen.)

Die Ersetzung eines bestimmten Werts ist auch mit einem logischen Vektor möglich (siehe folgendes Beispiel).

i Hinweis 5: Wertzuweisung mit logischem Vektor

Die Ersetzung eines bestimmten Werts ist auch durch die Auswahl bestimmter Array-Bereiche durch einen logischen Vektor möglich.

```
a = np.array([1, 2, 3, np.nan, 5, 6, np.nan])
b = np.isnan(a)
print(b)
a[b] = 0
print(a)
```

```
[False False False  True False False  True]
[1.  2.  3.  0.  5.  6.  0.]
```

Dabei können mehrere Bedingungen mit der Funktion `np.logical_or(x1, x2)` als logisches ODER kombiniert werden.

```
a = np.array([1, 2, 3, np.nan, 5, 6, np.nan])
bedingung1 = np.isnan(a)
bedingung2 = a >= 5
bedingung = np.logical_or(bedingung1, bedingung2)
a[bedingung] = 0
print(a)
```

```
[1.  2.  3.  0.  0.  0.  0.]
```

Auch ein logisches UND ist möglich (aber in Verbindung mit `np.nan` nicht sinnvoll). Der Operator `*` bewirkt das gleiche wie der logische Operator `and` oder die Funktion `np.logical_and(x1, x2)`.

```

a = np.array([1, 2, 3, np.nan, 5, 6, np.nan])

bedingung1 = a < 4

bedingung2 = a >= 1

bedingung = bedingung1 * bedingung2

a[bedingung] = 0

print(a)

[ 0.  0.  0. nan  5.  6. nan]

```

- `np.delete(arr = array, obj)` gibt ein neues (kürzeres) Array ohne die im Parameter `obj` spezifizierten Array-Bereiche zurück. Alle Elemente mit dem Wert `nan` werden so gelöscht: `np.delete(array, obj = np.nonzero(np.isnan(array)))`

NumPy wandelt `None` nicht automatisch in `nan` um. NumPy kann den Datentyp des Objekts deshalb nicht bestimmen und gibt `dtype=object` aus:

```

np_array_with_none = np.array([1, 2, None, 4])
print(np_array_with_none, np_array_with_none.dtype)

```

```
[1 2 None 4] object
```

Aufgabe: Wie kann im Array `np_array_with_none` `None` durch `np.nan` ersetzt werden?

💡 Tipp 17: Lösung

Eine logische Abfrage von `None` ist möglich. Auf diese Weise kann ein logisches Array erzeugt werden, das zur Auswahl der Indexpositionen verwendet wird, deren Werte ersetzt werden sollen.

```

np_array_with_none = np.array([1, 2, None, 4])
print(np_array_with_none)

np_array_with_nan = np_array_with_none.copy()

print(f"\nArray mit logischer Abfrage von None:\n{np_array_with_none == None}")
np_array_with_nan[np_array_with_none == None] = np.nan
print(f"\nArray mit None ersetzt durch nan:\n{np_array_with_nan, np_array_with_nan.dtype}")

[1 2 None 4]

Array mit logischer Abfrage von None:
[False False  True False]

Array mit None ersetzt durch nan:
(array([1, 2, nan, 4], dtype=object), dtype('O'))

```

Operationen mit fehlenden Werten

Operationen mit `nan` ergeben immer `nan`. Deshalb gibt es in NumPy viele Funktionen, die `nan` automatisch ignorieren bzw. durch einen geeigneten Wert ersetzen. Diese sind bereits am Funktionsnamen erkennbar. Beispielsweise liefern `np.nansum()` und `np.nancumsum()` die Summe bzw. die kumulierte Summe eines Arrays. In der kumulierten Summe werden `nan` durch das laufende Ergebnis ersetzt. Eine vollständige Liste der NumPy-Funktionen finden Sie in der [Dokumentation](#).

```

print(f"Array mit nan:\n{np_array_with_nan}\n")

print(f"Summe des Arrays:\n{np.sum(np_array_with_nan)}\n")

print(f"nan-Summe des Arrays:\n{np.nansum(np_array_with_nan)}\n")

print(f"kumulierte Summe des Arrays:\n{np.cumsum(np_array_with_nan)}\n")

print(f"kumulierte nan-Summe des Arrays:\n{np.nancumsum(np_array_with_nan)}\n")

```

```

Array mit nan:
[1 2 nan 4]

```

Summe des Arrays:

nan

nan-Summe des Arrays:

7

kumulierte Summe des Arrays:

[1 3 nan nan]

kumulierte nan-Summe des Arrays:

[1 3 3 7]

3.6.2 Pandas

Die Pandas-Funktionen zum Lesen von Dateien können mit fehlenden Werten umgehen. Standardmäßig werden folgende Werte als fehlende Werte erkannt:

```
['-1.#IND', '1.#QNAN', '1.#IND', '-1.#QNAN', '#N/A N/A', '#N/A', 'N/A',  
'n/a', 'NA', '<NA>', '#NA', 'NULL', 'null', 'NaN', '-NaN', 'nan', '-nan',  
'None', '']
```

Weitere Werte können mit dem Argument `na_values = []` als fehlende Werte definiert werden. Mit dem Argument `keep_default_na = False` kann festgelegt werden, dass ausschließlich die in `na_values = []` übergebenen Werte als fehlende Werte interpretiert werden sollen. Standardmäßig werden mit dem Argument `na_filter = True` auch leere Zellen als NA eingelesen. Vollständig leere Zeilen werden jedoch standardmäßig übersprungen. Dies kann mit dem Argument `skip_blank_lines = False` geändert werden. ([Pandas Dokumentation](#))

```
dateipfad = '01-daten/TC01_double_hyphen.csv'  
  
try:  
    daten_double_hyphen = pd.read_csv(dateipfad, na_values = ['--'])  
except ValueError as error:  
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)  
else:  
    print("Daten mit fehlenden Werten '--':\n", daten_double_hyphen, daten_double_hyphen.shape)
```

Daten mit fehlenden Werten '--':

```
    # Temperatur in C  
0          20.1  
1           NaN  
2          20.1
```

3	20.1
4	20.1
...	...
1508	24.3
1509	24.3
1510	24.3
1511	24.2
1512	24.2

[1513 rows x 1 columns] (1513, 1)

Mit dem Argument `skip_blank_lines = False` werden leere Zeilen ebenfalls eingelesen.

```
dateipfad = '01-daten/TC01_empty_lines.csv'

try:
    daten_empty_lines = pd.read_csv(dateipfad, skip_blank_lines = False)
except ValueError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print("Daten mit fehlenden Werten '':\n", daten_empty_lines, daten_empty_lines.shape)
```

Daten mit fehlenden Werten '':

	# Temperatur in C
0	20.1
1	NaN
2	20.1
3	20.1
4	20.1
...	...
1508	24.3
1509	24.3
1510	24.3
1511	24.2
1512	24.2

[1513 rows x 1 columns] (1513, 1)

Pandas verwendet abhängig vom Datentyp verschiedene Werte zur Kennzeichnung fehlender Werte.

- `numpy.nan` für NumPy-Datentypen. Hierbei wird der Datentyp automatisch in `np.float64` oder `object` konvertiert.
- `pd.NA` für Zeichenketten und Ganzzahlen. Der Datentyp bleibt erhalten.

Einlesen der Datei `TC01_empty_lines.csv` als string:

```
dateipfad = '01-daten/TC01_empty_lines.csv'

try:
    daten_empty_lines = pd.read_csv(dateipfad, skip_blank_lines = False, dtype = 'string')
except ValueError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print("Daten mit fehlenden Werten '':\n", daten_empty_lines, daten_empty_lines.shape)
```

Daten mit fehlenden Werten '':

```
# Temperatur in C
0          20.1
1          <NA>
2          20.1
3          20.1
4          20.1
...         ...
1508       24.3
1509       24.3
1510       24.3
1511       24.2
1512       24.2
```

[1513 rows x 1 columns] (1513, 1)

NA kann zwar auch als fehlender Wert für Gleitkommazahlen und andere NumPy Datentypen verwendet werden. Allerdings wird dafür ein Pandas-Datentyp benötigt (siehe das folgende Beispiel).

i Hinweis 6: `pd.Series` mit `np.nan` und `pd.NA`

Eine `pd.Series` mit `np.nan` wird automatisch in `dtype: float64` umgewandelt:

```
try:
    test = pd.Series([1, 2, np.nan])
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1.0
1    2.0
2    NaN
dtype: float64
```

Eine pd.Series mit pd.NA wird als dtype: object eingelesen:

```
try:
    test = pd.Series([1, 2, pd.NA])
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1
1    2
2  <NA>
dtype: object
```

Der dtype kann für eine Series mit pd.NA festgelegt werden:

```
try:
    test = pd.Series([1, 2, pd.NA], dtype = 'Int32')
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1
1    2
2  <NA>
dtype: Int32
```

Abhängig vom Datentyp kommt es auf den korrekten dtype (NumPy oder Pandas) an, erkennbar an der Groß- und Kleinschreibung. pd.NA mit Numpy-Fließkommazahl:

```
try:
    test = pd.Series([1, 2, pd.NA], dtype = 'float64')
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

Die Eingabe führt zu der Fehlermeldung:
float() argument must be a string or a real number, not 'NAType'

pd.NA mit Pandas-Fließkommazahl:

```
try:
    test = pd.Series([1, 2, pd.NA], dtype = 'Float64')
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1.0
1    2.0
2    <NA>
dtype: Float64
```

np.nan mit Numpy-Fließkommazahl:

```
try:
    test = pd.Series([1, 2, np.nan], dtype = 'float64')
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1.0
1    2.0
2    NaN
dtype: float64
```

np.nan mit Pandas-Fließkommazahl:

```
try:
    test = pd.Series([1, 2, np.nan], dtype = 'Float64')
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    print(test)
```

```
0    1.0
1    2.0
2    <NA>
dtype: Float64
```

⚠ Warning 3: Achtung Logik!

Die logische Abfrage fehlender Werte unterscheidet sich für `None`, `np.nan` und `pd.NA`.

```
bool_values = [None, float('nan'), pd.NA]

for element in bool_values:
    try:
        bool_value = bool(element)
    except TypeError as error:
        print(error)
    else:
        print("Wahrheitswert von", element, "ist", bool_value)
```

Wahrheitswert von None ist False

Wahrheitswert von nan ist True

boolean value of NA is ambiguous

Dies gilt auch für die Wertgleichheit.

```
bool_values = [None, float('nan'), pd.NA]

for element in bool_values:
    try:
        result = element == element
    except TypeError as error:
        print(error)
    else:
        print("Wertgleichheit von", element, "ist", result)
```

Wertgleichheit von None ist True

Wertgleichheit von nan ist False

Wertgleichheit von <NA> ist <NA>

([Pandas Dokumentation](#))

Fehlende Werte in Pandas erzeugen, prüfen, finden, ersetzen, löschen

Das Modul Pandas wandelt `None` automatisch in `nan` um. Das Modul Pandas bietet wie das Modul NumPy verschiedene Funktionen, um mit fehlenden Werten zu arbeiten.

- `pd.NA` erzeugt einen fehlenden Wert (Groß- und Kleinschreibung beachten: `pd.na` funktioniert nicht)
- Die Funktionen `pd.isnull()` und `pd.isna()` prüfen auf einen fehlenden Wert und geben einen Wahrheitswert bzw. ein NumPy-Array mit dtype bool zurück. Die Funktionen `pd.notna()` und `pd.notnull()` prüfen den umgekehrten Fall.
- Die Funktion `np.nonzero(pd.isna())` verwendet die NumPy-Funktion `np.nonzero()` und gibt ein Array mit den Indexpositionen der Elemente mit fehlenden Werten zurück (die Pandas-Funktion `pd.nonzero()` wird nicht mehr unterstützt).
- `pd.Series.fillna(value = 0)` ersetzt fehlende Werte mit dem im Argument `value` übergebenen Wert. Die Methoden `pd.ffill()` und `pd.bfill()` ersetzen fehlende Werte mit dem letzten bzw. dem nächsten gültigen Wert. Die Methode `pd.Series.interpolate()` ersetzt fehlende Werte durch Interpolation, wofür ein Datentyp definiert sein muss (`dtype = object` funktioniert nicht). Standardmäßig wird linear interpoliert, es stehen aber verschiedene Methoden zur Verfügung (siehe [Pandas Dokumentation](#))
- Die Methode `pd.Series.dropna()` gibt eine neue (kürzere) Series ohne fehlende Wert zurück.

Operationen mit fehlenden Werten

Operationen mit `pd.NA` ergeben in der Regel `pd.NA`. Es gibt jedoch einige Ausnahmen:

```
print(pd.NA ** 0)
print(1 ** pd.NA)
```

```
1
1
```

Die Methode `pd.Series.sum()` behandelt `pd.NA` als 0, die Methode `pd.Series.prod()` als 1.

```
print(pd.Series([pd.NA]).sum())
print(pd.Series([pd.NA]).prod())
```

```
0
1
```

Reduzierende Methoden wie `pd.Series.min()` oder `pd.Series.mean()` sowie zusammenfassende Methoden wie `pd.Series.cumsum()` oder `pd.Series.cumprod()` überspringen `pd.NA`.

```
print(pd.Series([pd.NA]).min())
print(pd.Series([pd.NA]).mean())
print(pd.Series([pd.NA]).cumsum())
print(pd.Series([pd.NA]).cumprod())
```

```
nan
nan
0    NaN
dtype: object
0    NaN
dtype: object
```

Das Verhalten von Methoden wie `pd.Series.sum()` und von Methoden wie `pd.Series.min()` hat für Datenreihen einen vergleichbaren Effekt, produziert für einzelne Werte jedoch unterschiedliche Ergebnisse.

3.6.3 Aufgabe fehlende Werte

Der Deutsche Wetterdienst misst deutschlandweit verschiedene Wetterdaten. In der Datei ‘produkt_st_stunde_20230831_20240630_01303.txt’ sind stündliche Stationsmessungen der Solarstrahlung in Essen-Bredeney gespeichert.

Spaltenname	Beschreibung
STATIONS_ID	Stationsnummer
QN_592	Qualitätsniveau der Daten
ATMO_LBERG	Stundensumme der atmosphärischen Gegenstrahlung
FD_LBERG	Stundensumme der diffusen solaren Strahlung
FG_LBERG	Stundensumme der Globalstrahlung
SD_LBERG	Stundensumme der Sonnenscheindauer
ZENIT	Zenitwinkel der Sonne 0 - 180 Grad

Deutscher Wetterdienst. 2024. Stündliche Stationsmessung der Solarstrahlung (global/diffus) und der atmosphärischen Gegenstrahlung für Deutschland. https://opendata.dwd.de/climate_environment/CDC/observations_germany/climate/hourly/solar/stundenwerte_ST_01303_row.zip Die Spalten MESS_DATUM, MESS_DATUM_WOZ und eor wurden entfernt.

Bestimmen Sie die Kodierung fehlender Werte und ersetzen Sie diese durch `np.nan` bzw. `pd.NA`. Wie viele Werte wurden ersetzt?

 Tipp 18: Musterlösung fehlende Werte

Mit der Methode `df.info()` ist erkennbar, dass der Datensatz vollständig ist.

```
dateipfad = "01-daten/produkt_st_stunde_20230831_20240630_01303.txt"
solar = pd.read_csv(dateipfad, sep = ";")
```

```
solar.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7296 entries, 0 to 7295
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype
---  -
0   STATIONS_ID     7296 non-null   int64
1   QN_592          7296 non-null   int64
2   ATMO_LBERG      7296 non-null   float64
3   FD_LBERG        7296 non-null   float64
4   FG_LBERG        7296 non-null   float64
5   SD_LBERG        7296 non-null   int64
6   ZENIT           7296 non-null   float64
dtypes: float64(4), int64(3)
memory usage: 399.1 KB
```

Mit der Methode `df.describe()` wird die deskriptive Statistik für numerische Spalten erstellt.

```
solar.describe()
```

	STATIONS_ID	QN_592	ATMO_LBERG	FD_LBERG	FG_LBERG	SD_LBERG	ZENIT
count	7296.0	7296.0	7296.00	7296.00	7296.00	7296.00	7296.00
mean	1303.0	1.0	111.80	-31.23	-16.46	9.00	92.65
std	0.0	0.0	89.42	222.34	229.74	18.66	30.02
min	1303.0	1.0	-999.00	-999.00	-999.00	0.00	28.56
25%	1303.0	1.0	112.00	0.00	0.00	0.00	70.61
50%	1303.0	1.0	121.00	0.00	0.00	0.00	92.40
75%	1303.0	1.0	127.25	25.00	33.00	3.00	115.9
max	1303.0	1.0	150.00	182.00	348.00	60.00	151.4

Drei Spalten weisen als minimalen Wert -999 auf, der inhaltlich nicht sinnvoll ist. Wie oft kommt der Wert -999 in den Spalten vor?

```
counting_df = solar[['ATMO_LBERG', 'FD_LBERG', 'FG_LBERG']] == -999
print(counting_df.sum())
print("Summe:\t\t", counting_df.sum().sum())
```

```
ATMO_LBERG      46
FD_LBERG       359
FG_LBERG       353
dtype: int64
Summe:         758
```

4 Zeitreihen

4.1 Datum und Zeit in NumPy und Pandas

Die Module NumPy und Pandas nutzen den Datentyp `datetime64`, um Datums- und Zeitinformationen zu verarbeiten.

4.2 NumPy

`datetime64`-Objekte werden mit der Funktion `np.datetime64()` angelegt, der Datentyp wird in der Ausgabe von Python auch durch den Buchstaben `M` repräsentiert. `datetime64`-Objekte können auf zwei Arten angelegt werden:

- Eine Zeichenkette nach [ISO 8601](#) als Repräsentation eines Datums in der festgelegten Reihenfolge Jahr, Monat, Tag, Stunde, Minute, Sekunde, Millisekunde im Format `YYYY-MM-DD 12:00:00.000`. Als Zeichentrenner zwischen Datum und Uhrzeit sind ein Leerzeichen oder der Buchstabe `T` zulässig. Der Datentyp und die kleinste verwendete Einheit werden im Attribut `dtype` gespeichert.

```
print(np.datetime64('2024'), np.datetime64('2024').dtype)
print(np.datetime64('2024-10-31'), np.datetime64('2024-10-31').dtype)
print(np.datetime64('2024-10-31T12:24:59.999'), np.datetime64('2024-10-31T12:24:59.999').dtype)
```

```
2024 datetime64[Y]
2024-10-31 datetime64[D]
2024-10-31T12:24:59.999 datetime64[ms]
```

- Als Zahl relativ zur Epoche und unter Angabe einer Zeiteinheit. Die verfügbaren Zeiteinheiten sind `years` ('Y'), `months` ('M'), `weeks` ('W'), `days` ('D') sowie `hours` ('h'), `minutes` ('m'), `seconds` ('s'), `milliseconds` ('ms') und weitere sekundenbasierte Einheiten bis zur Attosekunde (siehe [NumPy Dokumentation](#)).

```
print(np.datetime64(10 * 1000, 'D'), np.datetime64(10 * 1000, 'D').dtype)
print(np.datetime64(1000 * 1000, 'h'), np.datetime64(1000 * 1000, 'h').dtype)
print(np.datetime64(1000 * 1000 * 1000, 's'), np.datetime64(1000 * 1000 * 1000, 's').dtype)
```

```
1997-05-19 datetime64[D]
2084-01-29T16 datetime64[h]
2001-09-09T01:46:40 datetime64[s]
```

Außerdem können Datetime-Formate anderer Module in `np.datetime64()` umgewandelt werden.

Beim Anlegen eines Arrays, kann die Zeiteinheit gewählt werden.

```
my_array = np.array(['2007-07-13', '2006-01-13', '2010-08-13'], dtype = 'datetime64[s]')
print(my_array, my_array.dtype)
```

```
['2007-07-13T00:00:00' '2006-01-13T00:00:00' '2010-08-13T00:00:00'] datetime64[s]
```

Der Datentyp `datetime64` ist mit den meisten NumPy-Funktionen kompatibel.

```
np.arange('2005-02', '2005-03', dtype = 'datetime64[D]')
```

```
array(['2005-02-01', '2005-02-02', '2005-02-03', '2005-02-04',
      '2005-02-05', '2005-02-06', '2005-02-07', '2005-02-08',
      '2005-02-09', '2005-02-10', '2005-02-11', '2005-02-12',
      '2005-02-13', '2005-02-14', '2005-02-15', '2005-02-16',
      '2005-02-17', '2005-02-18', '2005-02-19', '2005-02-20',
      '2005-02-21', '2005-02-22', '2005-02-23', '2005-02-24',
      '2005-02-25', '2005-02-26', '2005-02-27', '2005-02-28'],
      dtype='datetime64[D]')
```

([NumPy Dokumentation](#))

4.3 Pandas

In Pandas werden `datetime64`-Objekte mit den Funktionen `pd.to_datetime()` oder `pd.date_range()` angelegt.

Hinweis: Eine weitere Möglichkeit ist die Funktion `pd.Timestamp()`, die umfangreichere Möglichkeiten zur Erzeugung eines Zeitpunkts bietet, aber kein string-parsing unterstützt.

`pd.to_datetime()` erzeugt Werte des Datentyps `datetime64[ns]` (mit `pd.to_datetime()` erzeugte Skalare (Einzelwerte) werden als `Timestamp` (Zeitpunkt) ausgegeben, die kein Attribut `dtype` haben). Die Funktion `pd.to_datetime()` akzeptiert als Eingabewerte:

- datetime-Objekte anderer Module.
- Zahlen und eine Zeiteinheit `pd.to_datetime(1, unit = None)` (Standard sind Nanosekunden). Das Argument `unit` nimmt die Werte `'ns'`, `'ms'`, `'s'`, `'m'`, `'h'`, `'D'`, `'W'`, `'M'`, `'Y'` für Nanosekunde, Millisekunde, Sekunde, Minute, Stunde, Tag, Woche, Monat bzw. Jahr entgegen. Erzeugt wird ein Zeitpunkt relativ zur Epoche.

```
print(pd.to_datetime(1000, unit = 'D'))
print(pd.to_datetime(1000 * 1000, unit = 'h'))
print(pd.to_datetime(1000 * 1000 * 1000, unit = 's'))
```

```
1972-09-27 00:00:00
2084-01-29 16:00:00
2001-09-09 01:46:40
```

- Zeichenketten, die ein Datum oder ein Datum mit Uhrzeit ausdrücken, formatiert nach [ISO 8601](#).

```
print(pd.to_datetime('2017'))
print(pd.to_datetime('2017-01-01T00'))
print(pd.to_datetime('2017-01-01 00:00:00'))
```

```
2017-01-01 00:00:00
2017-01-01 00:00:00
2017-01-01 00:00:00
```

- Anders formatierte Zeichenketten mit dem Argument `format = "%d/%m/%Y"` (siehe [Dokumentation strftime zur string-Formatierung](#)).

```
print(pd.to_datetime('Monday, 12. August `24', format = "%A, %d. %B `%y"))
print(pd.to_datetime('Monday, 12. August 2024, 12:15 Uhr CET', format = "%A, %d. %B %Y, %H:%M"))
```

```
2024-08-12 00:00:00
2024-08-12 12:15:00+02:00
```

- Dictionary oder DataFrame.

```
print(pd.to_datetime({'year':[2020, 2024], 'month': [1, 11], 'day': [1, 21]}), "\n")
print(pd.to_datetime(pd.DataFrame({'year':[2020, 2024], 'month': [1, 11], 'day': [1, 21]})))
```

```
0    2020-01-01
1    2024-11-21
dtype: datetime64[ns]
```

```
0    2020-01-01
1    2024-11-21
dtype: datetime64[ns]
```

Die Funktion `pd.date_range()` erzeugt ein Array vom Typ `DatetimeIndex` mit dtype `datetime64`. Genau drei der folgenden vier Argumente sind für die Erzeugung erforderlich:

- `start`: Beginn der Reihe.
- `end`: Ende der Reihe (inklusive)
- `freq`: Schrittweite (bspw. Jahr, Tag, Geschäftstag, Stunde oder Vielfache wie '6h' - siehe [Liste verfügbarer strings](#))
- `periods`: Anzahl der zu erzeugenden Werte.

```
print(pd.date_range(start = '2017', end = '2024', periods = 3), "\n")
print(pd.date_range(start = '2017', end = '2024', freq = 'Y'), "\n")
print(pd.date_range(end = '2024', freq = 'h', periods = 3))
```

```
DatetimeIndex(['2017-01-01', '2020-07-02', '2024-01-01'], dtype='datetime64[ns]', freq=None)
```

```
DatetimeIndex(['2017-12-31', '2018-12-31', '2019-12-31', '2020-12-31',
               '2021-12-31', '2022-12-31', '2023-12-31'],
              dtype='datetime64[ns]', freq='YE-DEC')
```

```
DatetimeIndex(['2023-12-31 22:00:00', '2023-12-31 23:00:00',
               '2024-01-01 00:00:00'],
              dtype='datetime64[ns]', freq='h')
```

Hinweis: Die Funktion `pd.date_range()` wird künftig das Kürzel 'Y' nicht mehr unterstützen. Stattdessen können die Kürzel 'YS' (Jahresbeginn) oder 'YE' (Jahresende) verwendet werden. Ebenso wird das Kürzel 'M' künftig durch 'MS' (Monatsstart), 'ME' (Monatsende) ersetzt.

Zeitdifferenzen werden über einen eigenen Datentyp dargestellt (siehe folgendes Beispiel).

4.4 NumPy

Zeitdifferenzen werden mit dem Datentyp `timedelta64` abgebildet. Dieser wird wie `datetime64` durch Angabe einer Ganzzahl und einer Zeiteinheit angelegt.

```
np.timedelta64(1, 'D')
```

```
np.timedelta64(1, 'D')
```

Objekte der Typen `datetime64` und `timedelta64` ermöglichen es, Operationen mit Datum und Zeit durchzuführen (weitere Beispiele in der [NumPy-Dokumentation](#)).

```
print(np.datetime64('today') - np.datetime64('2000-01-01', 'D'))
print(np.datetime64('now') - np.datetime64('2000-01-01', 'h'))
```

```
print("\n\nEine einfache Zeitverschiebung:", np.datetime64('now') - np.timedelta64(1, 'h'))
print("Wie viele Tage hat die Woche?", np.timedelta64(1, 'W') / np.timedelta64(1, 'D'))
```

```
9517 days
822323922 seconds
```

```
Eine einfache Zeitverschiebung: 2026-01-21T14:18:42
Wie viele Tage hat die Woche? 7.0
```

4.5 Pandas

Zeitdifferenzen können zum einen wie in NumPy durch Angabe einer Ganzzahl und einer Zeiteinheit angelegt werden. Außerdem ist die Übergabe mit Argumenten möglich (zulässige Argumente sind: `weeks`, `days`, `hours`, `minutes`, `seconds`, `milliseconds`, `microseconds`, `nanoseconds`).

```
pd.Timedelta(1, 'D')
pd.Timedelta(days = 1, hours = 1)
```

```
Timedelta('1 days 01:00:00')
```

Wichtig: Anders als in NumPy werden Zeitdifferenzen in Monaten und Jahren nicht mehr von Pandas unterstützt.

```
try:
    print( pd.Timedelta(1, 'Y'))
except ValueError as error:
    print(error)
else:
    print( pd.Timedelta(1, 'Y'))
```

Units 'M', 'Y', and 'y' are no longer supported, as they do not represent unambiguous time

Zum anderen können Zeitdifferenzen mit einer Zeichenkette erzeugt werden.

```
print(pd.Timedelta('10sec'))
print(pd.Timedelta('10min'))
print(pd.Timedelta('10hours'))
print(pd.Timedelta('10days'))
print(pd.Timedelta('10w'))
```

```
0 days 00:00:10
0 days 00:10:00
0 days 10:00:00
10 days 00:00:00
70 days 00:00:00
```

Mit Hilfe einer Zeitdifferenz können Zeitreihen leicht verschoben werden.

```
pd.date_range(start = '2024-01-01T00:00', end = '2024-01-01T02:00', freq = '15min') + pd.T
```

```
DatetimeIndex(['2024-01-01 00:30:00', '2024-01-01 00:45:00',
                '2024-01-01 01:00:00', '2024-01-01 01:15:00',
                '2024-01-01 01:30:00', '2024-01-01 01:45:00',
                '2024-01-01 02:00:00', '2024-01-01 02:15:00',
                '2024-01-01 02:30:00'],
              dtype='datetime64[ns]', freq='15min')
```

Wie alt sind Sie in Tagen? Wie alt in Sekunden? Rechnen Sie mit NumPy oder Pandas.

Tipp 4.2: Tipp Pandas und Musterlösung Alter

Für eine elegante Lösung in Pandas schauen Sie sich die verfügbaren Methoden und Attribute von Timedelta-Objekten an.

```
dir(pd.Timedelta(0))
```

Tipp 4.1: Musterlösung

Ersetzen Sie in der Lösung die Zeichenkette 'YYYY-MM-DD' bzw., wenn Sie die Uhrzeit Ihrer Geburt kennen, die Zeichenkette 'YYYY-MM-DDTHH:MM' durch ihren Geburtstag.

NumPy

In NumPy können die Schlüsselwörter `np.datetime64('today')` und `np.datetime64('now')` verwendet werden. Die Ausgabe ist in Tagen bzw. in Sekunden aufgelöst.

```
print(np.datetime64('today') - np.datetime64('YYYY-MM-DD', 'D'))
print(np.datetime64('now') - np.datetime64('YYYY-MM-DDTHH:MM', 's'))
```

Pandas

In Pandas werden die Schlüsselwörter `pd.to_datetime('today')` und `pd.to_datetime('now')` in Nanosekunden aufgelöst.

```
(pd.to_datetime('today') - pd.to_datetime('YYYY-MM-DD')).days
(pd.to_datetime('now') - pd.to_datetime('YYYY-MM-DDTHH:MM')).total_seconds()
```

4.6 Zeitreihen einlesen

Insbesondere das Modul Pandas bietet effiziente Möglichkeiten, um Datumsformate korrekt einzulesen. Im Folgenden wird das Einlesen von Zeitreihen mit NumPy und Pandas anhand von Strommarktdaten demonstriert. In Kapitel ?? stehen verschiedene Übungsaufgaben zur Verfügung.


Die Bundesnetzagentur veröffentlicht verschiedene Strommarktdaten, darunter die Großhandelspreise. Die Strommarktdaten der Bundesnetzagentur müssen manuell auf <https://www.smard.de/> heruntergeladen werden. In diesem Skript werden Daten für das Jahr 2023 benutzt.

Daten	Dateiname
Großhandelspreise 2023	Gro_handel- spreise_202301010000_202401010000_Stunde.csv

Daten	Dateiname
Großhandelspreise 2023 (Englisch)	Day-ahead_prices_202301010000_202401010000_Hour.csv

⚠ Warning 4: SMARD Daten herunterladen

Beim der Auswahl des Zeitraums auf Akzept-Daten in Originalauflösung auswählen und auf Download klicken.



(a)

Das Datumsformat der Dateien ist abhängig von der auf der Internetseite eingestellten Sprache (Deutsch/English).

4.6.1 NumPy

Der Versuch, die Datei mit `np.loadtxt()` einzulesen, führt zu verschiedenen Fehlermeldungen (Datentyp ist nicht numerisch, Spaltenzahl kann nicht ermittelt werden). Diesen wird durch Spezifizierung des Datentyps `dtype = str` und der Beschränkung auf die erste Zeile `max_rows = 1` begegnet.

```
dateipfad = "01-daten/Gro_handelspreise_202301010000_202401010000_Stunde.csv"
preise = np.loadtxt(fname = dateipfad, dtype = 'str', max_rows = 1)
preise
```

```
array(['\ufffdDatum', 'von;Datum', 'bis;Deutschland/Luxemburg', ' [€/MWh] ',
      'Originalauflösungen; ', 'Anrainer', 'DE/LU', ' [€/MWh] ',
      'Originalauflösungen;Belgien', ' [€/MWh] ',
      'Originalauflösungen;Dänemark', '1', ' [€/MWh] ',
      'Originalauflösungen;Dänemark', '2', ' [€/MWh] ',
      'Originalauflösungen;Frankreich', ' [€/MWh] ',
```

```

'Originalauflösungen;Niederlande', ' [€/MWh] ',
'Originalauflösungen;Norwegen', '2', ' [€/MWh] ',
'Originalauflösungen;Österreich', ' [€/MWh] ',
'Originalauflösungen;Polen', ' [€/MWh] ',
'Originalauflösungen;Schweden', '4', ' [€/MWh] ',
'Originalauflösungen;Schweiz', ' [€/MWh] ',
'Originalauflösungen;Tschechien', ' [€/MWh] ',
'Originalauflösungen;DE/AT/LU', ' [€/MWh] ',
'Originalauflösungen;Italien', '(Nord)', ' [€/MWh] ',
'Originalauflösungen;Slowenien', ' [€/MWh] ',
'Originalauflösungen;Ungarn', ' [€/MWh] ', 'Originalauflösungen'],
dtype='<U31')

```

Auf diese Weise kann die erste Zeile eingelesen und das Semikolon als Zeichentrenner identifiziert werden. Außerdem sind Fehler mit der Zeichenkodierung auffällig. Deshalb werden der Zeichentrenner mit `delimiter = ';'` und die Kodierung der Datei mit `encoding = 'UTF-8'` übergeben.

```

dateipfad = "01-daten/Gro_handelspreise_202301010000_202401010000_Stunde.csv"
preise = np.loadtxt(fname = dateipfad, dtype = 'str', max_rows = 1, delimiter = ';', encoding = 'UTF-8')
preise

```

```

array(['\ufffdDatum von', 'Datum bis',
'Deutschland/Luxemburg [€/MWh] Originalauflösungen',
' Anrainer DE/LU [€/MWh] Originalauflösungen',
'Belgien [€/MWh] Originalauflösungen',
'Dänemark 1 [€/MWh] Originalauflösungen',
'Dänemark 2 [€/MWh] Originalauflösungen',
'Frankreich [€/MWh] Originalauflösungen',
'Niederlande [€/MWh] Originalauflösungen',
'Norwegen 2 [€/MWh] Originalauflösungen',
'Österreich [€/MWh] Originalauflösungen',
'Polen [€/MWh] Originalauflösungen',
'Schweden 4 [€/MWh] Originalauflösungen',
'Schweiz [€/MWh] Originalauflösungen',
'Tschechien [€/MWh] Originalauflösungen',
'DE/AT/LU [€/MWh] Originalauflösungen',
'Italien (Nord) [€/MWh] Originalauflösungen',
'Slowenien [€/MWh] Originalauflösungen',
'Ungarn [€/MWh] Originalauflösungen'], dtype='<U49')

```

Es verbleibt die Zeichenkette “\uffeff” am Beginn des Arrays. Diese kennzeichnet die [Byte-Reihenfolge](#) der Datei. Diese kann mit der Übergabe der Kodierung `encoding = 'UTF-8-sig'` übersprungen werden ([Mark Tolonen auf stackoverflow.com](#), [Python Dokumentation](#)). Auf diese Weise wird die erste Zeile korrekt eingelesen, sodass die Anzahl der einzulesenden Zeilen mit `max_rows = 2` erweitert werden kann, um die Datentypen zu identifizieren.

```
preise = np.loadtxt(fname = dateipfad, dtype = 'str', max_rows = 2, delimiter = ';', encoding = 'UTF-8-sig')
preise
```

```
array([[ 'Datum von', 'Datum bis',
        'Deutschland/Luxemburg [€/MWh] Originalauflösungen',
        ' Anrainer DE/LU [€/MWh] Originalauflösungen',
        'Belgien [€/MWh] Originalauflösungen',
        'Dänemark 1 [€/MWh] Originalauflösungen',
        'Dänemark 2 [€/MWh] Originalauflösungen',
        'Frankreich [€/MWh] Originalauflösungen',
        'Niederlande [€/MWh] Originalauflösungen',
        'Norwegen 2 [€/MWh] Originalauflösungen',
        'Österreich [€/MWh] Originalauflösungen',
        'Polen [€/MWh] Originalauflösungen',
        'Schweden 4 [€/MWh] Originalauflösungen',
        'Schweiz [€/MWh] Originalauflösungen',
        'Tschechien [€/MWh] Originalauflösungen',
        'DE/AT/LU [€/MWh] Originalauflösungen',
        'Italien (Nord) [€/MWh] Originalauflösungen',
        'Slowenien [€/MWh] Originalauflösungen',
        'Ungarn [€/MWh] Originalauflösungen'],
      ['01.01.2023 00:00', '01.01.2023 01:00', '-5,17', '13,85',
        '-4,39', '2,01', '2,01', '0,00', '-3,61', '119,32', '12,06',
        '18,09', '2,01', '0,03', '4,84', '-', '195,90', '13,31', '19,76']],
      dtype='<U49')
```

Die ersten beiden Spalten enthalten Datums- und Zeitinformationen, die folgenden numerische Werte, wobei eine Spalte mit ‘-’ kodierte fehlende Werte enthält. Als Dezimaltrennzeichen wird das Komma verwendet. Da NumPy-Arrays immer nur einen Datentyp enthalten können, muss der Datensatz entsprechend aufgeteilt werden. Für die viertletzte Spalte ist zu prüfen, ob diese ausschließlich fehlende Werte enthält.

Zunächst wird der Datensatz vollständig als string eingelesen, die Spaltenbeschriftungen werden mit `skiprows = 1` übersprungen.

```
preise = np.loadtxt(fname = dateipfad, dtype = 'str', delimiter = ';', encoding = 'UTF-8-sig')
```

Anschließend werden im ersten Schritt die Datumsspalten isoliert. NumPy unterstützt keine String-Formatierung, die Zeitstempel müssen deshalb manuell von '01.01.2023 00:00' in die Formatierung nach ISO 8601 'YYYY-MM-DDThh:mm' konvertiert werden.

```
# Datumsspalten isolieren
preise_date = preise[ : , 0:2]

# Zeichenkette manuell ins Format ISO 8601 bringen
## Spalte 0
### neues Array anlegen
preise_datumvon = np.array([], dtype = 'datetime64')

for element in preise_date[ : , 0]:

    # string umstellen
    neues_element = element[6:10] + '-' + \
    element[3:5] + '-' + \
    element[0:2] + 'T' + \
    element[11:13] + ':' + \
    element[14:]

    # in datetime64 konvertieren
    neues_element = np.datetime64(neues_element)

    # anhängen
    preise_datumvon = np.append(preise_datumvon, neues_element)

## Spalte 1
### neues Array anlegen
preise_datumbis = np.array([], dtype = 'datetime64')

for element in preise_date[ : , 1]:

    # string umstellen
    neues_element = element[6:10] + '-' + \
    element[3:5] + '-' + \
    element[0:2] + 'T' + \
    element[11:13] + ':' + \
    element[14:]
```

```
# in datetime64 konvertieren
neues_element = np.datetime64(neues_element)

# anhängen
preise_datumbis = np.append(preise_datumbis, neues_element)

# die letzten 4 Elemente angucken
print(preise_datumvon[-4:], preise_datumvon.dtype)
print(preise_datumbis[-4:], preise_datumbis.dtype)
```

```
['2023-12-31T20:00' '2023-12-31T21:00' '2023-12-31T22:00'
 '2023-12-31T23:00'] datetime64[m]
['2023-12-31T21:00' '2023-12-31T22:00' '2023-12-31T23:00'
 '2024-01-01T00:00'] datetime64[m]
```

Im zweiten Schritt wird geprüft, ob die viertletzte Spalte ausschließlich fehlende Werte enthält. Die Position der Spalte ist zwar bekannt, wird aber dennoch mit der Funktion `np.argwhere()` ermittelt. Mit der Funktion `len(np.unique())` werden die einzigartigen Werte abgezählt.

```
# numerische Spalten isolieren
preise_numeric = preise[ : , 2:]

# Position der Spalte mit fehlendem Wert '-' in der nullten Zeile finden
position = np.argwhere(preise_numeric[0, : ] == '-')
print("Spaltenindex:", position)

# prüfen, welche Werte in der Spalte vorkommen
print("Anzahl einzigartiger Werte:", len(np.unique(preise_numeric[:, position])))
```

```
Spaltenindex: [[13]]
Anzahl einzigartiger Werte: 1
```

Da die viertletzte Spalte ausschließlich das Zeichen '-' enthält, kann die Spalte entfernt werden. Anschließend kann der Datentyp als Fließkommazahl deklariert werden. Dazu ist es erforderlich, mit `np.char.replace(preise_numeric, ',', '.')` das Dezimaltrennzeichen Komma durch den Punkt zu ersetzen. Die Spaltennamen müssen separat gespeichert werden.

```
# Spalte mit fehlenden Werten entfernen
preise_numeric = np.delete(arr = preise_numeric, obj = position, axis = 1) # axis 1 = columns
```

```
# Dezimaltrennzeichen ersetzen
preise_numeric = np.char.replace(preise_numeric, ',', '.')
preise_numeric = preise_numeric.astype('float64')

# Spaltennamen speichern
preise_numeric_colnames = np.loadtxt(fname = dateipfad, dtype = 'str', delimiter = ';', encoding = 'utf-8')
preise_numeric_colnames = preise_numeric_colnames[2:] # Datumsspalten entfernen
preise_numeric_colnames = np.delete(arr = preise_numeric_colnames, obj = position)

print(preise_numeric_colnames, "\n")
print(preise_numeric[0:2, :], preise_numeric.dtype)
```

```
['Deutschland/Luxemburg [€/MWh] Originalauflösungen'
 ' Anrainer DE/LU [€/MWh] Originalauflösungen'
 'Belgien [€/MWh] Originalauflösungen'
 'Dänemark 1 [€/MWh] Originalauflösungen'
 'Dänemark 2 [€/MWh] Originalauflösungen'
 'Frankreich [€/MWh] Originalauflösungen'
 'Niederlande [€/MWh] Originalauflösungen'
 'Norwegen 2 [€/MWh] Originalauflösungen'
 'Österreich [€/MWh] Originalauflösungen'
 'Polen [€/MWh] Originalauflösungen'
 'Schweden 4 [€/MWh] Originalauflösungen'
 'Schweiz [€/MWh] Originalauflösungen'
 'Tschechien [€/MWh] Originalauflösungen'
 'Italien (Nord) [€/MWh] Originalauflösungen'
 'Slowenien [€/MWh] Originalauflösungen'
 'Ungarn [€/MWh] Originalauflösungen']
```

```
[[-5.1700e+00  1.3850e+01 -4.3900e+00  2.0100e+00  2.0100e+00  0.0000e+00
 -3.6100e+00  1.1932e+02  1.2060e+01  1.8090e+01  2.0100e+00  3.0000e-02
  4.8400e+00  1.9590e+02  1.3310e+01  1.9760e+01]
 [-1.0700e+00  9.7900e+00 -1.7500e+00  1.3800e+00  1.3800e+00 -1.0000e-01
 -1.4600e+00  1.0883e+02 -1.0000e-01  5.7500e+00  1.3800e+00 -7.2500e+00
 -3.5000e-01  1.9109e+02 -7.0000e-02  1.9000e-01]] float64
```

4.6.2 Pandas

Zunächst wird die Datei der Großhandelspreise mit der Funktion `pd.read_csv()` eingelesen und der Erfolg durch Aufruf der Funktionen `pd.info()` kontrolliert.

```
dateipfad = "01-daten/Gro_handelspreise_202301010000_202401010000_Stunde.csv"
preise = pd.read_csv(filepath_or_buffer = dateipfad)
print(preise.info())
```

```
<class 'pandas.core.frame.DataFrame'>
MultiIndex: 8760 entries, ('01.01.2023 00:00;01.01.2023 01:00;-5', '17;13', '85;-
4', '39;2', '01;2', '01;0', '00;-3', '61;119', '32;12', '06;18', '09;2', '01;0', '03;4', '84
;195', '90;13', '31;19') to ('31.12.2023 23:00;01.01.2024 00:00;2', '44;19', '26;3', '17;26'
;106', '12;11', '02;14')
Data columns (total 1 columns):
#    Column
Null Count  Dtype
---  -
0    Datum von;Datum bis;Deutschland/Luxemburg [€/MWh] Originalauflösungen; Anrainer DE/LU [
null      int64
dtypes: int64(1)
memory usage: 4.3+ MB
None
```

Es wird nur eine Spalte erkannt, da im Datensatz das Semikolon als Zeichentrenner verwendet wird, das nun mit dem Argument `sep = ';'` übergeben wird (Standardwert ist das Komma). Durch Aufruf der Funktionen `pd.info()` und `pd.head()` wird der Erfolg kontrolliert.

```
dateipfad = "01-daten/Gro_handelspreise_202301010000_202401010000_Stunde.csv"
preise = pd.read_csv(filepath_or_buffer = dateipfad, sep = ';')
print(preise.info())
preise.head()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 19 columns):
#    Column                                                                 Non-Null Count  Dtype
---  -
0    Datum von                                                                8760 non-null   object
1    Datum bis                                                                8760 non-null   object
2    Deutschland/Luxemburg [€/MWh] Originalauflösungen                    8760 non-null   object
3    Anrainer DE/LU [€/MWh] Originalauflösungen                          8760 non-null   object
4    Belgien [€/MWh] Originalauflösungen                                   8760 non-null   object
5    Dänemark 1 [€/MWh] Originalauflösungen                               8760 non-null   object
6    Dänemark 2 [€/MWh] Originalauflösungen                               8760 non-null   object
7    Frankreich [€/MWh] Originalauflösungen                              8760 non-null   object
```

```

8  Niederlande [€/MWh] Originalauflösungen      8760 non-null  object
9  Norwegen 2 [€/MWh] Originalauflösungen      8760 non-null  object
10 Österreich [€/MWh] Originalauflösungen      8760 non-null  object
11 Polen [€/MWh] Originalauflösungen           8760 non-null  object
12 Schweden 4 [€/MWh] Originalauflösungen      8760 non-null  object
13 Schweiz [€/MWh] Originalauflösungen         8760 non-null  object
14 Tschechien [€/MWh] Originalauflösungen      8760 non-null  object
15 DE/AT/LU [€/MWh] Originalauflösungen        8760 non-null  object
16 Italien (Nord) [€/MWh] Originalauflösungen  8760 non-null  object
17 Slowenien [€/MWh] Originalauflösungen       8760 non-null  object
18 Ungarn [€/MWh] Originalauflösungen          8760 non-null  object
dtypes: object(19)
memory usage: 1.3+ MB
None

```

	Datum von	Datum bis	Deutschland/Luxemburg [€/MWh] Originalauflösungen	Anrainer
0	01.01.2023 00:00	01.01.2023 01:00	-5,17	13,85
1	01.01.2023 01:00	01.01.2023 02:00	-1,07	9,79
2	01.01.2023 02:00	01.01.2023 03:00	-1,47	8,91
3	01.01.2023 03:00	01.01.2023 04:00	-5,08	6,58
4	01.01.2023 04:00	01.01.2023 05:00	-4,49	5,42

In der Ausgabe ist am Datentyp object erkennbar, dass für keine Spalte der Datentyp erkannt wurde. In der Darstellung der ersten Zeilen des Datensatzes ist das Komma als Dezimaltrennzeichen zu sehen, der Standardwert der Funktion `pd.read_csv()` ist aber der Punkt. Nach Übergabe des Dezimaltrennzeichens sollten die numerischen Spalten korrekt erkannt werden.

```

preise = pd.read_csv(filepath_or_buffer = dateipfad, sep = ';', decimal = ',')
print(preise.info())

```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 19 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   Datum von                                                            8760 non-null  object
1   Datum bis                                                            8760 non-null  object
2   Deutschland/Luxemburg [€/MWh] Originalauflösungen                 8760 non-null  float64
3   Anrainer DE/LU [€/MWh] Originalauflösungen                       8760 non-null  float64

```

4	Belgien [€/MWh] Originalauflösungen	8760 non-null	float64
5	Dänemark 1 [€/MWh] Originalauflösungen	8760 non-null	float64
6	Dänemark 2 [€/MWh] Originalauflösungen	8760 non-null	float64
7	Frankreich [€/MWh] Originalauflösungen	8760 non-null	float64
8	Niederlande [€/MWh] Originalauflösungen	8760 non-null	float64
9	Norwegen 2 [€/MWh] Originalauflösungen	8760 non-null	float64
10	Österreich [€/MWh] Originalauflösungen	8760 non-null	float64
11	Polen [€/MWh] Originalauflösungen	8760 non-null	float64
12	Schweden 4 [€/MWh] Originalauflösungen	8760 non-null	float64
13	Schweiz [€/MWh] Originalauflösungen	8760 non-null	float64
14	Tschechien [€/MWh] Originalauflösungen	8760 non-null	float64
15	DE/AT/LU [€/MWh] Originalauflösungen	8760 non-null	object
16	Italien (Nord) [€/MWh] Originalauflösungen	8760 non-null	float64
17	Slowenien [€/MWh] Originalauflösungen	8760 non-null	float64
18	Ungarn [€/MWh] Originalauflösungen	8760 non-null	float64

dtypes: float64(16), object(3)
memory usage: 1.3+ MB
None

Der Datentyp der Spalte DE/AT/LU [€/MWh] Originalauflösungen wird nicht als float64 erkannt. In der Ausgabe ist zu sehen, dass wenigstens in den ersten Zeilen fehlende Werte durch '-' markiert sind. Mittels der Methode `.describe()` kann überprüft werden, ob die Spalte überhaupt numerische Werte enthält.

```
preise['DE/AT/LU [€/MWh] Originalauflösungen'].describe()
```

```
count      8760
unique      1
top         -
freq       8760
Name: DE/AT/LU [€/MWh] Originalauflösungen, dtype: object
```

Da dies nicht der Fall ist, kann die Spalte entfernt werden. Anschließend können die ersten beiden Spalten mit der Funktion `pd.to_datetime()` in ein Datumsformat konvertiert werden. Eine Zelle enthält Zeichenketten im Schema '01.01.2023 00:00'. Mit Hilfe der [strftime-Dokumentation](#) kann der Funktion das Datumsformat übergeben werden.

```
preise.drop(labels = 'DE/AT/LU [€/MWh] Originalauflösungen', axis = 'columns', inplace = True)

## Datumsspalten konvertieren
preise['Datum von'] = pd.to_datetime(preise['Datum von'], format = "%d.%m.%Y %H:%M")
```

```
preise['Datum bis'] = pd.to_datetime(preise['Datum bis'], format = "%d.%m.%Y %H:%M")
print(preise.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 18 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   Datum von                                                            8760 non-null   datetime64[ns]
1   Datum bis                                                            8760 non-null   datetime64[ns]
2   Deutschland/Luxemburg [€/MWh] Originalauflösungen                 8760 non-null   float64
3   Anrainer DE/LU [€/MWh] Originalauflösungen                     8760 non-null   float64
4   Belgien [€/MWh] Originalauflösungen                             8760 non-null   float64
5   Dänemark 1 [€/MWh] Originalauflösungen                         8760 non-null   float64
6   Dänemark 2 [€/MWh] Originalauflösungen                         8760 non-null   float64
7   Frankreich [€/MWh] Originalauflösungen                         8760 non-null   float64
8   Niederlande [€/MWh] Originalauflösungen                       8760 non-null   float64
9   Norwegen 2 [€/MWh] Originalauflösungen                       8760 non-null   float64
10  Österreich [€/MWh] Originalauflösungen                       8760 non-null   float64
11  Polen [€/MWh] Originalauflösungen                             8760 non-null   float64
12  Schweden 4 [€/MWh] Originalauflösungen                       8760 non-null   float64
13  Schweiz [€/MWh] Originalauflösungen                           8760 non-null   float64
14  Tschechien [€/MWh] Originalauflösungen                       8760 non-null   float64
15  Italien (Nord) [€/MWh] Originalauflösungen                   8760 non-null   float64
16  Slowenien [€/MWh] Originalauflösungen                       8760 non-null   float64
17  Ungarn [€/MWh] Originalauflösungen                           8760 non-null   float64
dtypes: datetime64[ns](2), float64(16)
memory usage: 1.2 MB
None
```

Wenn der innere Aufbau einer Datei bekannt ist, können die notwendigen Parameter auch direkt beim Einlesen mit `pd.read_csv` übergeben werden (Argumente `usecols`, `parse_dates` und `date_format`).

```
preise = pd.read_csv(filepath_or_buffer = dateipfad, sep = ';', decimal = ',',
                    usecols = list(range(0, 15)) + list(range(16, 19)), # Auswahl der einzul.
                    parse_dates = ['Datum von', 'Datum bis'], date_format = "%d.%m.%Y %H:%M")
print(preise.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
```

Data columns (total 18 columns):

#	Column	Non-Null Count	Dtype
0	Datum von	8760 non-null	datetime64[ns]
1	Datum bis	8760 non-null	datetime64[ns]
2	Deutschland/Luxemburg [€/MWh] Originalauflösungen	8760 non-null	float64
3	Anrainer DE/LU [€/MWh] Originalauflösungen	8760 non-null	float64
4	Belgien [€/MWh] Originalauflösungen	8760 non-null	float64
5	Dänemark 1 [€/MWh] Originalauflösungen	8760 non-null	float64
6	Dänemark 2 [€/MWh] Originalauflösungen	8760 non-null	float64
7	Frankreich [€/MWh] Originalauflösungen	8760 non-null	float64
8	Niederlande [€/MWh] Originalauflösungen	8760 non-null	float64
9	Norwegen 2 [€/MWh] Originalauflösungen	8760 non-null	float64
10	Österreich [€/MWh] Originalauflösungen	8760 non-null	float64
11	Polen [€/MWh] Originalauflösungen	8760 non-null	float64
12	Schweden 4 [€/MWh] Originalauflösungen	8760 non-null	float64
13	Schweiz [€/MWh] Originalauflösungen	8760 non-null	float64
14	Tschechien [€/MWh] Originalauflösungen	8760 non-null	float64
15	Italien (Nord) [€/MWh] Originalauflösungen	8760 non-null	float64
16	Slowenien [€/MWh] Originalauflösungen	8760 non-null	float64
17	Ungarn [€/MWh] Originalauflösungen	8760 non-null	float64

dtypes: datetime64[ns](2), float64(16)

memory usage: 1.2 MB

None

4.7 Zugriff auf Zeitreihen

Pandas bietet zahlreiche Attribute und Methoden, um Informationen aus `datetime64`-Objekten auszulesen. NumPy unterstützt vergleichbare Funktionen derzeit nicht nativ. Eine Übersicht aller verfügbaren Attribute und Methoden liefert `dir(pd.to_datetime(0))`.

```
# Attribute
print("Jahr:", pd.to_datetime(0).year)
print("Monat:", pd.to_datetime(0).month)
print("Tag:", pd.to_datetime(0).day)
print("Stunde:", pd.to_datetime(0).hour)
print("Minute:", pd.to_datetime(0).minute)
print("Sekunde:", pd.to_datetime(0).second)
print("Tag des Jahres:", pd.to_datetime(0).dayofyear)
print("Wochentag:", pd.to_datetime(0).dayofweek)
print("Tage im Monat:", pd.to_datetime(0).days_in_month)
```

```
print("Schaltjahr:", pd.to_datetime(0).is_leap_year)

# Methoden
print("\nDatum:", pd.to_datetime(0).date())
print("Zeit:", pd.to_datetime(0).time())
print("Wochentag (0-6):", pd.to_datetime(0).weekday())
print("Monatsname:", pd.to_datetime(0).month_name())
```

```
Jahr: 1970
Monat: 1
Tag: 1
Stunde: 0
Minute: 0
Sekunde: 0
Tag des Jahres: 1
Wochentag: 3
Tage im Monat: 31
Schaltjahr: False
```

```
Datum: 1970-01-01
Zeit: 00:00:00
Wochentag (0-6): 3
Monatsname: January
```

Für `pd.Series` erfolgt der Zugriff über den `.dt`-Operator (siehe [.dt accessor](#)). Der Zugriff auf verschiedene Informationen über ein Attribut (ohne Klammern) oder über eine Methode (mit Klammern) unterscheidet sich jedoch teilweise (siehe folgendes Beispiel).

Der dt-Operator

```
# Attribute
print("Datum:", pd.Series(pd.to_datetime(0)).dt.date) # Unterschied
print("Zeit:", pd.Series(pd.to_datetime(0)).dt.time) # Unterschied
print("Jahr", pd.Series(pd.to_datetime(0)).dt.year)
print("Monat", pd.Series(pd.to_datetime(0)).dt.month)
print("Tag", pd.Series(pd.to_datetime(0)).dt.day)
print("Stunde", pd.Series(pd.to_datetime(0)).dt.hour)
print("Minute", pd.Series(pd.to_datetime(0)).dt.minute)
print("Sekunde", pd.Series(pd.to_datetime(0)).dt.second)

print("\nTag des Jahres", pd.Series(pd.to_datetime(0)).dt.dayofyear)
print("Wochentag:", pd.Series(pd.to_datetime(0)).dt.dayofweek)
print("Wochentag:", pd.Series(pd.to_datetime(0)).dt.weekday) # Unterschied
print("Tage im Monat:", pd.Series(pd.to_datetime(0)).dt.days_in_month)
print("Schaltjahr:", pd.Series(pd.to_datetime(0)).dt.is_leap_year)

# Methoden
print("\nName des Monats:", pd.Series(pd.to_datetime(0)).dt.month_name())
```

```
Datum: 0    1970-01-01
dtype: object
Zeit: 0    00:00:00
dtype: object
Jahr 0    1970
dtype: int32
Monat 0    1
dtype: int32
Tag 0    1
dtype: int32
Stunde 0    0
dtype: int32
Minute 0    0
dtype: int32
Sekunde 0    0
dtype: int32
```

```
Tag des Jahres 0    1
dtype: int32
Wochentag: 0    3
dtype: int32
```

```

Wochentag: 0      3
dtype: int32
Tage im Monat: 0      31
dtype: int32
Schaltjahr: 0      False
dtype: bool

Name des Monats: 0      January
dtype: object

```

Die im vorherigen Abschnitt eingelesenen Großhandelspreise für Strom 2023 sollen auf die Unterschiede an Werktagen und am Wochenende untersucht werden. **Vergleichen Sie den durchschnittlichen Strompreis im Gebiet Deutschland/Luxemburg an Werktagen (Montag - Freitag) mit dem durchschnittlichen Strompreis am Wochenende.**

Tipp 19: Musterlösung Strompreisvergleich

```

## Zugriff mit .dt für pd.Series
# Werktage und Wochenende unterscheiden
werktags = preise['Datum von'].dt.weekday.isin(list(range(0, 5)))
wochenende = preise['Datum von'].dt.weekday.isin(list(range(5, 7)))

print(werktags.head())
print(wochenende.head())

# Preise vergleichen
preis_werktags = preise.loc[werktags, 'Deutschland/Luxemburg [€/MWh] Originalauflösungen']
preis_wochenende = preise.loc[wochenende, 'Deutschland/Luxemburg [€/MWh] Originalauflösungen']

print(f"\nDurchschnittspreis werktags: {preis_werktags:.2f} [€/MWh]\nDurchschnittspreis am
0      False
1      False
2      False
3      False
4      False
Name: Datum von, dtype: bool
0      True
1      True
2      True
3      True
4      True

```

```
Name: Datum von, dtype: bool
```

```
Durchschnittspreis werktags: 103.18 [€/MWh]
```

```
Durchschnittspreis am Wochenende: 75.34 [€/MWh]
```

4.8 Fehlende Werte in Zeitreihen

NumPy und Pandas unterstützen NaT für `np.datetime64`, `np.timedelta64`

- NumPy: <https://numpy.org/doc/stable/reference/arrays.datetime.html>
NaT, in any combination of lowercase/uppercase letters, for a “Not A Time”
- Pandas: https://pandas.pydata.org/docs/user_guide/missing_data.html

⚠ Warning 5: Achtung Logik!

Die logische Abfrage fehlender Werte unterscheidet sich für `None`, `np.nan` und `pd.NA` und `pd.NaT`.

```
bool_values = [None, float('nan'), pd.NA, pd.NaT]

for element in bool_values:
    try:
        bool_value = bool(element)
    except TypeError as error:
        print(error)
    else:
        print("Wahrheitswert von", element, "ist", bool_value)
```

```
Wahrheitswert von None ist False
Wahrheitswert von nan ist True
boolean value of NA is ambiguous
Wahrheitswert von NaT ist True
```

Dies gilt auch für die Wertgleichheit.

```
for element in bool_values:
    try:
        result = element == element
    except TypeError as error:
        print(error)
    else:
        print("Wertgleichheit von", element, "ist", result)
```

```
Wertgleichheit von None ist True
Wertgleichheit von nan ist False
Wertgleichheit von <NA> ist <NA>
Wertgleichheit von NaT ist False
```

4.9 Übungen: Zeitreihen einlesen

Die folgenden Übungen trainieren die Anwendung der in diesem Kapitel vorgestellten Werkzeuge und können mit NumPy oder mit Pandas gelöst werden.

“everybody I know has war stories about cleaning up lousy datasets”

Nicholas J. Cox

Cox, Nicholas J. 2004: Exploratory Data Mining and Data Cleaning. Book Review 9. In: Journal of Statistical Software 2004, Volume 11. <https://www.jstatsoft.org/article/view/v011b09/30>

Leicht: Englisches Datumsformat einlesen

Aufgabe: Lesen Sie die Datei Dateipfad: ‘01-daten/Day-ahead_prices_202301010000_202401010000’ so ein, dass die Datentypen korrekt erkannt werden. (Hinweise zur Datei siehe Hinweis 4, siehe [Dokumentation strptime zur string-Formatierung](#))

💡 Tipp 20: Musterlösung Strompreise

```
import pandas as pd

dateipfad = "01-daten/Day-ahead_prices_202301010000_202401010000_Hour.csv"

data = pd.read_csv(dateipfad, sep=";") # Semikolon als Trennzeichen muss angegeben werden
data.info() # -> man sieht, dass Spalten 0 "Start date" und 1 "End date" als Dtype "object"
print("\n")

print(data.iloc[0:10, 0:2], "\n") # anzeigen von ein paar Zeilen, um zu schauen wie die ers
# Ausgabe lautet:
# Start date: Jan 1, 2023 12:00 AM
# End date Jan 1, 2023 1:00 AM
# also bieten sich zwei Varianten an:

# 1. Variante: beim Einlesen schon Datumsformat angeben:
data = pd.read_csv(dateipfad, sep=";" , parse_dates=[0,1], date_format="%b %d, %Y %I:%M %p")

# 2. Variante: Die beiden Spalten zu Anfang, die dtype object haben, separat ändern nachden
data["Start date"] = pd.to_datetime(data["Start date"], format="%b %d, %Y %I:%M %p") # %b f
data["End date"] = pd.to_datetime(data["End date"], format="%b %d, %Y %I:%M %p")
print(data.iloc[0:10, 0:2], "\n")

data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 19 columns):
 #   Column                                Non-
Null Count  Dtype
```

```

---  -----
0    Start date                                8760 non-
null  object
1    End date                                  8760 non-
null  object
2    Germany/Luxembourg [€/MWh] Original resolutions 8760 non-
null  float64
3    DE/LU neighbours [€/MWh] Original resolutions 8760 non-
null  float64
4    Belgium [€/MWh] Original resolutions            8760 non-
null  float64
5    Denmark 1 [€/MWh] Original resolutions          8760 non-
null  float64
6    Denmark 2 [€/MWh] Original resolutions          8760 non-
null  float64
7    France [€/MWh] Original resolutions             8760 non-
null  float64
8    Netherlands [€/MWh] Original resolutions        8760 non-
null  float64
9    Norway 2 [€/MWh] Original resolutions           8760 non-
null  float64
10   Austria [€/MWh] Original resolutions            8760 non-
null  float64
11   Poland [€/MWh] Original resolutions             8760 non-
null  float64
12   Sweden 4 [€/MWh] Original resolutions           8760 non-
null  float64
13   Switzerland [€/MWh] Original resolutions        8760 non-
null  float64
14   Czech Republic [€/MWh] Original resolutions    8760 non-
null  float64
15   DE/AT/LU [€/MWh] Original resolutions          8760 non-
null  object
16   Northern Italy [€/MWh] Original resolutions      8760 non-
null  float64
17   Slovenia [€/MWh] Original resolutions           8760 non-
null  float64
18   Hungary [€/MWh] Original resolutions            8760 non-
null  float64
dtypes: float64(16), object(3)
memory usage: 1.3+ MB

```

	Start date	End date
0	Jan 1, 2023 12:00 AM	Jan 1, 2023 1:00 AM
1	Jan 1, 2023 1:00 AM	Jan 1, 2023 2:00 AM
2	Jan 1, 2023 2:00 AM	Jan 1, 2023 3:00 AM
3	Jan 1, 2023 3:00 AM	Jan 1, 2023 4:00 AM
4	Jan 1, 2023 4:00 AM	Jan 1, 2023 5:00 AM
5	Jan 1, 2023 5:00 AM	Jan 1, 2023 6:00 AM
6	Jan 1, 2023 6:00 AM	Jan 1, 2023 7:00 AM
7	Jan 1, 2023 7:00 AM	Jan 1, 2023 8:00 AM
8	Jan 1, 2023 8:00 AM	Jan 1, 2023 9:00 AM
9	Jan 1, 2023 9:00 AM	Jan 1, 2023 10:00 AM

	Start date	End date
0	2023-01-01 00:00:00	2023-01-01 01:00:00
1	2023-01-01 01:00:00	2023-01-01 02:00:00
2	2023-01-01 02:00:00	2023-01-01 03:00:00
3	2023-01-01 03:00:00	2023-01-01 04:00:00
4	2023-01-01 04:00:00	2023-01-01 05:00:00
5	2023-01-01 05:00:00	2023-01-01 06:00:00
6	2023-01-01 06:00:00	2023-01-01 07:00:00
7	2023-01-01 07:00:00	2023-01-01 08:00:00
8	2023-01-01 08:00:00	2023-01-01 09:00:00
9	2023-01-01 09:00:00	2023-01-01 10:00:00

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 8760 entries, 0 to 8759
```

```
Data columns (total 19 columns):
```

#	Column	Non-
Null Count	Dtype	
---	-----	-----
0	Start date	8760 non-
null	datetime64[ns]	
1	End date	8760 non-
null	datetime64[ns]	
2	Germany/Luxembourg [€/MWh] Original resolutions	8760 non-
null	float64	
3	DE/LU neighbours [€/MWh] Original resolutions	8760 non-
null	float64	
4	Belgium [€/MWh] Original resolutions	8760 non-
null	float64	
5	Denmark 1 [€/MWh] Original resolutions	8760 non-

```

null    float64
   6    Denmark 2 [€/MWh] Original resolutions      8760 non-
null    float64
   7    France [€/MWh] Original resolutions        8760 non-
null    float64
   8    Netherlands [€/MWh] Original resolutions    8760 non-
null    float64
   9    Norway 2 [€/MWh] Original resolutions       8760 non-
null    float64
  10    Austria [€/MWh] Original resolutions        8760 non-
null    float64
  11    Poland [€/MWh] Original resolutions         8760 non-
null    float64
  12    Sweden 4 [€/MWh] Original resolutions       8760 non-
null    float64
  13    Switzerland [€/MWh] Original resolutions    8760 non-
null    float64
  14    Czech Republic [€/MWh] Original resolutions 8760 non-
null    float64
  15    DE/AT/LU [€/MWh] Original resolutions       8760 non-
null    object
  16    Northern Italy [€/MWh] Original resolutions  8760 non-
null    float64
  17    Slovenia [€/MWh] Original resolutions       8760 non-
null    float64
  18    Hungary [€/MWh] Original resolutions        8760 non-
null    float64
dtypes: datetime64[ns](2), float64(16), object(1)
memory usage: 1.3+ MB

```

Musterlösung von Marc Sönneken. Zur Verbesserung der Lesbarkeit wurde die Ausgabe mit `print(data.head(10))` ersetzt durch `print(data.iloc[0:10, 0:2], "\n")`. Um sich einen Überblick über einen Datensatz zu verschaffen, ist die Methode `.head()` jedoch besser geeignet

Mittel: Strommarktdaten Österreich

Die Austrian Power Grid AG (APG) veröffentlicht Strommarktdaten unter <https://markttransparenz.apg.at/>. Unter dem Link können Erzeugungsdaten für das Jahr 2023 heruntergeladen werden.

Warning 6: Markttransparenzdaten Österreich herunterladen

Nach der Auswahl des Zeitraums auf Exportieren klicken, dann erscheint die Schaltfläche Download.




Abbildung 4.3:




Abbildung 4.4:

Das Datumsformat der Dateien ist abhängig von der auf der Internetseite eingestellten Sprache (Deutsch/English).

Diesem Skript ist folgende Datei angefügt.

Daten	Dateiname
Realisierte Stromerzeugung 2023	AGPT_2022-12-31T23_00_00Z_2023-12-31T23_00_00Z_15M_de_2024-06-10T09_32_38Z.csv

In dem Datensatz wird durch die Umstellung von Sommer- auf Winterzeit am letzten Sonntag im Oktober die Stunde 2 Uhr morgens doppelt eingetragen (dafür fehlt eine Stunde bei der Umstellung von Winter- auf Sommerzeit am letzten Sonntag im März). Die doppelte Stunde wird im Datensatz mit 2A bzw. 2B gekennzeichnet. (Mitteilung Austrian Power Grid AG vom 13.08.2024)

	A	B	C	D	
1	Zeit von [CET/CEST]	Zeit bis [CET/CEST]	Wind [MW]	Solar [MW]	Biom
28899	29.10.2023 01:15:00	29.10.2023 01:30:00	396	0	
28900	29.10.2023 01:30:00	29.10.2023 01:45:00	360	0	
28901	29.10.2023 01:45:00	29.10.2023 2A:00:00	308	0	
28902	29.10.2023 2A:00:00	29.10.2023 2A:15:00	300	0	
28903	29.10.2023 2A:15:00	29.10.2023 2A:30:00	296	0	
28904	29.10.2023 2A:30:00	29.10.2023 2A:45:00	288	0	
28905	29.10.2023 2A:45:00	29.10.2023 2B:00:00	272	0	
28906	29.10.2023 2B:00:00	29.10.2023 2B:15:00	264	0	
28907	29.10.2023 2B:15:00	29.10.2023 2B:30:00	260	0	
28908	29.10.2023 2B:30:00	29.10.2023 2B:45:00	252	0	
28909	29.10.2023 2B:45:00	29.10.2023 03:00:00	240	0	
28910	29.10.2023 03:00:00	29.10.2023 03:15:00	244	0	

Abbildung 4.5: Zeitumstellung im österreichischen Datensatz

Lesen Sie die Datei so ein, dass die Spalten mit Datums- und Zeitinformationen als `datetime` erkannt werden. Lösen Sie die Zeitumstellung so auf, dass jeder Tag 24 Stunden hat.

💡 Tipp 21: Musterlösung Strommarktdaten Österreich

einfache Variante

Die einfachste Lösung ist es, Zeitreihen zu generieren und die Spalten 'Zeit von [CET/CEST]' und 'Zeit bis [CET/CEST]' damit zu ersetzen.

```

von = pd.date_range(start = "2023-01-01T00:00", end = "2023-12-31T23:45", freq = '15min')
bis = pd.date_range(start = "2023-01-01T00:15", end = "2024-01-01T00:00", freq = '15min')

print(von[8070:8078], "\n")
print(bis[8070:8078], "\n")

```

Datei einlesen und String-Manipulation

Zunächst wird die Datei eingelesen. Die Zellen, die sich nicht in `datetime` umwandeln lassen, können mit Python ausgegeben werden.

```
# Datei einlesen
erzeugung_austria = pd.read_csv(filepath_or_buffer = "01-daten/AGPT_2022-12-31T23_00_00Z_2022-12-31T23_00_00Z_2022-12-31T23_00_00Z.csv",
                                sep = ";", decimal = ",", thousands = ".")

# Zellen mit fehlerhaften datetime strings identifizieren
print("Spalte 'Zeit von [CET/CEST]'" )
i = 0
position_element = []
for element in erzeugung_austria['Zeit von [CET/CEST]']:
    try:
        pd.to_datetime(element, format = "%d.%m.%Y %H:%M:%S")
    except:
        print(element)
        position_element.append(i)
        i += 1
print("\nDie Zellen haben den Zeilenindex: ", position_element, "\n")

print("Spalte 'Zeit bis [CET/CEST]'" )
i = 0
position_element = []
for element in erzeugung_austria['Zeit bis [CET/CEST]']:
    try:
        pd.to_datetime(element, format = "%d.%m.%Y %H:%M:%S")
    except:
        print(element)
        position_element.append(i)
        i += 1
print("\nDie Zellen haben den Zeilenindex: ", position_element, "\n")

Spalte 'Zeit von [CET/CEST]'
29.10.2023 2A:00:00
29.10.2023 2A:15:00
29.10.2023 2A:30:00
29.10.2023 2A:45:00
29.10.2023 2B:00:00
29.10.2023 2B:15:00
29.10.2023 2B:30:00
29.10.2023 2B:45:00
```

Die Zellen haben den Zeilenindex: [28900, 28901, 28902, 28903, 28904, 28905, 28906, 28907]

Spalte 'Zeit bis [CET/CEST]'

29.10.2023 2A:00:00
29.10.2023 2A:15:00
29.10.2023 2A:30:00
29.10.2023 2A:45:00
29.10.2023 2B:00:00
29.10.2023 2B:15:00
29.10.2023 2B:30:00
29.10.2023 2B:45:00

Die Zellen haben den Zeilenindex: [28899, 28900, 28901, 28902, 28903, 28904, 28905, 28906]

Damit die Datumsspalten korrekt eingelesen werden können, werden die Zeichenfolgen “2A” und “2B” mit der Methode `str.replace()` durch “02” ersetzt. Dadurch wird eine Dublette im Datensatz erzeugt.

```
# string replace & als Datum einlesen
## Spalte Zeit von [CET/CEST]
erzeugung_austria['Zeit von [CET/CEST]'] = erzeugung_austria['Zeit von [CET/CEST]'].str.replace('2A', '02')
erzeugung_austria['Zeit von [CET/CEST]'] = erzeugung_austria['Zeit von [CET/CEST]'].str.replace('2B', '02')

erzeugung_austria['Zeit von [CET/CEST]'] = pd.to_datetime(erzeugung_austria['Zeit von [CET/CEST]'])

## Spalte Zeit bis [CET/CEST]
erzeugung_austria['Zeit bis [CET/CEST]'] = erzeugung_austria['Zeit bis [CET/CEST]'].str.replace('2A', '02')
erzeugung_austria['Zeit bis [CET/CEST]'] = erzeugung_austria['Zeit bis [CET/CEST]'].str.replace('2B', '02')

erzeugung_austria['Zeit bis [CET/CEST]'] = pd.to_datetime(erzeugung_austria['Zeit bis [CET/CEST]'])

print(erzeugung_austria.info())
```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 35040 entries, 0 to 35039

Data columns (total 15 columns):

#	Column	Non-Null Count	Dtype
----	-----	-----	-----
0	Zeit von [CET/CEST]	35040 non-null	datetime64[ns]
1	Zeit bis [CET/CEST]	35040 non-null	datetime64[ns]
2	Wind [MW]	35040 non-null	float64
3	Solar [MW]	35040 non-null	float64
4	Biomasse [MW]	35040 non-null	float64
5	Gas [MW]	35040 non-null	float64

```

6   Kohle [MW]                35040 non-null float64
7   Öl [MW]                   35040 non-null float64
8   Geothermie [MW]           35040 non-null float64
9   Pumpspeicher [MW]         35040 non-null float64
10  Lauf- und Schwellwasser [MW] 35040 non-null float64
11  Speicher [MW]              35040 non-null float64
12  Sonstige Erneuerbare [MW]   35040 non-null float64
13  Müll [MW]                  35040 non-null float64
14  Andere [MW]                35040 non-null float64
dtypes: datetime64[ns](2), float64(13)
memory usage: 4.0 MB
None

```

Indexpositionen der doppelten und der fehlenden Stunde bestimmen

Im nächsten Schritt werden die Indexposition der doppelten und der fehlenden Stunde bestimmt. Dazu wird ein neues Objekt angelegt, das auf den Speicherbereich der Datums­spalten zugreift (was nicht zwingend erforderlich ist). Die Position der doppelten Stunde wird mit der Methode `pd.Series.duplicated()` bestimmt, die einen logischen Vektor zurückgibt. Dieser wird zum Slicing und der Ausgabe der Indexposition verwendet. Durch die Subtraktion von 4 wird der Index der ersten Stunde ausgegeben (der Datensatz ist auf Viertelstundenbasis).

doppelte Stunde

```

# neues Objekt anlegen
austria_dates = erzeugung_austria[['Zeit von [CET/CEST]', 'Zeit bis [CET/CEST]']].copy()

# Indexposition der doppelten Stunde bestimmen
## Zeit von
position_doppelte_stunde_von = austria_dates['Zeit von [CET/CEST]'][austria_dates['Zeit von [CET/CEST]'].isnull().idxmax()

print(f"Die doppelte Stunde (Zeit von):\n{austria_dates.loc[position_doppelte_stunde_von, 'Zeit von [CET/CEST]']}")
print(f"Die nächste Stunde lautet:\n{austria_dates.loc[position_doppelte_stunde_von + 4, 'Zeit von [CET/CEST]']}")
print(f"\nBeide Stunden sind identisch.")

### Ende der Verschiebung in Spalte Zeit von
ende_verschiebung_von = position_doppelte_stunde_von[-1]
print(f"\nDie Zeitverschiebung in der Spalte Zeit von endet bei Indexposition: {ende_verschiebung_von}")

## Zeit bis
position_doppelte_stunde_bis = austria_dates['Zeit bis [CET/CEST]'][austria_dates['Zeit bis [CET/CEST]'].isnull().idxmax()

print(f"\nDie doppelte Stunde (Zeit bis):\n{austria_dates.loc[position_doppelte_stunde_bis, 'Zeit bis [CET/CEST]']}")
print(f"Die nächste Stunde lautet:\n{austria_dates.loc[position_doppelte_stunde_bis + 4, 'Zeit bis [CET/CEST]']}")
print(f"\nBeide Stunden sind identisch.")

### Ende der Verschiebung in Spalte Zeit bis
ende_verschiebung_bis = position_doppelte_stunde_bis[-1]
print(f"\nDie Zeitverschiebung in der Spalte Zeit bis endet bei Indexposition: {ende_verschiebung_bis}")

```

Die doppelte Stunde (Zeit von):

28900	2023-10-29 02:00:00
28901	2023-10-29 02:15:00
28902	2023-10-29 02:30:00
28903	2023-10-29 02:45:00

Name: Zeit von [CET/CEST], dtype: datetime64[ns]
steht an Indexposition
Index([28900, 28901, 28902, 28903], dtype='int64')

Die nächste Stunde lautet:

28904	2023-10-29 02:00:00
28905	2023-10-29 02:15:00
28906	2023-10-29 02:30:00
28907	2023-10-29 02:45:00

Name: Zeit von [CET/CEST], dtype: datetime64[ns]

Beide Stunden sind identisch.

Die Zeitverschiebung in der Spalte Zeit von endet bei Indexposition: 28903

Die doppelte Stunde (Zeit bis):

```
28899    2023-10-29 02:00:00
28900    2023-10-29 02:15:00
28901    2023-10-29 02:30:00
28902    2023-10-29 02:45:00
Name: Zeit bis [CET/CEST], dtype: datetime64[ns]
steht an Indexposition
Index([28899, 28900, 28901, 28902], dtype='int64')
```

Die nächste Stunde lautet:

```
28903    2023-10-29 02:00:00
28904    2023-10-29 02:15:00
28905    2023-10-29 02:30:00
28906    2023-10-29 02:45:00
Name: Zeit bis [CET/CEST], dtype: datetime64[ns]
```

Beide Stunden sind identisch.

Die Zeitverschiebung in der Spalte Zeit bis endet bei Indexposition: 28902

fehlende Stunde

Die Sommerzeit beginnt am letzten Sonntag im März. Die Stunde liegt nicht in range(0, 24). Diese Bedingung kann in vier Schritten kontrolliert werden:

- Monat März: `march = pd.Series[pd.Series.dt.month == 3]`
- Sonntage im März: `sundays = march[march.dt.dayofweek == 6]`
- letzter Sonntag im März: Die letzten 23*4 Einträge sind der letzte Sonntag des Monats (23 weil eine Stunde fehlt).
`last_sunday = sundays[-23*4:]`
- fehlende Stunde: `np.argmax(np.invert(pd.Series(range(0,24)).isin(last_sunday.dt.hour)))`

```

# Indexposition der fehlenden Stunde bestimmen
## Zeit von
### Monat März
maske_märz_von = austria_dates['Zeit von [CET/CEST]'].dt.month == 3
austria_dates_march_von = austria_dates.loc[maske_märz_von, 'Zeit von [CET/CEST]']
print(f"Der Monat März (Zeit von):\n{austria_dates_march_von.head}\n");

### letzter Sonntag
maske_sonntag_von = (austria_dates_march_von.dt.dayofweek == 6)
letzter_sonntag_von = (austria_dates_march_von[maske_sonntag_von]) [-23*4 :]
print(f"Der letzte Sonntag im März:\n{letzter_sonntag_von}\n")

### fehlende Stunde
print(letzter_sonntag_von.dt.hour)
fehlende_stunde_von = np.argwhere(np.invert(pd.Series(range(0,24)).isin(letzter_sonntag_von.dt.hour)))
print(f"\nEs fehlt die Stunde:\n{fehlende_stunde_von}\n")
print(letzter_sonntag_von[letzter_sonntag_von.dt.hour == (fehlende_stunde_von - 1)], letzter_sonntag_von[letzter_sonntag_von.dt.hour == fehlende_stunde_von])

### Beginn der Verschiebung in Spalte Zeit von
beginn_verschiebung_von = letzter_sonntag_von[letzter_sonntag_von.dt.hour == (fehlende_stunde_von - 1)]

print(f"\nDie Zeitverschiebung in der Spalte Zeit von beginnt bei Indexposition: {beginn_verschiebung_von.index[0]}")

## Zeit bis
### Monat März
maske_märz_bis = austria_dates['Zeit bis [CET/CEST]'].dt.month == 3
austria_dates_march_bis = austria_dates.loc[maske_märz_bis, 'Zeit bis [CET/CEST]']
print(f"Der Monat März (Zeit bis):\n{austria_dates_march_bis.head}\n");

### letzter Sonntag
maske_sonntag_bis = (austria_dates_march_bis.dt.dayofweek == 6)
letzter_sonntag_bis = (austria_dates_march_bis[maske_sonntag_bis]) [-23*4 :]
print(f"Der letzte Sonntag im März:\n{letzter_sonntag_bis}\n")

### fehlende Stunde
print(letzter_sonntag_bis.dt.hour)
fehlende_stunde_bis = np.argwhere(np.invert(pd.Series(range(0,24)).isin(letzter_sonntag_bis.dt.hour)))
print(f"\nEs fehlt die Stunde:\n{fehlende_stunde_bis}\n")
print(letzter_sonntag_bis[letzter_sonntag_bis.dt.hour == (fehlende_stunde_bis - 1)], letzter_sonntag_bis[letzter_sonntag_bis.dt.hour == fehlende_stunde_bis])

### Beginn der Verschiebung in Spalte Zeit bis
beginn_verschiebung_bis = letzter_sonntag_bis[letzter_sonntag_bis.dt.hour == (fehlende_stunde_bis - 1)]

print(f"\nDie Zeitverschiebung in der Spalte Zeit bis beginnt bei Indexposition: {beginn_verschiebung_bis.index[0]}")

```

```

Der Monat März (Zeit von):
<bound method NDFrame.head of 5664    2023-03-01 00:00:00
5665    2023-03-01 00:15:00
5666    2023-03-01 00:30:00
5667    2023-03-01 00:45:00
5668    2023-03-01 01:00:00
...
8631    2023-03-31 22:45:00
8632    2023-03-31 23:00:00
8633    2023-03-31 23:15:00
8634    2023-03-31 23:30:00
8635    2023-03-31 23:45:00
Name: Zeit von [CET/CEST], Length: 2972, dtype: datetime64[ns]>

Der letzte Sonntag im März:
8064    2023-03-26 00:00:00
8065    2023-03-26 00:15:00
8066    2023-03-26 00:30:00
8067    2023-03-26 00:45:00
8068    2023-03-26 01:00:00
...
8151    2023-03-26 22:45:00
8152    2023-03-26 23:00:00
8153    2023-03-26 23:15:00
8154    2023-03-26 23:30:00
8155    2023-03-26 23:45:00
Name: Zeit von [CET/CEST], Length: 92, dtype: datetime64[ns]

8064    0
8065    0
8066    0
8067    0
8068    1
...
8151    22
8152    23
8153    23
8154    23
8155    23
Name: Zeit von [CET/CEST], Length: 92, dtype: int32

```

Es fehlt die Stunde:

2

```
8068    2023-03-26 01:00:00
8069    2023-03-26 01:15:00
8070    2023-03-26 01:30:00
8071    2023-03-26 01:45:00
Name: Zeit von [CET/CEST], dtype: datetime64[ns]
8072    2023-03-26 03:00:00
8073    2023-03-26 03:15:00
8074    2023-03-26 03:30:00
8075    2023-03-26 03:45:00
Name: Zeit von [CET/CEST], dtype: datetime64[ns]
```

Die Zeitverschiebung in der Spalte Zeit von beginnt bei Indexposition: 8072

Der Monat März (Zeit bis):

```
<bound method NDFrame.head of 5663    2023-03-01 00:00:00
5664    2023-03-01 00:15:00
5665    2023-03-01 00:30:00
5666    2023-03-01 00:45:00
5667    2023-03-01 01:00:00
...
8630    2023-03-31 22:45:00
8631    2023-03-31 23:00:00
8632    2023-03-31 23:15:00
8633    2023-03-31 23:30:00
8634    2023-03-31 23:45:00
Name: Zeit bis [CET/CEST], Length: 2972, dtype: datetime64[ns]>
```

Der letzte Sonntag im März:

```
8063    2023-03-26 00:00:00
8064    2023-03-26 00:15:00
8065    2023-03-26 00:30:00
8066    2023-03-26 00:45:00
8067    2023-03-26 01:00:00
...
8150    2023-03-26 22:45:00
8151    2023-03-26 23:00:00
8152    2023-03-26 23:15:00
```

```
8153    2023-03-26 23:30:00
8154    2023-03-26 23:45:00
Name: Zeit bis [CET/CEST], Length: 92, dtype: datetime64[ns]
```

```
8063      0
8064      0
8065      0
8066      0
8067      1
      ..
8150     22
8151     23
8152     23
8153     23
8154     23
Name: Zeit bis [CET/CEST], Length: 92, dtype: int32
```

Es fehlt die Stunde:
2

```
8067    2023-03-26 01:00:00
8068    2023-03-26 01:15:00
8069    2023-03-26 01:30:00
8070    2023-03-26 01:45:00
Name: Zeit bis [CET/CEST], dtype: datetime64[ns]
8071    2023-03-26 03:00:00
8072    2023-03-26 03:15:00
8073    2023-03-26 03:30:00
8074    2023-03-26 03:45:00
Name: Zeit bis [CET/CEST], dtype: datetime64[ns]
```

Die Zeitverschiebung in der Spalte Zeit bis beginnt bei Indexposition: 8071

Mit den gespeicherten Indexpositionen können die betreffenden Zeitstempel verschoben werden:

- Spalte Zeit von: 8072 (Objekt `beginn_verschiebung_von`) bis 28903 (Objekt `ende_verschiebung_von`)
- Spalte Zeit bis: 8071 (Objekt `beginn_verschiebung_bis`) bis 28902 (Objekt `ende_verschiebung_bis`)

Für das Slicing wird die Methode `pd.Series.iloc[]` verwendet, die exklusiv index-

iert, d. h. die Endpositionen müssen um 1 erhöht werden. Durch Subtraktion von `pd.Timedelta(1, unit = 'h')` wird die Zeitverschiebung aus dem Datensatz entfernt.

```
# Zeitverschiebung korrigieren
## Zeit von
austria_dates['Zeit von [CET/CEST]'].iloc[beginn_verschiebung_von : ende_verschiebung_von + 1]

erzeugung_austria['Zeit von [CET/CEST]'] = austria_dates['Zeit von [CET/CEST]']

## Zeit bis
austria_dates['Zeit bis [CET/CEST]'].iloc[beginn_verschiebung_bis : ende_verschiebung_bis + 1]

erzeugung_austria['Zeit bis [CET/CEST]'] = austria_dates['Zeit bis [CET/CEST]']

# Kontrolle
print("Kontrolle im Datensatz +/- eine Viertelstunde\n")
print("Die Spalte Zeit von")
print(erzeugung_austria['Zeit von [CET/CEST]'].iloc[beginn_verschiebung_von - 1 : ende_verschiebung_von + 1])

print("Die Spalte Zeit bis")
print(erzeugung_austria['Zeit bis [CET/CEST]'].iloc[beginn_verschiebung_bis - 1 : ende_verschiebung_bis + 1])
```

Kontrolle im Datensatz +/- eine Viertelstunde

Die Spalte Zeit von

```
8071    2023-03-26 01:45:00
8072    2023-03-26 02:00:00
8073    2023-03-26 02:15:00
8074    2023-03-26 02:30:00
8075    2023-03-26 02:45:00
```

...

```
28900   2023-10-29 01:00:00
28901   2023-10-29 01:15:00
28902   2023-10-29 01:30:00
28903   2023-10-29 01:45:00
28904   2023-10-29 02:00:00
```

Name: Zeit von [CET/CEST], Length: 20834, dtype: datetime64[ns]

Die Spalte Zeit bis

```
8070    2023-03-26 01:45:00
8071    2023-03-26 02:00:00
8072    2023-03-26 02:15:00
```

```

8073    2023-03-26 02:30:00
8074    2023-03-26 02:45:00
...
28899   2023-10-29 01:00:00
28900   2023-10-29 01:15:00
28901   2023-10-29 01:30:00
28902   2023-10-29 01:45:00
28903   2023-10-29 02:00:00
Name: Zeit bis [CET/CEST], Length: 20834, dtype: datetime64[ns]

```

Schwer: CAPE Ratio - ein Datensatz voller Tücken

Der Nobelpreisgewinner für Wirtschaftswissenschaften von 2013 Robert Shiller pflegt einen Datensatz mit monatlichen Kursdaten des amerikanischen Aktienindexes S&P500 und weiteren Wirtschaftsindikatoren zur Berechnung des inflationsbereinigten Kurs-Gewinn-Verhältnisses (CAPE Ratio). Der Datensatz ist auf der [Webseite](#) von Robert Shiller verfügbar ([Direktlink zur XLS-Datei](#)). **Lesen Sie den Datensatz ein.**

Daten	Dateiname
monatliche Kursdaten S&P500	shiller_data.xls

Tipp 22: Hinweise und Musterlösung Shiller data

Schauen Sie sich den Datensatz zunächst mit einem Tabellenkalkulationsprogramm an. Bemerkenswerte Auffälligkeiten sind:

- Metadaten in den Zeilen 2 und 3, in denen teilweise auch Spaltenbeschriftungen eingetragen sind, sowie am Ende des Datensatzes,
- mehrzeilige Spaltenbeschriftungen,
- Leerspalten P und N,
- Kennzeichnung fehlender Werte durch 'NA' und leere Zellen '' sowie
- abweichende Formatierung des Monats Oktober in der Spalte Date 'YYYY-M'.

Tipp 4.7: Lösungshilfe

Aufgrund der zahlreichen Auffälligkeiten ist es hilfreich, die Daten und die Kopfzeilen getrennt einzulesen. Den korrekten Zeilenindex können Sie entweder

der ersten Betrachtung mit einem Tabellenkalkulationsprogramm entnehmen oder indem Sie einfach die ersten 10 oder 20 Zeilen des Datensatzes in Python einlesen. Dadurch können die Daten einfacher überblickt und mit Methoden der String-Bearbeitung manipuliert werden. In der Praxis ist es einfacher, die Spaltenbeschriftungen manuell mit dem Argument `names = Sequence of column labels to apply` einzutragen bzw. dies mit Hilfe eines Tabellenkalkulationsprogramms zu erledigen.

Außerdem empfiehlt es sich, schrittweise vorzugehen und für jedes Problem eine separate Lösung, mit Ausschnitten des Datensatzes bzw. mit dafür generierten Testdaten, zu entwickeln.

Tipp 4.6: Vollständige Musterlösung

Zum Einlesen wird die Funktion `pd.read_excel()` verwendet. Mit dem Argument `sheet_name` kann das Tabellenblatt Data ausgewählt werden. Über die Methode `pd.head(n = 10)` kann der Zeilenindex bestimmt werden, an dem der Tabellenkopf endet und die Daten beginnen. Es handelt sich um die achte Zeile, die in Python den Zeilenindex 7 hat.

Kopf einlesen

```
dateipfad = '01-daten/shiller_data.xls'
shiller = pd.read_excel(io = dateipfad, sheet_name = 'Data')

# manuell Ende des Kopfs und Beginn der Daten identifizieren (auskommentiert)
# print(shiller.head(n = 10), "\n")

# Kopf einlesen
shiller_head = pd.read_excel(io = dateipfad, sheet_name = 'Data', skiprows = 1, n
print(shiller_head, "\n")
print(shiller_head.info()) # die leeren Spalten werden als numerisch erkannt
```

	0	1	2	\
0	Stock Market Data Used in "Irrational Exuberan...	NaN	NaN	
1	Robert J. Shiller	NaN	NaN	
2	NaN	NaN	NaN	
3	NaN	NaN	NaN	
4	NaN	S&P	NaN	
5	NaN	Comp.	Dividend	
6	Date	P	D	

	3	4	5	6	7	8	9	...	\
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	

1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	
2	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	
3	NaN	Consumer	NaN	NaN	NaN	NaN	Real	...	
4	NaN	Price	NaN	Long	NaN	NaN	Total	...	
5	Earnings	Index	Date	Interest	Real	Real	Return	...	
6	E	CPI	Fraction	Rate	GS10	Price	Dividend	Price	...

		12	13			14	15		16		17		18	\
0	Cyclically	NaN		Cyclically	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1	Adjusted	NaN		Adjusted	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
2	Price	NaN	Total	Return	Price	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
3	Earnings	NaN		Earnings	NaN	NaN	NaN	Monthly	Real	NaN	NaN	NaN	NaN	
4	Ratio	NaN		Ratio	NaN	Excess	Total	Total	NaN	NaN	NaN	NaN	NaN	
5	P/E10 or	NaN		TR P/E10 or	NaN	CAPE	Bond	Bond	NaN	NaN	NaN	NaN	NaN	
6	CAPE	NaN		TR CAPE	NaN	Yield	Returns	Returns	NaN	NaN	NaN	NaN	NaN	

		19		20		21
0		NaN		NaN		NaN
1		NaN		NaN		NaN
2		NaN		NaN		NaN
3		NaN		NaN		NaN
4		10 Year		10 Year		Real 10 Year
5	Annualized	Stock	Annualized	Bonds	Excess	Annualized
6	Real	Return	Real	Return		Returns

[7 rows x 22 columns]

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 7 entries, 0 to 6

Data columns (total 22 columns):

#	Column	Non-Null Count	Dtype
0	0	3 non-null	object
1	1	3 non-null	object
2	2	2 non-null	object
3	3	2 non-null	object
4	4	4 non-null	object
5	5	2 non-null	object
6	6	3 non-null	object
7	7	2 non-null	object
8	8	2 non-null	object

```

9    9      4 non-null    object
10   10     2 non-null    object
11   11     4 non-null    object
12   12     7 non-null    object
13   13     0 non-null    float64
14   14     7 non-null    object
15   15     0 non-null    float64
16   16     3 non-null    object
17   17     4 non-null    object
18   18     4 non-null    object
19   19     3 non-null    object
20   20     3 non-null    object
21   21     3 non-null    object
dtypes: float64(2), object(20)
memory usage: 1.3+ KB
None

```

Spaltenbeschriftungen isolieren

Anschließend kann der Kopf weiter bearbeitet werden, um die Spaltenbeschriftungen zu isolieren. Dafür gibt es verschiedene Möglichkeiten. Weitere Alternativen zur folgenden Variante finden Sie im nachfolgenden Beispiel. Spaltenweise erfolgt die Verkettung der Zeichenketten mit der Methode `pd.Series.str.cat()`, die nur für `pd.Series` verfügbar ist (weshalb mit einer Schleife die Spalten einzeln durchlaufen werden) und nur mit dem Datentyp 'string' verfügbar ist, was durch die Methode `astype('string')` sichergestellt wird.

Anschließend werden nicht zur Spaltenbeschriftung gehörende Zeichenketten mit der Methode `str.replace()` entfernt. Dabei erweist sich das Argument `regex = True` als nützlich.

```

# Spaltenbeschriftung mit Schleife erzeugen
shiller_column_labels = pd.Series()

for column in shiller_head:
    shiller_column_labels = pd.concat([shiller_column_labels, pd.Series(shiller_head.

# Zeichenketten säubern
## erste Zelle entfernen Stock Market Data Used in "Irrational Exuberan...
shiller_column_labels = shiller_column_labels.astype('str').replace(shiller_head.1

## 'Robert J. Shiller' entfernen
shiller_column_labels = shiller_column_labels.astype('str').replace(shiller_head.1

## Leerzeichen entfernen
## regex = True um Leerzeichen innerhalb von Strings zu entfernen
shiller_column_labels = shiller_column_labels.astype('str').replace(' ', '', regex

## sehr lange strings ersetzen
shiller_column_labels = shiller_column_labels.astype('str').replace('CyclicallyAdj
shiller_column_labels = shiller_column_labels.astype('str').replace('CyclicallyAdj

## Index zurücksetzen
shiller_column_labels.reset_index(inplace = True, drop = True)

print(shiller_column_labels)

```

```

0          Date
1      S&PComp.P
2      DividendD
3      EarningsE
4      ConsumerPriceIndexCPI
5          DateFraction
6      LongInterestRateGS10
7          RealPrice
8          RealDividend
9      RealTotalReturnPrice
10         RealEarnings
11      RealTRScaledEarnings
12          CAPE
13
14          TRCAPE

```

```

15
16             ExcessCAPEYield
17             MonthlyTotalBondReturns
18             RealTotalBondReturns
19             10YearAnnualizedStockRealReturn
20             10YearAnnualizedBondsRealReturn
21             Real10YearExcessAnnualizedReturns
dtype: object

```

Alternative Vorgehensweisen zur String-Manipulation des Dateikopfs

Verwendung des NumPy-Datentyps 'str'

Die Angabe von `dtype = 'str'` führt zur Verwendung des NumPy-Datentyps `string` (`dtype = 'str'`), der veränderlich (mutable) ist. Nur damit funktioniert die Verkettung von Strings mit der Methode `PD.df.sum()`.

```

# Der NumPy-Datentyp string ist veränderlich
my_array = np.array(['1', '2'], ['3', '4'])
my_array[0] = ['a', 'b']
my_array

```

```

array(['a', 'b'],
      ['3', '4'], dtype='<U1')

```

Mit den Pandas-Datentypen `'string'` und `'object'` funktioniert das gezeigte Vorgehen nicht. Denn Pandas nutzt den Python-Datentyp `'string'`, der unveränderlich ist. Das bedeutet, es gibt keine Methoden, die eine angelegte Zeichenkette verändern können. Stattdessen geben Methoden wie `str.replace()` neue strings zurück.

```

## mit NumPy-Datentyp string
shiller_head = pd.read_excel(io = dateipfad, sheet_name = 'Data', skiprows = 1

# Kopf mit NumPy-Datentyp string mit pd.sum() verketteten
# print(shiller_head.astype('str').sum(skipna = True, axis = 0))

## Bereinigung des Datensatzes
### nan entfernen
shiller_head = shiller_head.astype('str').replace('nan', '')

### erste Zelle entfernen Stock Market Data Used in "Irrational Exuberan...
shiller_head = shiller_head.astype('str').replace(shiller_head.loc[0, 0], '')

### 'Robert J. Shiller' entfernen
shiller_head = shiller_head.astype('str').replace(shiller_head.loc[1, 0], '')

### Leerzeichen entfernen
### regex = True um Leerzeichen innerhalb von Strings zu entfernen
shiller_head = shiller_head.astype('str').replace(' ', '', regex = True)

### sehr lange strings ersetzen
shiller_head = shiller_head.astype('str').replace('CyclicallyAdjustedPriceEarn
shiller_head = shiller_head.astype('str').replace('CyclicallyAdjustedTotalRetu

### spaltenweise Zeilen verketteten
shiller_head = shiller_head.astype('str').sum(skipna = True, axis = 0)

print("\nzusammengeführte Spaltennamen\n", shiller_head)

```

Verwendung von DF.agg() oder DF.apply()

Die Pandas-Methode `DF.agg()` aggregiert einen DataFrame zeilen- oder spaltenweise durch eine spezifizierbare Funktion. Die Pandas-Methode `DF.apply()` wendet eine Funktion zeilen- oder spaltenweise auf einen DataFrame an. Die Methoden machen also das selbe. Details zur Verwendung des [Lambda-Ausdrucks](#) und der Methode `join` aus der [Pythonbasis](#) finden Sie in den angegebenen Links.

```
shiller_head = pd.read_excel(io = dateipfad, sheet_name = 'Data', skiprows = 1)
# DF.agg()
print(shiller_head.agg(lambda x: ''.join(x.astype(str))))

# DF.apply
print(shiller_head.apply(lambda x: ''.join(x.astype(str))))
```

Daten einlesen

Beim Einlesen der Daten wird der Kopf kontrolliert sowie mit der Methode `.tail()` das Ende der Datenreihe bestimmt, an dem weitere Metadaten vermerkt sind. Diese Metadaten werden anschließend mit dem Argument `skipfooter = 1` übersprungen.

```
dateipfad = '01-daten/shiller_data.xls'

# Daten einlesen
shiller_data = pd.read_excel(io = dateipfad, sheet_name = 'Data', skiprows = 8, skipfooter = 1)
print(shiller_data.head(n = 2), "\n")
shiller_data.tail(n = 5)
```

	0	1	2	3	4	5	6	7	8	9	...	\
0	1871.01	4.44	0.26	0.4	12.46	1871.04	5.32	111.06	6.50	111.06	...	
1	1871.02	4.5	0.26	0.4	12.84	1871.12	5.32	109.22	6.31	109.75	...	
	12	13	14	15	16	17	18	19	20	21		
0	NaN	NaN	NaN	NaN	NaN	1.0	1.00	0.13	0.09	0.04		
1	NaN	NaN	NaN	NaN	NaN	1.0	0.97	0.13	0.09	0.04		
[2 rows x 22 columns]												

	0	1	2	3	4	5	6
1836	2024.01	4815.61	70.48	NaN	308.42	2024.04	4.06
1837	2024.02	5011.96	70.65	NaN	310.33	2024.12	4.21
1838	2024.03	5170.57	70.82	NaN	311.28	2024.21	4.21
1839	2024.04	5243.77	NaN	NaN	311.76	2024.29	4.2
1840	NaN	Apr price is Apr 1st close	NaN	NaN	Mar/Apr CPI estimated	NaN	Apr GS10 is

Nachdem die Metadaten entfernt wurden, werden die erkannten Datentypen mit der Methode `.info()` kontrolliert.

```
shiller_data = pd.read_excel(io = dateipfad, sheet_name = 'Data', skiprows = 8, header = 0)
print(shiller_data.head(n = 2), "\n")
print(shiller_data.tail(n = 2))

# Datentypen bestimmen
shiller_data.info()
```

	0	1	2	3	4	5	6	7	8	9	...	\
0	1871.01	4.44	0.26	0.4	12.46	1871.04	5.32	111.06	6.50	111.06	...	
1	1871.02	4.50	0.26	0.4	12.84	1871.12	5.32	109.22	6.31	109.75	...	

	12	13	14	15	16	17	18	19	20	21
0	NaN	NaN	NaN	NaN	NaN	1.0	1.00	0.13	0.09	0.04
1	NaN	NaN	NaN	NaN	NaN	1.0	0.97	0.13	0.09	0.04

[2 rows x 22 columns]

	0	1	2	3	4	5	6	7	8	\
1838	2024.03	5170.57	70.82	NaN	311.28	2024.21	4.21	5178.50	70.93	
1839	2024.04	5243.77	NaN	NaN	311.76	2024.29	4.20	5243.77	NaN	

	9	...	12	13	14	15	16	17	18	19	20	21
1838	3.43e+06	...	34.02	NaN	36.79	NaN	0.02	1.0	39.27	NaN	NaN	NaN
1839	3.48e+06	...	34.41	NaN	37.18	NaN	0.01	NaN	39.37	NaN	NaN	NaN

[2 rows x 22 columns]

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 1840 entries, 0 to 1839
```

```
Data columns (total 22 columns):
```

#	Column	Non-Null Count	Dtype
0	0	1840 non-null	float64
1	1	1840 non-null	float64
2	2	1839 non-null	float64
3	3	1836 non-null	float64
4	4	1840 non-null	float64
5	5	1840 non-null	float64
6	6	1840 non-null	float64
7	7	1840 non-null	float64

```

8  8      1839 non-null   float64
9  9      1840 non-null   float64
10 10     1836 non-null   float64
11 11     1836 non-null   float64
12 12     1720 non-null   float64
13 13      0 non-null     float64
14 14     1720 non-null   float64
15 15      0 non-null     float64
16 16     1720 non-null   float64
17 17     1839 non-null   float64
18 18     1840 non-null   float64
19 19     1720 non-null   float64
20 20     1720 non-null   float64
21 21     1720 non-null   float64

```

dtypes: float64(22)

memory usage: 316.4 KB

Kopf und Daten zusammenführen

Die Spalten mit dem Index 13 (Spalte N) und 15 (Spalte P) sind leer, diese werden aus dem Kopf und den Daten entfernt. Alle Spalten werden als Fließkommazahl erkannt. Das bedeutet, die Prozentzeichen in den Spalten mit den Indizes 16 und 19 bis 21 (Q, T:V) wurden durch eine Division durch 100 verarbeitet. Mit Ausnahme der Spalte Date wurde somit alle Datentypen korrekt erkannt.

```

# # leere Spalten entfernen
shiller_column_labels = shiller_column_labels.drop(labels = [13, 15])
shiller_data = shiller_data.drop(labels = [13, 15], axis = 'columns')

# Spaltennamen eintragen
shiller_data.columns = shiller_column_labels
shiller_data.info()

```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1840 entries, 0 to 1839

Data columns (total 20 columns):

#	Column	Non-Null Count	Dtype
0	Date	1840 non-null	float64
1	S&PComp.P	1840 non-null	float64
2	DividendD	1839 non-null	float64
3	EarningsE	1836 non-null	float64

4	ConsumerPriceIndexCPI	1840	non-null	float64
5	DateFraction	1840	non-null	float64
6	LongInterestRateGS10	1840	non-null	float64
7	RealPrice	1840	non-null	float64
8	RealDividend	1839	non-null	float64
9	RealTotalReturnPrice	1840	non-null	float64
10	RealEarnings	1836	non-null	float64
11	RealTRScaledEarnings	1836	non-null	float64
12	CAPE	1720	non-null	float64
13	TRCAPE	1720	non-null	float64
14	ExcessCAPEYield	1720	non-null	float64
15	MonthlyTotalBondReturns	1839	non-null	float64
16	RealTotalBondReturns	1840	non-null	float64
17	10YearAnnualizedStockRealReturn	1720	non-null	float64
18	10YearAnnualizedBondsRealReturn	1720	non-null	float64
19	Real10YearExcessAnnualizedReturns	1720	non-null	float64

dtypes: float64(20)

memory usage: 287.6 KB

Datumsformat korrigieren

Im nächsten Schritt wird das Datumsformat korrigiert. Die Spalte Date enthält Zeichenketten im Format 'YYYY,MM'. Eine Ausnahme ist der Monat Oktober, der im Format 'YYYY.M' kodiert ist. In der Ausgabe mit `print()` ist dies nicht zu sehen, da die Darstellung von 2 Dezimalstellen mit dem Befehl `pd.set_option("display.precision", 2)` eingestellt wurde. Die unterschiedliche Länge der Zeichenketten kann mit dem Befehl `shiller_data.loc[0:12, 'Date'].astype('str').str.len()` verdeutlicht werden.

```
print(shiller_data.loc[0:12, 'Date'], "\n")

try:
    pd.to_datetime(shiller_data.loc[0:12, 'Date'], format = "%Y.%m")
except ValueError as error:
    print(error, "\n")
else:
    pd.to_datetime(shiller_data.loc[0:12, 'Date'], format = "%Y.%m")

print(shiller_data.loc[0:12, 'Date'].astype('str').str.len(), "\n")
```

0	1871.01
1	1871.02

```

2    1871.03
3    1871.04
4    1871.05
5    1871.06
6    1871.07
7    1871.08
8    1871.09
9    1871.10
10   1871.11
11   1871.12
12   1872.01

```

Name: Date, dtype: float64

time data "1871" doesn't match format "%Y.%m", at position 0. You might want to try:

- passing ``format`` if your strings have a consistent format;
- passing ``format='ISO8601'`` if your strings are all ISO8601 but not necessarily consistent;
- passing ``format='mixed'``, and the format will be inferred for each element if possible.

```

0    7
1    7
2    7
3    7
4    7
5    7
6    7
7    7
8    7
9    6
10   7
11   7
12   7

```

Name: Date, dtype: int64

Der Datentyp der Spalte 'Date' wird als String deklariert. Mit einer Maske werden die Zeichenketten mit Länge 6 bestimmt. An die Zeichenketten mit der Länge 6 wird eine 0 angehängt, um das Datumsformat anzugleichen. Anschließend wird die Spalte mit der Funktion `pd.to_datetime(format = "%Y.%m")` als datetime eingelesen.

```

# Datentyp Spalte Date als String setzen
# führt zu einer Fehlermeldung:
shiller_data['Date'] = shiller_data['Date'].astype('str');

maske = shiller_data['Date'].str.len() == 6
shiller_data.loc[maske, 'Date'] = shiller_data.loc[maske, 'Date'] + '0'

# Ausgabe Länge Zeichenkette
print(shiller_data.loc[0:12, 'Date'].str.len())
print(shiller_data.loc[0:12, 'Date'])

# Datentyp Spalte Date als datetime setzen
shiller_data['Date'] = pd.to_datetime(shiller_data['Date'], format = "%Y.%m");
shiller_data.info()

```

```

0      7
1      7
2      7
3      7
4      7
5      7
6      7
7      7
8      7
9      7
10     7
11     7
12     7
Name: Date, dtype: int64
0      1871.01
1      1871.02
2      1871.03
3      1871.04
4      1871.05
5      1871.06
6      1871.07
7      1871.08
8      1871.09
9      1871.10
10     1871.11
11     1871.12
12     1872.01

```

```

Name: Date, dtype: object
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1840 entries, 0 to 1839
Data columns (total 20 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Date                                     1840 non-null   object
1   S&PComp.P                               1840 non-null   float64
2   DividendD                               1839 non-null   float64
3   EarningsE                               1836 non-null   float64
4   ConsumerPriceIndexCPI                   1840 non-null   float64
5   DateFraction                             1840 non-null   float64
6   LongInterestRateGS10                    1840 non-null   float64
7   RealPrice                               1840 non-null   float64
8   RealDividend                             1839 non-null   float64
9   RealTotalReturnPrice                    1840 non-null   float64
10  RealEarnings                             1836 non-null   float64
11  RealTRScaledEarnings                     1836 non-null   float64
12  CAPE                                     1720 non-null   float64
13  TRCAPE                                  1720 non-null   float64
14  ExcessCAPEYield                         1720 non-null   float64
15  MonthlyTotalBondReturns                  1839 non-null   float64
16  RealTotalBondReturns                     1840 non-null   float64
17  10YearAnnualizedStockRealReturn          1720 non-null   float64
18  10YearAnnualizedBondsRealReturn          1720 non-null   float64
19  Real10YearExcessAnnualizedReturns        1720 non-null   float64
dtypes: datetime64[ns](1), float64(19)
memory usage: 287.6 KB

```

5 Zugriff auf mehrere lokale Dateien: Modul glob

Das Modul `glob` erlaubt es, mit der Funktion `glob.glob(pathname, *, root_dir = None, recursive = False)` aus einem Ordner alle Dateipfade, die dem im Argument `pathname` spezifizierten Muster entsprechen zurückzugeben. Das Argument `pathname` kann als Schlüsselwort oder positional übergeben werden, die übrigen Argumente müssen als Schlüsselwort übergeben werden (dies signalisiert das Zeichen `*`). Die Speicheradresse des Ordners wird mit dem Argument `root_dir` übergeben, dessen Standardwert das aktuelle Arbeitsverzeichnis ist. Im Argument `pathname` können Platzhalter, sogenannte Wildcards, verwendet werden, um beliebige Zeichen und Zeichenfolgen zu spezifizieren.

Wildcard	Funktion
<code>*</code>	beliebige Zeichenfolge außer Dateipfadelemente wie <code>/</code> oder <code>.</code>
<code>?</code>	genau ein beliebiges Zeichen
<code>[]</code>	alle in den Klammern eingeschlossenen Zeichen inklusive der Wildcards
	<code>* ?</code>
<code>[0-9]</code>	alle Ziffern 0 bis 9

Unter dem Pfad `'01-daten/glob'` liegen, teils in einem Unterordner, verschiedene Dateien.

```
import glob
ordnerpfad = '01-daten/glob'

pfadliste = glob.glob(pathname = '*', root_dir = ordnerpfad, recursive = False)
print(pfadliste)
```

```
['hintergrund.png', 'Unterordner glob', 'Unfallorte2022_LinRef.csv', 'Unfallorte2020_LinRef.csv']
```

Das Argument `recursive` steuert, ob auch Unterordner durchsucht werden. Um auch Unterordner zu durchsuchen, muss es auf `True` gesetzt und im `pathname` `**` spezifiziert werden.

```
pfadliste = glob.glob(pathname = '**', root_dir = ordnerpfad, recursive = True)
print(pfadliste)
```

```
['hintergrund.png', 'Unterordner glob', 'Unterordner glob/Unfallorte2021_LinRef.csv', 'Unter
```

Im angegebenen Pfad '01-daten/glob' liegen die Dateien 'hintergrund.png', 'ToothGrowth.csv', 'Unfallorte2020_LinRef.csv', 'Unfallorte2022_LinRef.csv' sowie der Unterordner 'Unterordner glob'. In diesem Unterordner liegen die Dateien 'Unfallorte2021_LinRef.csv' und 'Unfallorte2023_LinRef.csv'.

Um die Suchergebnisse auf die Dateien 'Unfallorte2020_LinRef.csv', 'Unfallorte2021_LinRef.csv', 'Unfallorte2022_LinRef.csv' und 'Unfallorte2023_LinRef.csv' zu beschränken, muss der im Argument `pathname` übergebene Dateipfad angepasst werden. **Schauen Sie in die [Dokumentation des Moduls glob](#) und übergeben einen geeigneten Dateipfad.**

Tipp 23: Tipp und Musterlösung

Tipp: Die gesuchten Dateien beginnen mit dem Buchstaben 'U' und enden mit der Dateiendung '.csv'. Wie Sie Dateien aus einem Ordner und aus einem Unterordner auslesen, sehen Sie in der verlinkten Dokumentation unter Examples.

Tipp 5.1: Musterlösung glob

```
pfadliste = glob.glob(pathname = '**/U*.csv', root_dir = ordnerpfad, recursive = True)
print(pfadliste)
```

```
['Unfallorte2022_LinRef.csv', 'Unfallorte2020_LinRef.csv', 'Unterordner glob/Unfallort
```

Mit den Dateipfaden können die Dateien mit Hilfe einer Schleife in eine Liste eingelesen werden (aus Gründen der Lesbarkeit jeweils 3 Zeilen und 3 Spalten).

```
list_of_files = []
for pfad in pfadliste:
    zwischenspeicher = pd.read_csv(filepath_or_buffer = ordnerpfad + '/' + pfad,
    delimiter = ';', nrows = 3, usecols = [0, 1, 2])
    list_of_files.append(zwischenspeicher)
    print(pfad, "\n", zwischenspeicher, "\n")
```

Unfallorte2022_LinRef.csv

	OBJECTID	UIDENTSTLAE	ULAND
0	1	1220204125013262022	1

1	2	1220529134013152022	1
2	3	1220508125013982022	1

Unfallorte2020_LinRef.csv

	OBJECTID	UIDENTSTLAE	ULAND
0	1	12200116471201851100	12
1	2	12200106642131830700	12
2	3	12200109522101836720	12

Unterordner glob/Unfallorte2021_LinRef.csv

	OBJECTID	UIDENTSTLAE	ULAND
0	1	1210308125013512021	1
1	2	1210608134013112021	1
2	3	1210610181013902021	1

Unterordner glob/Unfallorte2023_LinRef.csv

	OID_	UIDENTSTLAE	ULAND
0	1	1230519134013042023	1
1	2	1230519134013022023	1
2	3	1230519125013522023	1

Aus der Liste können die Datensätze dann eigenen Objekten zugewiesen werden.

```
unfalldaten2020 = list_of_files[0]
unfalldaten2021 = list_of_files[2]
unfalldaten2022 = list_of_files[1]
unfalldaten2023 = list_of_files[3]

print(unfalldaten2020, "\n")
print(unfalldaten2020.dtypes)
```

	OBJECTID	UIDENTSTLAE	ULAND
0	1	1220204125013262022	1
1	2	1220529134013152022	1
2	3	1220508125013982022	1

```
OBJECTID      int64
UIDENTSTLAE   int64
ULAND         int64
dtype: object
```

Die Objekte könnten auch in einem DataFrame zusammengeführt werden.

- state.name
- state.region

Die Datensätze können in R durch Eingabe des Datensatznamens in der Konsole aufgerufen werden.

💡 Tipp 24: Musterlösung US State Facts and Figures

Mit dem Modul glob werden die Pfade der im Ordner liegenden Dateien in einer Liste gespeichert. In einer Schleife wird mit der Funktion `open()` jede Datei als Dateiojekt geöffnet, aus dem der Dateiname und der Dateiinhalt ausgelesen werden, um diese zu betrachten.

```
import os
ordnerpfad = "01-daten/glob leicht"
pfadliste = glob.glob(pathname = '*', root_dir = ordnerpfad, recursive = False)

list_of_files = []
names_of_files = []
for pfad in pfadliste:

    # Dateiojekt öffnen
    zwischenspeicher = open(ordnerpfad + '/' + pfad, 'r')

    # Dateinamen extrahieren
    name = os.path.basename(zwischenspeicher.name)
    names_of_files.append(name)

    # Datei auslesen
    datei = zwischenspeicher.read()
    list_of_files.append(datei)

    # Ausgabe
    print(name, "Encoding:", zwischenspeicher.encoding)
    print(datei[0:40], "\n")

    # Dateiojekt schließen
    zwischenspeicher.close()

print(f"Die Dateien heißen:\n{names_of_files}")
```

state abb.csv Encoding: UTF-8

```
"x"  
"1" "AL"  
"2" "AK"  
"3" "AZ"  
"4" "AR"
```

state area.csv Encoding: UTF-8

```
"x"  
"1" 51609  
"2" 589757  
"3" 113909  
"4"
```

state region.csv Encoding: UTF-8

```
"x"  
"1" "South"  
"2" "West"  
"3" "West"  
"4"
```

state name.csv Encoding: UTF-8

```
"x"  
"1" "Alabama"  
"2" "Alaska"  
"3" "Ariz"
```

Die Dateien heißen:

```
['state abb.csv', 'state area.csv', 'state region.csv', 'state name.csv']
```

Als nächstes werden die Daten in einem Datensatz 'states' gespeichert. Als Spaltennamen bieten sich die Dateinamen ohne Dateiendung an.

```

# Spaltennamen vorbereiten
i = 0
for name in names_of_files:
    names_of_files[i] = name[0:-4]
    i+= 1

# DataFrame erstellen
states = pd.DataFrame()
i = 0
list_of_files = []
for pfad in pfadliste:
    zwischenspeicher = open(ordnerpfad + '/' + pfad, 'r')
    states[i] = pd.read_csv(filepath_or_buffer = zwischenspeicher, sep = ' ', usecols = [1])
    zwischenspeicher.close()
    i+= 1

# Spaltennamen eintragen
states.columns = names_of_files

print(f"Es gibt die Regionen:\n{states['state region'].unique()}\n")

states.head()

```

Es gibt die Regionen:

['South' 'West' 'Northeast' 'North Central']

	state abb	state area	state region	state name
0	AL	51609	South	Alabama
1	AK	589757	West	Alaska
2	AZ	113909	West	Arizona
3	AR	53104	South	Arkansas
4	CA	158693	West	California

Im nächsten Schritt können die Anzahl der Staaten und die Fläche je Region bestimmt werden.

```
print(f"Die Anzahl der Staaten je Region beträgt:\n{states.groupby('state region')['state name'].count()}")
print(f"Die Fläche der Regionen beträgt:\n{states.groupby('state region')['state area'].sum()}")
```

Die Anzahl der Staaten je Region beträgt:

```
state region
North Central    12
Northeast         9
South            16
West             13
Name: state name, dtype: int64
```

Die Fläche der Regionen beträgt:

```
state region
North Central    765530
Northeast        169353
South            899556
West             1783960
Name: state area, dtype: int64
```

```
/tmp/ipykernel_4261/3346728540.py:2: FutureWarning: The provided callable <built-in function sum> is currently using np.sum. In a future version of pandas, the provided callable will be the builtin sum() function.
print(f"Die Fläche der Regionen beträgt:\n{states.groupby('state region')['state area'].sum()}")
```

Schwer: DSB Unfallatlas

Im Skript wurden bereits Daten aus dem DSB Unfallatlas eingelesen. Aus Gründen der Lesbarkeit wurden jedoch nur die ersten drei Zeilen und Spalten eingelesen. Für diese Aufgabe sollen nun die Dateien im Dateipfad '01-daten/glob schwer' vollständig eingelesen und zu einem Datensatz zusammengeführt werden. Ein Problem dabei ist, dass die Spaltenbeschriftungen für den Straßenzustand und die ID-Variable nicht einheitlich sind.

Unfallatlas Deutschland. von Statistische Ämter des Bundes und der Länder steht unter der Lizenz [CC BY 4.0](#) und ist verfügbar auf dem [Statistikportal des Bundes und der Länder](#). 2024

💡 Tipp 25: Musterlösung Unfallatlas

Das Erhebungsjahr ist eine Variable im Datensatz. Dennoch wird gezeigt, wie dieses aus dem Dateinamen ausgelesen werden kann.

Zuerst werden der Inhalt des Ordners und anschließend die Dateipfade ausgelesen.

```
# Inhalt Ordner auslesen
ordnerpfad = '01-daten/glob schwer'
pfadliste = glob.glob(pathname = '**', root_dir = ordnerpfad, recursive = True)
print(f"Im Suchpfad liegen {len(pfadliste)} Elemente. Die Bezeichnungen lauten:\n{pfadliste}")

# Dateipfade auslesen
pfadliste = glob.glob(pathname = '**/U*.csv', root_dir = ordnerpfad, recursive = True)
print(f"Im Suchpfad liegen {len(pfadliste)} CSV-Dateien. Die Dateinamen lauten:\n{pfadliste}")
```

Im Suchpfad liegen 6 Elemente. Die Bezeichnungen lauten:

```
['Unterordner glob', 'Unterordner glob/Unfallorte2021_LinRef.csv', 'Unterordner glob/Unfallorte2022_LinRef.csv']
```

Im Suchpfad liegen 4 CSV-Dateien. Die Dateinamen lauten:

```
['Unfallorte2022_LinRef.csv', 'Unfallorte2020_LinRef.csv', 'Unterordner glob/Unfallorte2021_LinRef.csv', 'Unterordner glob/Unfallorte2022_LinRef.csv']
```

Als nächstes werden die Jahreszahlen aus den Pfadnamen extrahiert sowie die Spaltennamen ausgelesen.

Um die Jahreszahlen aus den Dateinamen zu extrahieren, können die Zeichenketten manuell beschnitten werden (Die Jahreszahl steht an den Indexpositionen 10 bis exklusiv 14). Alternativ kann ein regulärer Ausdruck verwendet werden. Reguläre Ausdrücke werden mit dem Modul `re` verarbeitet. Die Funktion `re.search(string = x, pattern = '[0-9]+')` sucht im Objekt `x` nach dem im Argument `pattern` spezifizierten Ausdruck, hier nach einer Zahl von 0 bis 9 `[0-9]` und jeder darauf folgenden Zahl `+`. Die Funktion `re.search()` erzeugt ein Match-Objekt, dessen Inhalt mit der Methode `Match.group()` ausgegeben werden kann, die einen string zurückgibt. (siehe [Dokumentation Modul re](#))

Um die Spaltennamen auszulesen, wird die Funktion `pd.read_csv()` mit den Argumenten `nrows = 1`, `header = 0` angewiesen, die erste Zeile auszulesen. Anschließend können die Spaltennamen visuell abgeglichen werden - dies ist im Reiter DataFrame der Spaltennamen umgesetzt. Für größere Datensätze ist dies aber nicht mehr praktikabel. Eine algorithmische Lösung ist im Reiter Spaltennamen finden umgesetzt. Dazu wird jede Spalte des DataFrames gegen alle anderen Spalten mit der Methode `pd.Series.isin(df)` abgeglichen.

5.2 Jahreszahlen und Spaltennamen auslesen

```
# Die Jahreszahlen auslesen
import re

jahreszahlen = []
for pfad in pfadliste:
    zwischenspeicher = re.search(string = pfad, pattern = '[0-9]+').group()
    jahreszahlen.append(int(zwischenspeicher))

print(f"Aus den Dateinamen extrahierte Jahreszahlen:\t{jahreszahlen}\n")

# Spaltennamen durch Einlesen der ersten Zeile extrahieren, header = None
i = 0
list_of_columns = []
for pfad in pfadliste:

    zwischenspeicher = pd.read_csv(filepath_or_buffer = ordnerpfad + '/' + pfad,
    delimiter = ';', nrows = 1, header = None).transpose()

    list_of_columns.append(zwischenspeicher)
    i += 1

df_of_columns = pd.concat(list_of_columns, axis = 1, ignore_index = True)
df_of_columns.columns = jahreszahlen
```

Aus den Dateinamen extrahierte Jahreszahlen: [2022, 2020, 2021, 2023]

Die Spaltennamen werden im nächsten Reiter ausgegeben.

5.3 DataFrame der Spaltennamen

Mit der Ausgabe des DataFrames können die ungleichen Spaltennamen visuell identifiziert werden.

```
print(f"Ein DataFrame der Spaltennamen:\n{df_of_columns}")
```

Ein DataFrame der Spaltennamen:

	2022	2020	2021	2023
0	OBJECTID	OBJECTID	OBJECTID	OID_
1	UIDENTSTLAE	UIDENTSTLAE	UIDENTSTLAE	UIDENTSTLAE

2	ULAND	ULAND	ULAND	ULAND
3	UREGBEZ	UREGBEZ	UREGBEZ	UREGBEZ
4	UKREIS	UKREIS	UKREIS	UKREIS
5	UGEMEINDE	UGEMEINDE	UGEMEINDE	UGEMEINDE
6	UJAHR	UJAHR	UJAHR	UJAHR
7	UMONAT	UMONAT	UMONAT	UMONAT
8	USTUNDE	USTUNDE	USTUNDE	USTUNDE
9	UWOCHENTAG	UWOCHENTAG	UWOCHENTAG	UWOCHENTAG
10	UKATEGORIE	UKATEGORIE	UKATEGORIE	UKATEGORIE
11	UART	UART	UART	UART
12	UTYP1	UTYP1	UTYP1	UTYP1
13	ULICHTVERH	ULICHTVERH	ULICHTVERH	ULICHTVERH
14	IstStrassenzustand	IstRad	USTRZUSTAND	IstStrassenzustand
15	IstRad	IstPKW	IstRad	IstRad
16	IstPKW	IstFuss	IstPKW	IstPKW
17	IstFuss	IstKrad	IstFuss	IstFuss
18	IstKrad	IstGkfz	IstKrad	IstKrad
19	IstGkfz	IstSonstige	IstGkfz	IstGkfz
20	IstSonstige	LINREFX	IstSonstige	IstSonstige
21	LINREFX	LINREFY	LINREFX	LINREFX
22	LINREFY	XGCSWGS84	LINREFY	LINREFY
23	XGCSWGS84	YGCSWGS84	XGCSWGS84	XGCSWGS84
24	YGCSWGS84	STRZUSTAND	YGCSWGS84	YGCSWGS84
25	NaN	NaN	NaN	PLST

5.4 Spaltennamen finden

Der Abgleich der ungleichen Spaltennamen kann auch algorithmisch gelöst werden.

```
# Spaltennamen algorithmisch abgleichen
ungleiche_spaltennamen = pd.Series()

## vergleiche jede Spalte gegen alle anderen Spalten
for i in range(0, df_of_columns.shape[1]):

    aktuelle_spalte = df_of_columns.iloc[:, i]

    vergleichs_df = df_of_columns.drop(df_of_columns.columns[i], axis = 1)

    j = 0
    for vergleichsspalte in vergleichs_df: # vergleichsspalte ist der Spaltenname (als int) 2

        # print(vergleichsspalte)
        maske_ fehlender_spaltennamen = aktuelle_spalte.isin(vergleichs_df.loc[:, vergleichsspalte])
        maske_ fehlender_spaltennamen = np.invert(maske_ fehlender_spaltennamen) # pandas hat kein not

        # WENN Spaltennamen fehlen DANN
        if maske_ fehlender_spaltennamen.sum() > 0:

            print(f"In den Unfalldaten {df_of_columns.columns[i]} treten die Spaltennamen {aktuelle_spalte} auf")

            ungleiche_spaltennamen = pd.concat([ungleiche_spaltennamen, pd.Series(aktuelle_spalte, index=aktuelle_spalte.index)])

        j +=1

ungleiche_spaltennamen = ungleiche_spaltennamen.dropna().unique()

print(f"Folgende Spaltennamen müssen vereinheitlicht werden:\n{ungleiche_spaltennamen}")
```

```
In den Unfalldaten 2022 treten die Spaltennamen ['IstStrassenzustand'] auf, die nicht in de
In den Unfalldaten 2022 treten die Spaltennamen ['IstStrassenzustand'] auf, die nicht in de
In den Unfalldaten 2022 treten die Spaltennamen ['OBJECTID' nan] auf, die nicht in den Unfa
In den Unfalldaten 2020 treten die Spaltennamen ['STRZUSTAND'] auf, die nicht in den Unfall
In den Unfalldaten 2020 treten die Spaltennamen ['STRZUSTAND'] auf, die nicht in den Unfall
In den Unfalldaten 2020 treten die Spaltennamen ['OBJECTID' 'STRZUSTAND' nan] auf, die nicht
```

In den Unfalldaten 2021 treten die Spaltennamen ['USTRZUSTAND'] auf, die nicht in den Unfalldaten 2023

In den Unfalldaten 2021 treten die Spaltennamen ['USTRZUSTAND'] auf, die nicht in den Unfalldaten 2023

In den Unfalldaten 2021 treten die Spaltennamen ['OBJECTID' 'USTRZUSTAND' nan] auf, die nicht in den Unfalldaten 2023

In den Unfalldaten 2023 treten die Spaltennamen ['OID_' 'PLST'] auf, die nicht in den Unfalldaten 2021

In den Unfalldaten 2023 treten die Spaltennamen ['OID_' 'IstStrassenzustand' 'PLST'] auf, die nicht in den Unfalldaten 2021

In den Unfalldaten 2023 treten die Spaltennamen ['OID_' 'IstStrassenzustand' 'PLST'] auf, die nicht in den Unfalldaten 2021

Folgende Spaltennamen müssen vereinheitlicht werden:

```
['IstStrassenzustand' 'OBJECTID' 'STRZUSTAND' 'USTRZUSTAND' 'OID_' 'PLST']
```

Die Spaltennamen 'STRZUSTAND', 'IstStrassenzustand' und 'USTRZUSTAND' sowie 'OBJECTID', und 'OID_' müssen beim Einlesen der Daten vereinheitlicht werden. Die Spalte 'PLST' wurde nur im Jahr 2023 erhoben und kann entfallen (siehe Unfallatlas Metadaten). Dafür wird der Methode `pd.DataFrame.drop()` das Argument `errors = 'ignore'` übergeben, da in einem Datensatz nicht vorhandene Spalten andernfalls zu einer Fehlermeldung führen.

Die Spalte 'UIDENTSTLAE' enthält sehr große Ganzzahlen, weshalb diese als String eingelesen wird.

```

## Dateien einlesen
unfallatlas = pd.DataFrame()

for pfad in pfadliste:

    ### Datei einlesen
    zwischenspeicher = pd.read_csv(filepath_or_buffer = ordnerpfad + '/' + pfad,
    delimiter = ';', dtype = {'UIDENTSTLAE': 'string'})

    ### Spaltennamen vereinheitlichen
    zwischenspeicher.rename(columns = {"IstStrassenzustand": "STRZUSTAND", "USTRZUSTAND": "STRZUSTAND"},
    zwischenspeicher.drop(columns = "PLST", inplace = True, errors = 'ignore')

    unfallatlas = pd.concat([unfallatlas, zwischenspeicher])

# Ausgabe
print(unfallatlas.info(), "\n")
unfallatlas.head()

```

```

<class 'pandas.core.frame.DataFrame'>
Index: 996742 entries, 0 to 269047
Data columns (total 25 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   OBJECTID              996742 non-null  int64
1   UIDENTSTLAE           996742 non-null  string
2   ULAND                 996742 non-null  int64
3   UREGBEZ               996742 non-null  int64
4   UKREIS                996742 non-null  int64
5   UGEMEINDE             996742 non-null  int64
6   UJAHR                 996742 non-null  int64
7   UMONAT                996742 non-null  int64
8   USTUNDE               996742 non-null  int64
9   UWOCHENTAG            996742 non-null  int64
10  UKATEGORIE            996742 non-null  int64
11  UART                  996742 non-null  int64
12  UTYP1                 996742 non-null  int64
13  ULICHTVERH            996742 non-null  int64
14  STRZUSTAND            996742 non-null  int64
15  IstRad                996742 non-null  int64
16  IstPKW                996742 non-null  int64
17  IstFuss               996742 non-null  int64

```

```

18 IstKrad      996742 non-null int64
19 IstGkfz     996742 non-null int64
20 IstSonstige 996742 non-null int64
21 LINREFX     996742 non-null object
22 LINREFY     996742 non-null object
23 XGCSWGS84   996742 non-null object
24 YGCSWGS84   996742 non-null object
dtypes: int64(20), object(4), string(1)
memory usage: 197.7+ MB
None

```

	OBJECTID	UIDENTSTLAE	ULAND	UREGBEZ	UKREIS	UGEMEINDE	UJAHR	U
0	1	01220204125013262022	1	0	54	84	2022	2
1	2	01220529134013152022	1	0	57	44	2022	5
2	3	01220508125013982022	1	0	59	73	2022	5
3	4	01220517152013752022	1	0	3	0	2022	5
4	5	01220426181013142022	1	0	61	46	2022	4

Abschließend kann der Datensatz aufgeräumt werden:

- der Datensatz wird nach dem Jahr sortiert (wichtig: als erstes ausführen),
- der Index wird zurückgesetzt (wichtig: als zweites),
- die Spalte 'OBJECTID' wird neu erstellt, um die beim Einlesen erzeugten Duplikate zu entfernen und

```
# Datensatz nach Jahr sortieren
unfallatlas.sort_values(by = 'UJAHR', inplace = True)

# Index zurücksetzen
unfallatlas.reset_index(drop = True, inplace = True)

# Spalte 'OBJECTID' neu generieren
unfallatlas['OBJECTID'] = pd.Series(range(1, unfallatlas.shape[0] + 1))

print(unfallatlas.info(), "\n")
unfallatlas.head()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 996742 entries, 0 to 996741
Data columns (total 25 columns):
#   Column          Non-Null Count  Dtype
---  -
0   OBJECTID        996742 non-null  int64
1   UIDENTSTLAE     996742 non-null  string
2   ULAND           996742 non-null  int64
3   UREGBEZ         996742 non-null  int64
4   UKREIS          996742 non-null  int64
5   UGEMEINDE       996742 non-null  int64
6   UJAHR           996742 non-null  int64
7   UMONAT          996742 non-null  int64
8   USTUNDE         996742 non-null  int64
9   UWOCHENTAG      996742 non-null  int64
10  UKATEGORIE      996742 non-null  int64
11  UART            996742 non-null  int64
12  UTYP1           996742 non-null  int64
13  ULICHTVERH      996742 non-null  int64
14  STRZUSTAND      996742 non-null  int64
15  IstRad          996742 non-null  int64
```

```

16 IstPKW      996742 non-null int64
17 IstFuss     996742 non-null int64
18 IstKrad     996742 non-null int64
19 IstGkfz     996742 non-null int64
20 IstSonstige 996742 non-null int64
21 LINREFX     996742 non-null object
22 LINREFY     996742 non-null object
23 XGCSWGS84   996742 non-null object
24 YGCSWGS84   996742 non-null object
dtypes: int64(20), object(4), string(1)
memory usage: 190.1+ MB
None

```

	OBJECTID	UIDENTSTLAE	ULAND	UREGBEZ	UKREIS	UGEMEINDE	UJAHR	U
0	1	16200531001309353040	16	0	56	0	2020	5
1	2	16200429001105316570	16	0	51	0	2020	4
2	3	16200526001105353500	16	0	51	0	2020	5
3	4	16200609001208367470	16	0	77	1	2020	6
4	5	16200526001105353850	16	0	51	0	2020	5

6 Maskierte Arrays

Maskierte Arrays sind eine Erweiterung für NumPy, um Probleme mit fehlenden Werten insbesondere bei Ganzzahlen zu umgehen.

“**nan**, short for ‘not a number’ [...] was specifically designed to address the problem of missing values, but the reality is that different platforms behave differently, making life more difficult. On some platforms, the presence of **nan** slows calculations 10-100 times. For integer data, no **nan** value exists. [...] Those wishing to avoid potential headaches will be interested in an alternative solution which has a long history in NumPy’s predecessors – **masked arrays**. [...] Despite their additional memory requirement, masked arrays are faster than nans on many floating point units.” (SciPy.org Frequently Asked Questions, Zugriff via [waybackmachine](#))

```
# Fehlende Werte für Ganzzahlen sind in Pandas kein Problem
print("Eine pd.Series vom dtype Int64 mit einem fehlenden Wert:")
print(pd.Series([0, 1, np.nan], dtype = 'Int64'), "\n")

# In NumPy ist das anders
try:
    np.array([0, 1, np.nan], dtype = 'int')
except ValueError as error:
    print("Da np.nan vom Datentyp float ist, haben Integer-Arrays keinen fehlenden Wert.\n Die
else:
    np.array([0, 1, np.nan], dtype = 'int')

print(f"Die Ursache ist der Datentyp von nan: type(np.nan)\n{type(np.nan)}\n")
```

```
Eine pd.Series vom dtype Int64 mit einem fehlenden Wert:
0      0
1      1
2    <NA>
dtype: Int64
```

Da np.nan vom Datentyp float ist, haben Integer-Arrays keinen fehlenden Wert.

Die Eingabe `np.array([0, 1, np.nan], dtype = 'int')` führt zu der Fehlermeldung:
`cannot convert float NaN to integer`
Die Ursache ist der Datentyp von `nan`: `type(np.nan)`
`<class 'float'>`

Maskierte Arrays (masked arrays) werden durch das Modul `numpy.ma` bereitgestellt und erlauben es, Werte als ungültig oder fehlend zu markieren, ohne diese zu ersetzen oder zu löschen. Ein maskiertes Array besteht aus drei Elementen:

1. einem normalen NumPy-Array, das die Daten enthält.
2. einer Maske, die entweder den Wert `numpy.ma.nomask` hat, wenn kein Wert ungültig ist oder fehlt, oder aus einem NumPy-Array mit Wahrheitswerten für jedes Element des datentragenden NumPy-Arrays besteht: `True` kennzeichnet einen ungültigen/fehlenden Wert, `False` einen gültigen Wert.
3. dem Füllwert, mit dem in der Maske mit `True` markierte Werte ersetzt werden. Standardmäßig ist dies die Zeichenkette `--`.

Über die Attribute `.data` und `.mask` kann auf das zugrundeliegende NumPy-Array und die Maske zugegriffen werden. Ebenfalls können die Funktionen `ma.getmask(maskiertes_array)` und `ma.getdata(maskiertes_array)` genutzt werden. Der Füllwert wird mit der Methode `maskiertes_array.filled()` eingesetzt. Dies gibt eine Kopie des datentragenden Arrays zurück, die Daten selbst bleiben unverändert.

```
import numpy.ma as ma

maskiertes_array = ma.masked_array(data = np.array([1, 2, 3, 4]), mask = [0, 0, 1, 1])
print(f"maskiertes Array:\t{maskiertes_array}")

print(f"Daten:\t\t\t\t{maskiertes_array.data}")

print(f"Maske:\t\t\t\t{maskiertes_array.mask}")

print(f"Zugriff über Funktionen ma.getdata() und ma.getmask():\n{ma.getdata(maskiertes_array)}")

print(f"gefülltes Array:\t\t\t\t{maskiertes_array.filled()}")

print(f"Das maskierte Array bleibt unverändert: {maskiertes_array}")
```

```
maskiertes Array:  [1 2 -- --]
Daten:             [1 2 3 4]
Maske:             [False False  True  True]
```

Zugriff über Funktionen `ma.getdata()` und `ma.getmask()`:
(`array([1, 2, 3, 4])`, `array([False, False, True, True])`)

gefülltes Array: [1 2 999999 999999]
Das maskierte Array bleibt unverändert: [1 2 -- --]

Der Standardfüllwert ist abhängig vom Datentyp des NumPy-Arrays.

Datentyp	Standardfüllwert
bool	True
int	999999
float	1.e20
complex	1.e20+0j
object	'?'
string	'N/A'

Der Standardfüllwert kann mit der Funktion `np.ma.default_fill_value()` ausgegeben werden.

```
print(np.ma.default_fill_value(1))  
print(np.ma.default_fill_value('1'))
```

999999
N/A

([NumPy Dokumentation](#))

Der Füllwert kann über das Attribut `maskiertes_array.fill_value` geändert werden. Die Übergabe von `maskiertes_array.fill_value = None` setzt den Füllwert auf den Standardwert zurück.

```
# Anlegen eines maskierten Arrays vom Datentyp Integer mit einem ganzzahligen Füllwert  
maskiertes_array = ma.masked_array(data = np.arange(0, 4), mask = [0, 0, 1, 1], fill_value =  
  
print(f"Gefülltes Array vom Datentyp integer mit ganzzahligem Füllwert:\n{maskiertes_array.f  
  
# Ändern des Füllwerts mit Datentyp float  
maskiertes_array.fill_value = 1.5  
print(f"Wird einem maskierten Array vom Datentyp integer ein Füllwert vom Datentyp float über
```

```

print(f"Wird einem maskierten Array vom Datentyp integer ein Füllwert vom Datentyp string übergeben,")

try:
    maskiertes_array.fill_value = '1.5'
    print(maskiertes_array.filled())
except TypeError as error:
    print(error)
else:
    maskiertes_array.fill_value = '1.5'
    print(maskiertes_array.filled())

# Füllwert None
maskiertes_array.fill_value = None
print(f"\nDer Füllwert None bewirkt den Rückgriff auf einen datentypabhängigen Standardwert:")

```

Gefülltes Array vom Datentyp integer mit ganzzahligem Füllwert:

```
[ 0  1 42 42]
```

Wird einem maskierten Array vom Datentyp integer ein Füllwert vom Datentyp float übergeben, wird nur der ganzzahlige Teil eingesetzt:

```
[0 1 1 1]
```

Wird einem maskierten Array vom Datentyp integer ein Füllwert vom Datentyp string übergeben, folgt eine Fehlermeldung:

```
Cannot set fill value of string with array of dtype int64
```

Der Füllwert None bewirkt den Rückgriff auf einen datentypabhängigen Standardwert:

```
[      0      1 999999 999999]
```

6.1 Maskierte Arrays erzeugen

Maskierte Arrays können auf zahlreichen Wegen erzeugt werden. Eine vollständige Übersicht erhalten Sie in der [Dokumentation](#).

```

a = np.array([1, 10, 100, 1000])

print(f"Die Methode ma.asanyarray(array, dtype = ) legt den Datentyp des maskierten Arrays fest.")
print(f"ma.asanyarray(a, dtype = 'float64'):\n")
print(f"{ma.asanyarray(a, dtype = 'float64')}\n")

```

```

print(f"Die Methode ma.masked_equal(x = array, value) maskiert alle Werte value.\n"
      f"ma.masked_equal(a, 100):\n"
      f"{ma.masked_equal(a, 100)}\n")

print(f"Die Methode ma.masked_greater(x = array, value) maskiert alle Werte größer als value.\n"
      f"ma.masked_greater(a, 100):\n"
      f"{ma.masked_greater(a, 100)}\n")

print(f"Die Methode ma.masked_inside(x = array, v1, v2) maskiert alle Werte im Intervall v1 bis v2.\n"
      f"ma.masked_inside(a, 5, 100):\n"
      f"{ma.masked_inside(a, 5, 100)}\n")

print(f"Die Methode ma.masked_where(condition, a = array) maskiert alle Werte, für die die Bedingung condition erfüllt ist.\n"
      f"ma.masked_where(a % 2 != 0, a):\n"
      f"{ma.masked_where(a % 2 != 0, a)}\n")

```

Die Methode `ma.asanyarray(array, dtype = )` legt den Datentyp des maskierten Arrays fest.

`ma.asanyarray(a, dtype = 'float64'):`

```
[ 1.  10. 100. 1000.]
```

Die Methode `ma.masked_equal(x = array, value)` maskiert alle Werte `value`.

`ma.masked_equal(a, 100):`

```
[1 10 -- 1000]
```

Die Methode `ma.masked_greater(x = array, value)` maskiert alle Werte größer als `value`.

`ma.masked_greater(a, 100):`

```
[1 10 100 --]
```

Die Methode `ma.masked_inside(x = array, v1, v2)` maskiert alle Werte im Intervall `v1` bis `v2`.

`ma.masked_inside(a, 5, 100):`

```
[1 -- -- 1000]
```

Die Methode `ma.masked_where(condition, a = array)` maskiert alle Werte, für die die Bedingung `condition` erfüllt ist.

`ma.masked_where(a % 2 != 0, a):`

```
[-- 10 100 1000]
```

Die NumPy-Funktion `genfromtxt(usemask = True)` erzeugt mit dem entsprechenden Argument ein maskiertes Array.

```
dateipfad = '01-daten/TC01_double_hyphen.csv'
daten_double_hyphen = np.genfromtxt(dateipfad, missing_values = '--', usemask = True)
daten_double_hyphen
```

```
masked_array(data=[20.1, --, 20.1, ..., 24.3, 24.2, 24.2],
             mask=[False,  True, False, ..., False, False, False],
             fill_value=1e+20)
```

Eine weitere Möglichkeit, Arraybereiche zu maskieren, ist es, einzelnen Werten oder einem Wertebereich eines maskierten Arrays den Wert `ma.masked` zuzuweisen.

```
maskiertes_array = ma.masked_array([1, 2, 3, 4])

maskiertes_array[1] = ma.masked
print(maskiertes_array)

maskiertes_array[1:3] = ma.masked
print(maskiertes_array)
```

```
[1 -- 3 4]
[1 -- -- 4]
```

6.2 Übung maskierte Arrays erzeugen

Gegeben sei das NumPy-Array `np.linspace(1, 1000, 18, dtype = 'int')`. **Erzeugen Sie mit dem NumPy-Array ein maskiertes Array.**

- Maskieren Sie jeden Wert im Intervall 250 bis 750. Wie viele Werte sind maskiert?
- Maskieren Sie jeden zweiten Wert. Wie lautet die Summe des maskierten Arrays?
- Maskieren Sie jeden geraden Wert.
- Maskieren Sie jeden Wert, der mindestens 3 Stellen hat.

💡 Tipp 26: Musterlösung maskierte Arrays erzeugen

```
# Array erzeugen
a = np.linspace(1, 1000, 18, dtype = 'int')

# Maske im Intervall 250-750
my_ma = ma.masked_inside(x = a, v1 = 250, v2 = 750)
print("Maske im Intervall 250-750:")
print(my_ma, "Anzahl maskierter Werte:", my_ma.mask.sum(), "\n")

# jeder 2. Wert maskiert
my_ma = ma.masked_array(a)
my_ma[::2] = ma.masked
print("Jeder 2. Wert maskiert:")
print(my_ma, "Summe nicht maskierter Werte:", my_ma.sum(), "\n")

# jeder gerade Wert maskiert
my_ma = ma.masked_where(a % 2 == 0, a)
print("Jeder gerade Wert maskiert:")
print(my_ma, "\n")

# jeder mindestens dreistellige Wert maskiert
my_ma = ma.masked_where(a / 100 >= 1, a)
print("Jeder mindestens dreistellige Wert maskiert:")
print(my_ma)

## eine Alternative
my_mask = [len(str(i)) >= 3 for i in a]
print(f"ma.masked_array(data = a, mask = my_mask")
```

Maske im Intervall 250-750:

[1 59 118 177 236 -- -- -- -- -- -- -- -- 764 823 882 941 1000] Anzahl maskierter Werte: 8

Jeder 2. Wert maskiert:

[-- 59 -- 177 -- 294 -- 412 -- 529 -- 647 -- 764 -- 882 -- 1000] Summe nicht maskierter Werte: 3530

Jeder gerade Wert maskiert:

[1 59 -- 177 -- -- 353 -- 471 529 -- 647 -- -- 823 -- 941 --]

Jeder mindestens dreistellige Wert maskiert:

[1 59 -- -- -- -- -- -- -- -- -- -- -- -- --]

ma.masked_array(data = a, mask = my_mask)

6.3 unmasking, soft und hard masks

Ein maskiertes Array kann auf verschiedene Weise demaskiert werden.

```
unmask_me = my_ma.copy()
unmask_me.mask = ma.nomask
print(f"Die Maske kann auf ma.nomask oder False gesetzt werden.\n"
      f"unmask_me.mask = ma.nomask: {unmask_me}\n")

unmask_me = my_ma.copy()
unmask_me.mask = False
print(f"unmask_me.mask = False: {unmask_me}\n")

unmask_me = my_ma.copy()
unmask_me = np.linspace(1, 1000, 18, dtype = 'int')
print(f"Die Maskierung wird auch durch eine Wertzuweisung aufgehoben.\nDas Objekt wird neu a
print(f"unmask_me = np.linspace(1, 1000, 18, dtype = 'int'):\n"
      f"{unmask_me}\n")
```

Die Maske kann auf ma.nomask oder False gesetzt werden.

```
unmask_me.mask = ma.nomask: [1 59 118 177 236 294 353 412 471 529 588 647 706 764 823 882 941 1000]
```

```
unmask_me.mask = False: [1 59 118 177 236 294 353 412 471 529 588 647 706 764 823 882 941 1000]
```

Die Maskierung wird auch durch eine Wertzuweisung aufgehoben.

Das Objekt wird neu angelegt.

```
unmask_me = np.linspace(1, 1000, 18, dtype = 'int'):
[   1   59  118  177  236  294  353  412  471  529  588  647  706  764
  823  882  941 1000]
```

Die Demaskierung ist auch für Indexbereiche möglich.

```
unmask_me = my_ma.copy()
unmask_me[6:10].mask = ma.nomask
print(f"Die Maske kann auf ma.nomask oder False gesetzt werden.\n"
      f"unmask_me[6:10].mask = ma.nomask: {unmask_me}\n")

unmask_me = my_ma.copy()
unmask_me[6:10].mask = False
print(f"unmask_me[6:10].mask = False: {unmask_me}\n")
```

```

unmask_me = my_ma.copy()
unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int')
print(f"Die Maskierung wird auch durch eine Wertzuweisung aufgehoben.")
print(f"unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int'):\n"
      f"{unmask_me}\n")

```

Die Maske kann auf `ma.nomask` oder `False` gesetzt werden.

```

unmask_me[6:10].mask = ma.nomask: [1 59 -- -- -- -- 353 412 471 529 -- -- -- -- -- -- -- --
]

```

```

unmask_me[6:10].mask = False: [1 59 -- -- -- -- 353 412 471 529 -- -- -- -- -- -- -- --
]

```

Die Maskierung wird auch durch eine Wertzuweisung aufgehoben.

```

unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int'):
[1 59 -- -- -- -- 1 334 667 1000 -- -- -- -- -- -- -- --]

```

Insbesondere die Demaskierung durch eine Wertzuweisung in einem Indexbereich kann ein unerwünschtes Verhalten sein.

soft und hard masks

Die Maske eines maskierten Arrays ist eine veränderliche, sogenannte soft mask. Um die Maske vor Änderungen zu schützen, kann die Maske mit dem Argument `ma.array(data = [data], mask = [mask], hard_mask = True)` oder mit der Methode `masked_array.harden_mask()` in eine hard mask verwandelt werden.

```

unmask_me = my_ma.copy()
unmask_me.harden_mask()
unmask_me.mask = ma.nomask
print(f"Die hard mask wird auf ma.nomask gesetzt.\n"
      f"unmask_me.mask = ma.nomask: {unmask_me}\n")

unmask_me.mask = False
print(f"unmask_me.mask = False: {unmask_me}\n")

unmask_me = np.linspace(1, 1000, 18, dtype = 'int')
print(f"Die hard mask wird dennoch durch eine Wertzuweisung aufgehoben.\nDas Objekt wird neu")
print(f"unmask_me = np.linspace(1, 1000, 18, dtype = 'int'):\n"
      f"{unmask_me}\n")

```

```
unmask_me.mask = ma.nomask: [1 59 -- -- -- -- -- -- -- -- -- -- -- -- -- -- -- ]
```

```
unmask_me.mask = False: [1 59 -- -- -- -- -- -- -- -- -- -- -- -- -- -- -- -- ]
```

```
unmask_me = np.linspace(1, 1000, 18, dtype = 'int'):
[   1   59  118  177  236  294  353  412  471  529  588  647  706  764
   823  882  941 1000]
```

```
unmask_me = my_ma.copy()
unmask_me.harden_mask()
unmask_me[6:10].mask = ma.nomask
print(f"Die hard mask wird auf ma.nomask gesetzt.\n"
      f"unmask_me.mask[6:10] = ma.nomask: {unmask_me}\n")

unmask_me[6:10].mask = False
print(f"unmask_me[6:10].mask = False: {unmask_me}\n")

unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int')
print(f"Die hard mask wird nicht (!) durch eine Wertzuweisung im Indexbereich aufgehoben.")
print(f"unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int'):\n"
      f"{unmask_me}\n")
```

```
unmask_me.mask[6:10] = ma.nomask: [1 59 -- -- -- -- -- -- -- -- -- -- -- ]
```

```
unmask_me[6:10].mask = False: [1 59 -- -- -- -- -- -- -- -- -- -- -- -- -- -- -- ]
```

```
unmask_me[6:10] = np.linspace(1, 1000, 4, dtype = 'int'):
```

```
[1 59 -- -- -- -- -- -- -- -- -- -- -- -- -- -- --]
```

148

```
unmask_me[0:2] = ma.masked
print(f"Die Maskierungen zusätzlicher Elemente ist mit einer hard mask möglich.\n"
      f"{unmask_me}")
```

Die Maskierungen zusätzlicher Elemente ist mit einer hard mask möglich.
 [-- -- -- -- -- -- -- -- -- -- -- -- -- -- -- --]

Eine hard mask kann mit der Methode `masked_array.soften_mask()` aufgehoben werden.

```
unmask_me.soften_mask()
unmask_me.mask = ma.nomask
print(f"{unmask_me}")
```

[1 59 118 177 236 294 353 412 471 529 588 647 706 764 823 882 941 1000]

([NumPy Dokumentation](#))

6.4 Operationen mit maskierten Arrays

Arithmetische und vergleichende Operationen mit maskierten Arrays werden nicht auf die maskierten Elemente angewendet.

<https://numpy.org/doc/stable/reference/maskedarray.generic.html#operations-on-masked-arrays>

<https://numpy.org/doc/2.1/reference/routines.ma.html>

```
# Array erzeugen
a = np.linspace(1, 1000, 18, dtype = 'int')
maskiertes_array = ma.masked_array(a)
maskiertes_array[0:2] = ma.masked

# Ausgewählte Operationen
print(f"Summe maskiertes_array: {maskiertes_array.sum()}\tSumme maskiertes_array.data: {maskiertes_array.data.sum()}")
print(f"maskiertes_array > 222:\n{maskiertes_array > 222}")
```

Summe maskiertes_array: 4764 Summe maskiertes_array.data: 9001
 maskiertes_array > 222:
 [-- False -- False -- True -- True -- True -- True -- True -- True -- True]

Arithmetische und vergleichende Operationen mit maskierten Elementen führen immer zu maskierten Ergebnissen.

```
print("NumPy ist bei Operationen mit np.nan nicht konsistent.")
print(f"np.nan ** 0:\t{np.nan ** 0}")
print(f"1 ** np.nan:\t{1 ** np.nan}")
print(f"np.nan == np.nan:\t{np.nan == np.nan}\n")

print("Maskierte Arrays verhalten sich dagegen konsistent.")
print(f"maskiertes_array[0] ** 0:\t\t\t\t\t{maskiertes_array[0] ** 0}")
print(f"1 ** maskiertes_array[0]:\t\t\t\t\t\t\t{1 ** maskiertes_array[0]}")
print(f"maskiertes_array[0] == maskiertes_array[2]:\t{maskiertes_array[0] == maskiertes_array[2]}")
print(f"maskiertes_array[0] == np.nan:\t\t\t\t\t{maskiertes_array[0] == np.nan}")
```

```
NumPy ist bei Operationen mit np.nan nicht konsistent.
np.nan ** 0:      1.0
1 ** np.nan:     1.0
np.nan == np.nan: False
```

```
Maskierte Arrays verhalten sich dagegen konsistent.
maskiertes_array[0] ** 0:      --
1 ** maskiertes_array[0]:     --
maskiertes_array[0] == maskiertes_array[2]: --
maskiertes_array[0] == np.nan:  --
```

Das Modul `numpy.ma` implementiert die meisten NumPy-Funktionen (siehe [NumPy Dokumentation](#)). Funktionen, die nur einen bestimmten Wertebereich als Eingabe akzeptieren, geben den Wert `masked` zurück, wenn Werte außerhalb des gültigen Bereichs übergeben werden. Ein Beispiel ist die Funktion `ma.log()`.

```
ma.log([-1, 0, 1, 2])
```

```
masked_array(data=[--, --, 0.0, 0.6931471805599453],
             mask=[ True,  True, False, False],
             fill_value=1e+20)
```

Auch Operation mit mehreren Arrays sind möglich. Im Ergebnis ist jedes in der Eingabe maskierte Element ebenfalls maskiert.

```
print(a + maskiertes_array)
print(np.logical_or(a, maskiertes_array))
```

```
[-- 118 -- 354 -- 588 -- 824 -- 1058 -- 1294 -- 1528 -- 1764 -- 2000]
[-- True -- True -- True -- True -- True -- True -- True -- True -- True]
```

Zusammenfassende Funktionen wie `len()` oder `ma.unique(masked_array)` werden auch auf die maskierten Elemente angewendet.

```
# Ausgewählte Operationen
print(len(maskiertes_array))
print(ma.unique(maskiertes_array))
```

```
18
[59 177 294 412 529 647 764 882 1000 --]
```

Warning 7: Warnhinweis maskierte Arrays

Die Dokumentation warnt, dass maskierte Werte nicht zuverlässig von Operationen ausgenommen sind. Welche Operationen dies betrifft, ist nicht angegeben.

“Arithmetic and comparison operations are supported by masked arrays. As much as possible, invalid entries of a masked array are not processed, meaning that the corresponding **data** entries *should* be the same before and after the operation.

Warning

We need to stress that this behavior may not be systematic, that masked data may be affected by the operation in some cases and therefore users should not rely on this data remaining unchanged.”

<https://numpy.org/doc/stable/reference/maskedarray.generic.html#operations-on-masked-arrays>

6.5 Übungen Operationen mit maskierten Arrays

1. Erstellen Sie ein zweidimensionales Array (10x10) der Zahlen 1 bis 100. Maskieren Sie alle ungeraden Werte, die ganzzahlig durch 3 teilbar sind.
2. Berechnen Sie anschließend die Summe der maskierten und die Summe der unmaskierten Werte.

3. Setzen sie die Maske zurück, sodass keine Werte mehr maskiert sind.
4. Primzahlensieb: Maskieren Sie alle Elemente, die den Wert 1 haben oder Vielfache von Primzahlen sind, bis das gefüllte Array nur noch aus Primzahlen besteht (siehe [Sieb des Eratosthenes](#)).
5. Wie viele Primzahlen sind in dem Array? Welches ist die größte, welches die kleinste Primzahl? Sortieren Sie die Primzahlen absteigend.

 Tipp 27: Musterlösung

```
# 1. NumPy-Array erstellen und maskieren
maskiertes_array = np.arange(1, 100 + 1).reshape(10, 10)
maskiertes_array = ma.masked_where(condition = (maskiertes_array % 2 != 0) & (maskiertes_ar
print(maskiertes_array, "\n")
```

```
[[1 2 -- 4 5 6 7 8 -- 10]
 [11 12 13 14 -- 16 17 18 19 20]
 [-- 22 23 24 25 26 -- 28 29 30]
 [31 32 -- 34 35 36 37 38 -- 40]
 [41 42 43 44 -- 46 47 48 49 50]
 [-- 52 53 54 55 56 -- 58 59 60]
 [61 62 -- 64 65 66 67 68 -- 70]
 [71 72 73 74 -- 76 77 78 79 80]
 [-- 82 83 84 85 86 -- 88 89 90]
 [91 92 -- 94 95 96 97 98 -- 100]]
```

```
# 2. Summen bilden
print(f"Summe der maskierten Werte: {maskiertes_array.data[maskiertes_array.mask].sum()}\tS
```

Summe der maskierten Werte: 867 Summe der unmaskierten Werte: 4183

```
# 3. Maske zurücksetzen
maskiertes_array.mask = False
print(maskiertes_array, "\n")
```

```
[[1 2 3 4 5 6 7 8 9 10]
 [11 12 13 14 15 16 17 18 19 20]
 [21 22 23 24 25 26 27 28 29 30]
 [31 32 33 34 35 36 37 38 39 40]
 [41 42 43 44 45 46 47 48 49 50]
 [51 52 53 54 55 56 57 58 59 60]]
```

```

[61 62 63 64 65 66 67 68 69 70]
[71 72 73 74 75 76 77 78 79 80]
[81 82 83 84 85 86 87 88 89 90]
[91 92 93 94 95 96 97 98 99 100]]

# 4. Primzahlsieb
## 1
i = 1
bedingung1 = maskiertes_array == i
sieb = ma.masked_where(bedingung1, maskiertes_array)
print(f"i = {i}\n{sieb}\n")

## 2
i = 2
bedingung2 = (maskiertes_array > i) & (maskiertes_array % i == 0)
sieb = ma.masked_where(bedingung1 | bedingung2, maskiertes_array)
print(f"zusätzlich Vielfache von {i}\n{sieb}\n")

## 3
i = 3
bedingung3 = (maskiertes_array > i) & (maskiertes_array % i == 0)
sieb = ma.masked_where(bedingung1 | bedingung2 | bedingung3, maskiertes_array)
print(f"zusätzlich Vielfache von {i}\n{sieb}\n")

## 5
i = 5
bedingung5 = (maskiertes_array > i) & (maskiertes_array % i == 0)
sieb = ma.masked_where(bedingung1 | bedingung2 | bedingung3 | bedingung5, maskiertes_array)
print(f"zusätzlich Vielfache von {i}\n{sieb}\n")

## 7
i = 7
bedingung7 = (maskiertes_array > i) & (maskiertes_array % i == 0)
sieb = ma.masked_where(bedingung1 | bedingung2 | bedingung3 | bedingung5 | bedingung7, maskiertes_array)
print(f"zusätzlich Vielfache von {i}\n{sieb}\n")

i = 1
[[- 2 3 4 5 6 7 8 9 10]
 [11 12 13 14 15 16 17 18 19 20]
 [21 22 23 24 25 26 27 28 29 30]
 [31 32 33 34 35 36 37 38 39 40]
 [41 42 43 44 45 46 47 48 49 50]]

```

```
[51 52 53 54 55 56 57 58 59 60]
[61 62 63 64 65 66 67 68 69 70]
[71 72 73 74 75 76 77 78 79 80]
[81 82 83 84 85 86 87 88 89 90]
[91 92 93 94 95 96 97 98 99 100]]
```

zusätzlich Vielfache von 2

```
[[-- 2 3 -- 5 -- 7 -- 9 --]
[11 -- 13 -- 15 -- 17 -- 19 --]
[21 -- 23 -- 25 -- 27 -- 29 --]
[31 -- 33 -- 35 -- 37 -- 39 --]
[41 -- 43 -- 45 -- 47 -- 49 --]
[51 -- 53 -- 55 -- 57 -- 59 --]
[61 -- 63 -- 65 -- 67 -- 69 --]
[71 -- 73 -- 75 -- 77 -- 79 --]
[81 -- 83 -- 85 -- 87 -- 89 --]
[91 -- 93 -- 95 -- 97 -- 99 --]]
```

zusätzlich Vielfache von 3

```
[[-- 2 3 -- 5 -- 7 -- -- --]
[11 -- 13 -- -- -- 17 -- 19 --]
[-- -- 23 -- 25 -- -- -- 29 --]
[31 -- -- -- 35 -- 37 -- -- --]
[41 -- 43 -- -- -- 47 -- 49 --]
[-- -- 53 -- 55 -- -- -- 59 --]
[61 -- -- -- 65 -- 67 -- -- --]
[71 -- 73 -- -- -- 77 -- 79 --]
[-- -- 83 -- 85 -- -- -- 89 --]
[91 -- -- -- 95 -- 97 -- -- --]]
```

zusätzlich Vielfache von 5

```
[[-- 2 3 -- 5 -- 7 -- -- --]
[11 -- 13 -- -- -- 17 -- 19 --]
[-- -- 23 -- -- -- -- -- 29 --]
[31 -- -- -- -- -- 37 -- -- --]
[41 -- 43 -- -- -- 47 -- 49 --]
[-- -- 53 -- -- -- -- -- 59 --]
[61 -- -- -- -- -- 67 -- -- --]
[71 -- 73 -- -- -- 77 -- 79 --]
[-- -- 83 -- -- -- -- -- 89 --]
[91 -- -- -- -- -- 97 -- -- --]]
```

```

zusätzlich Vielfache von 7
[[- 2 3 -- 5 -- 7 -- -- --]
 [11 -- 13 -- -- -- 17 -- 19 --]
 [-- -- 23 -- -- -- -- -- 29 --]
 [31 -- -- -- -- -- 37 -- -- --]
 [41 -- 43 -- -- -- 47 -- -- --]
 [-- -- 53 -- -- -- -- -- 59 --]
 [61 -- -- -- -- -- 67 -- -- --]
 [71 -- 73 -- -- -- -- 79 --]
 [-- -- 83 -- -- -- -- -- 89 --]
 [-- -- -- -- -- -- 97 -- -- --]]

```

```

# 5. verschiedene Aufgaben
## Wie viele Primzahlen sind in dem Array?
print("Anzahl Primzahlen:", sieb.size - sieb.mask.sum())

## Welches ist die größte, welches die kleinste Primzahl?
print(sieb.max(), sieb.min())

## Primzahlen absteigend sortiert
### ma.sort() sortiert nur aufsteigend, deshalb:
### Übergabe des eindimensionalen arrays sieb.flatten() in umgekehrter Reihenfolge [::-1]
### anschließend umformen in 2D-Array
### endwith = False missing values are treated as smallest values
print(ma.sort(sieb.flatten(), endwith = False)[::-1].reshape(sieb.shape))

```

```

Anzahl Primzahlen: 25
97 2
[[97 89 83 79 73 71 67 61 59 53]
 [47 43 41 37 31 29 23 19 17 13]
 [11 7 5 3 2 -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]
 [-- -- -- -- -- -- -- -- --]]

```

7 Wissenschaftliche Dateiformate

Wissenschaftliche Datensätze können extrem groß sein. Beispielsweise hat das Kernforschungszentrum CERN im November 2018 15,8 Petabyte Daten aufgezeichnet ([Key Facts and Figures - CERN Data Centre](#)). Für den Austausch großer Datenmengen wurden Datenformate wie das Hierarchical Data Format (HDF) und Network Common Data Format (netCDF) entwickelt. Diese erlauben es unter anderem, Datensätze direkt vom Massenspeicher des Computers auszulesen, sodass eine mögliche Begrenzung durch den Arbeitsspeicher vermieden wird.

Im Folgenden werden knapp die Grundfunktionen für das Arbeiten mit HDF5- und netCDF4-Dateien vorgestellt. Detailliertere Informationen finden Sie in der jeweiligen Dokumentation.

7.1 HDF5

HDF5 bedeutet Hierarchical Data Format Version 5. HDF organisiert Daten in einer Ordnerstruktur, die mit der Ordnerstruktur eines Computers vergleichbar ist, und enthält beschreibende Metadaten, weshalb HDF als selbstbeschreibend gilt. Die HDF-Verzeichnisstruktur wird mit bestimmten Begriffen beschrieben.

- Gruppen oder **groups** bezeichnen die Verzeichnisse (Unterordner) innerhalb der HDF-Datei. **groups** können weitere Gruppen oder **datasets** enthalten.
- Dateien oder **datasets** entsprechen einzelnen Dateien.




Abbildung 7.1: HDF5-Verzeichnisstruktur

An illustration of a HDF5 file and associated metadata from U.S National Science Foundation's National Ecological Observatory Network (NEON) is available under <https://www.neonscience.org/resources/learning-hub/tutorials/about-hdf5>.

In Python können die Pakete [PyTables](#), das von Pandas verwendet wird, und `h5py` mit HDF5 umgehen. Das Einlesen von HDF5-Dateien funktioniert ähnlich wie das Einlesen von Dateien in der Pythonbasis: Der Zugriff auf die Datei erfolgt mit einem Dateiobjekt, über das verschiedene Methoden zum Lesen und Schreiben bereitgestellt werden. Abschließend wird das Dateiobjekt wieder geschlossen.

Die Integration des Pakets `PyTables` in Pandas ist auf die Verwendung von Pandas-Objekten ausgelegt. Es wird eine spezifische Dateistruktur genutzt und erwartet. Anders aufgebaute HDF5-Dateien können nicht eingelesen werden. Deshalb wird das Paket hier nur kurz vorgestellt. ([Thema auf stackoverflow](#), [Antwort von Kevin S](#) unter CC-BY-SA 3.0)

Warning 8: Datensatz

In diesem Abschnitt wird ein Teil des Datensatzes IceBridge ATM L1B Elevation and Return Strength, Version 2 genutzt ([kostenlose Registrierung bei NASA Earth erforderlichlich](#)). Das [Handbuch ist hier verfügbar](#). Der Datensatz enthält flugzeugbasierte Lasermessungen für die Höhe des Eisschildes in der Arktis und Antarktis mittels des NASA Airborne Topographic Mapper (ATM). ATM hat eine Abtastrate von 3 bis 5 kHz. Jede Datei enthält die Daten von einigen Minuten Flugdauer. Das geografische Referenzsystem ist das World Geodetic System 1984 (WGS 84). Die Dateien sind nach dem Schema ILATM1B_YYYYMMDD_HH-MMSS.ATM4BT4.h5 benannt:

- Datensatz-ID__
- Jahr, Monat, Tag der Messung__
- Zeitpunkt am Beginn der Messung in Stunden, Minuten, Sekunden__
- Instrumenten-ID (fünfstellig) und Messwinkel (T2 = 15 Grad, T3 = 23 Grad, T4 = 30 Grad).
- xxx Dateityp (.h5 = HDF5, h5.xml = zusätzliche Metadatendatei)

Studinger, M. 2013, updated 2020. IceBridge ATM L1B Elevation and Return Strength, Version 2. [Indicate subset used]. Boulder, Colorado USA. NASA National Snow and Ice Data Center Distributed Active Archive Center. <https://doi.org/10.5067/19SIM5TXKPGT>. [05.12.2024]

7.1.1 PyTables

Das Paket PyTables wird mit dem Befehl `pip install tables` installiert. Die Funktionen des Pakets sind in Pandas integriert. Der Zugriff auf HDF-Dateien wird in Pandas über ein [HDFStore-Objekt](#) bereitgestellt. Hierrüber können HDF-Dateien gelesen und geschrieben werden. Das HDFStore-Objekt entspricht dem Wurzelverzeichnis der strukturierten Datei. Die Funktion `pd.HDFStore(path, mode)` nimmt als Argumente den Dateipfad `path` und den Zugriffsmodus `mode` entgegen.

Zugriffsmodus	Beschreibung
'a'	Standardmodus append: öffnet die Datei im Lese- und Schreibmodus. Falls die Datei nicht vorhanden ist, wird diese erstellt.
'w'	Schreibzugriff, Erstellen einer neuer Datei, Überschreiben einer bestehenden, gleichnamigen Datei

Zugriffs- modus	Beschreibung
'r'	Lesezugriff
'r+'	Lese- und Schreibzugriff wie 'a', Datei muss aber existieren.

Über das `HDFStore`-Objekt kann der Inhalt der Datei ausgelesen werden, sofern das Format kompatibel ist.

- Die Methode `hdf.info()` gibt Informationen zum Dateiojekt aus.
- Die Methode `hdf.keys(include = 'pandas')` gibt standardmäßig die Schlüssel der Pandas-Objekte im Wurzelverzeichnis zurück. Mit dem Argument `hdf.keys(include = 'native')` sollten auch native HDF5-Objekte ausgegeben werden können, sofern die HDF5-Datei kompatibel ist.
- Der Zugriff auf ausgewählte Schlüssel erfolgt mit der Methode `hdf.get('key')` oder durch `hdf['key']`.
- Mit der Methode `hdf.close()` wird das `HDFStore`-Objekt wieder geschlossen.

Hinweis 7: inkompatible HDF5-Datei

```
# Datei öffnen
dateipfad = "01-daten/ILATM1B_20191120_041200.ATM6AT6.h5"
hdf = pd.HDFStore(dateipfad, mode = 'r')

print(hdf.info(), "\n")

# parameter include: str, default 'pandas'. When 'pandas' return pandas objects. When 'native' return native objects.
print(hdf.keys(include = 'native'), "\n")
print(hdf.keys(include = 'pandas'), "\n")

print(hdf.groups(), "\n")

# Test hdf.get()
try:
    elevation = hdf.get('elevation')
    print(type(elevation))
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    elevation = hdf.get('elevation')
    print(type(elevation))

# Test pd.read_hdf()
try:
    elevation = pd.read_hdf(path_or_buf = hdf, key = 'elevation')
    print(type(elevation))
except TypeError as error:
    print("Die Eingabe führt zu der Fehlermeldung:\n", error)
else:
    elevation = pd.read_hdf(path_or_buf = hdf, key = 'elevation')
    print(type(elevation))

# HDFStore-Objekt schließen
hdf.close()
```

```
<class 'pandas.io.pytables.HDFStore'>
File path: 01-daten/ILATM1B_20191120_041200.ATM6AT6.h5
Empty
```

```
[]
```

```
[]
```

```
[]
```

Die Eingabe führt zu der Fehlermeldung:

cannot create a storer if the object is not existing nor a value are passed

Die Eingabe führt zu der Fehlermeldung:

cannot create a storer if the object is not existing nor a value are passed

/opt/hostedtoolcache/Python/3.12.1/x64/lib/python3.12/site-

packages/tables/attributeset.py:322: VisibleDeprecationWarning: dtype(): align should be pa

value = self._g_getattr(self._v_node, name)

Um die Funktionen zu demonstrieren, wird mit eine HDF5-Datei erstellt. Dazu wird ein HDFStore-Objekt im Modus append angelegt und mit der Methode `hdf.put(key, value, format)` ein DataFrame gespeichert.

```
# HDF5-Datei anlegen
```

```
df = pd.DataFrame({'Spalte1': [1, 2, 3], 'Spalte2': [4, 5, 6]})
```

```
hdf = pd.HDFStore("01-daten/hdf_file_demo.h5", mode = 'a')
```

```
hdf.put('daten', df, format = 'table')
```

```
hdf.close()
```

```
# HDF5-Datei einlesen
```

```
hdf2 = pd.HDFStore("01-daten/hdf_file_demo.h5", mode = 'r')
```

```
print(hdf2.info(), "\n")
```

```
print(hdf2.keys(), "\n")
```

```
df2 = hdf2.get(key = "/daten")
```

```
print(df2)
```

```
hdf2.close()
```

```
<class 'pandas.io.pytables.HDFStore'>
```

```
File path: 01-daten/hdf_file_demo.h5
```

```
/daten          frame_table  (typ->appendable,nrows->3,ncols->2,indexers->[index],dc->[])
```

```
['/daten']
```

```
   Spalte1  Spalte2
0         1         4
```

1	2	5
2	3	6

Eine Liste verfügbarer Funktionen findet sich [in der Dokumentation](#).
([Numpy Ninja](#))

7.1.2 h5py

Das Paket h5py wird mit dem Befehl `pip install h5py` installiert. Das Modul h5py funktioniert ähnlich wie PyTables. Der Zugriff auf eine HDF5-Datei erfolgt über ein Dateiojekt, das mit der Funktion `h5py.File(Dateipfad, Zugriffsmodus)` erzeugt wird ([siehe h5py Dokumentation](#)).

Zugriffs- modus	Beschreibung
r	Lesemodus, Datei muss existieren (default)
r+	Lese- und Schreibmodus, Datei muss existieren
w	Datei erstellen, bestehende Datei kürzen
w- or x	Datei erstellen, abbrechen wenn Datei bereits besteht
a	Lesen / Schreiben, wenn die Datei besteht, andernfalls Datei erstellen

Über das Dateiojekt erfolgt der Zugriff auf Gruppen und Datensätze. Gruppen sind wie dictionaries aufgebaut, der Zugriff erfolgt also über Schlüssel-Wert-Paare (key: value). Die Schlüssel sind die Namen der Elemente in einer Gruppe, die Werte sind die Elemente selbst (Gruppen oder Datasets).

“The most fundamental thing to remember when using h5py is:

Groups work like dictionaries, and datasets work like NumPy arrays” ([Dokumentation h5py](#), Hervorhebung im Original)

Die Gruppennamen können mit der Methode `Dateiojekt.keys()` abgerufen werden.

```
import h5py
dateipfad = "01-daten/ILATM1B_20191120_041200.ATM6AT6.h5"
hdf = h5py.File(dateipfad, mode = 'r')

print(hdf, "\n")
print(list(hdf.keys()))
```


Die Objekte `elevation`, `latitude` und `longitude` sind Datensätze. Die Objekte `ancillary_data` und `instrument_parameters` sind Gruppen. Der Zugriff innerhalb von Gruppen erfolgt wie bei der Eingabe eines Dateipfads: `Dateiobjekt['Gruppe/key']`.

Um mit Datasets zu arbeiten muss eine Kopie z. B. durch Slicing erstellt werden.

```
try:
    print(hdf['elevation'] - 1000)
except TypeError as error:
    print("Der Direktzugriff führt zu der Fehlermeldung:\n", error)

# Mit einer Kopie kann gearbeitet werden
print("\nMit einer Kopie geht es:")
print(hdf['elevation'][:] - 1000)

# Mit Indexbereichen ebenso
print("\nEbenso mit ausgewählten Indexbereichen:")
print(hdf['elevation'][0:10])
```

Der Direktzugriff führt zu der Fehlermeldung:

```
unsupported operand type(s) for -: 'Dataset' and 'int'
```

Mit einer Kopie geht es:

```
[178.32202 178.34302 178.44495 ... 129.38794 128.62195 128.18799]
```

Ebenso mit ausgewählten Indexbereichen:

```
[1178.322 1178.343 1178.445 1178.351 1178.363 1178.389 1178.396 1178.393
 1178.274 1178.321]
```

Am Ende wird das Dateiobjekt geschlossen.

```
hdf.close()
```

7.1.3 Übung Zugriff auf H5P-Datasets

Berechnen Sie aus der relativen Zeit `hdf['instrument_parameters/rel_time']` im Format 'hhmmss' und dem im Dateinamen enthaltenen Beginn der Messung die tatsächliche Zeit der Messung. Der Dateipfad lautet: '01-daten/ILATM1B_20191120_041200.ATM6AT6.h5'.

Hinweis: Die relative Zeit liegt in Tausendstelsekunden aufgelöst vor. Aufgrund der hohen Abtastrate von ATM kommen Zeiten in der Regel mehrfach vor.

💡 Tipp 28: Musterlösung absolute Zeit berechnen

```
# HDF-Datei öffnen
dateipfad = "01-daten/ILATM1B_20191120_041200.ATM6AT6.h5"
hdf = h5py.File(dateipfad, mode = 'r')

zeitstempel = int(str(hdf)[29:35])
print(f"Beginn der Messungen: {zeitstempel}\n")

rel_time = hdf['instrument_parameters/rel_time'][:]
abs_time = rel_time + zeitstempel

print(f"rel_time[-5:]:\n{rel_time[-5:]}\n\nabs_time[-5:]:\n{abs_time[-5:]}" )

# HDF-Datei schließen
hdf.close()
```

Beginn der Messungen: 41200

rel_time[-5:]:
[59.986 59.986 59.987 59.989 59.99]

abs_time[-5:]:
[41259.984 41259.984 41259.99 41259.99 41259.99]

HDF5 Dateien schreiben

Um Objekte in eine HDF5-Datei zu schreiben, muss diese im Schreibmodus geöffnet werden.

```
hdf_neu = h5py.File('01-daten/hdf_neu.h5', mode = 'w')
hdf_neu['abs_time'] = abs_time
hdf_neu.close()

# Kontrolle
hdf_neu = h5py.File('01-daten/hdf_neu.h5', mode = 'r')
print(hdf_neu.keys())
hdf_neu.close()
```

<KeysViewHDF5 ['abs_time']>

([Dokumentation h5py](#))

7.2 netCDF4

Das Paket netCDF4 (Network Common Data Format Version 4) wird mit `pip install netCDF4` installiert. netCDF4 basiert auf HDF5, verwendet aber eine eigene Terminologie. Der Zugriff auf eine netCDF4 Datei erfolgt über das Dataset-Objekt, das der Wurzelgruppe entspricht. Eine netCDF-Datei bzw. das Dataset-Objekt besteht aus:

- Gruppen (groups): Gruppen sind Unterverzeichnisse des Dataset-Objekts und können Variablen, Dimensionen, Attribute und weitere Gruppen enthalten.
- Variablen (variables): Variablen entsprechen Datensätzen bzw. NumPy-Arrays.
- Dimensionen (dimensions): Dimensionen beschreiben Eigenschaften der Variablen wie Name (name), Größe (size), Gruppenzugehörigkeit (group)
- Attribute (attributes): Attribute beschreiben entweder das gesamte Dataset (globale Attribute) oder einzelne Variablen. Attribute speichern die Metadaten.

```
- Dataset.description = 'Beschreibung des Datensatzes'
- Dataset.history = 'Zeitpunkt der Erstellung'
- Dataset.source = 'Quelle'
- Dataset.units = 'Beschreibung der Messeinheit'
- Dataset.calender = 'gregorianischer Kalender'
```

Diese Elemente sind als Dictionary aufgebaut und erlauben den Zugriff über Schlüssel-Wert-Paare.

7.3 Datensatz

In diesem Abschnitt wird ein Datensatz der NASA zur Blitzdichte (Anzahl Blitze pro Quadratkilometer) verwendet [kostenlose Registrierung bei NASA Earth erforderlich](#). Die netCDF4-Datei enthält verschiedene Datensätze (Variablen), die mit satellitengestützten Messinstrumenten erstellt wurden. Blitze im Bereich von +/- 38 Grad um den Äquator wurden mit dem Lightning Imaging Sensor (LIS) des Satelliten der Tropical Rainfall Measuring Mission (TRMM) gemessen. In höheren und niedrigeren Breitengraden wurden Blitze mit dem Optical Transient Detector (OTD) auf Orbview-1 gemessen. Die Daten liegen in einer Auflösung von 0.5 Grad vor. ([Datensatzdokumentation](#), [Poetzsch 2021](#): 182-183)

Die Datensätze folgen dem Namensschema HRFC_COM_FR

- HRFC = High Resolution Full Climatology
- COM = Kombination beider Messinstrumente [LIS, OTD]

- FR = Flash Rates [RF = Raw Flash Rates, SF = Scaled Flash Rates]

LIS/OTD 0.5 Degree High Resolution Full Climatology (HRFC) V2.3.2015 von Global Hydrometeorology Resource Center DAAC (GHRC DAAC)

DOI <https://doi.org/10.5067/LIS/LIS-OTD/DATA302>

Ein Dataset-Objekt wird mit der Funktion `nc.Dataset(filename, mode)` geöffnet. Mit dem Argument `filename` wird der Dateipfad übergeben. Im Argument `mode` wird der Zugriffsmodus festgelegt.

Zugriffsmodus	Beschreibung
r	Lesemodus, Datei muss existieren (default)
r+	Update-Modus, Datei wird ggf. angelegt und kann gelesen und geschrieben werden
w	Schreibmodus Datei erstellen, bestehende Datei überschreiben
x	Datei erstellen, abbrechen wenn Datei bereits besteht
a	Anhängen: Datei wird ggf. angelegt, neue Inhalte werden am Ende der Datei angehängt, bestehende Inhalte werden dabei nicht gelöscht.

netCDF-Dateien können verschiedene Versionen haben (NETCDF3_CLASSIC, NETCDF3_64BIT_OFFSET, NETCDF3_64BIT_DATA, NETCDF4_CLASSIC, NETCDF4). Um die Version abzurufen, kann das Attribut `cdf.data_model` abgerufen werden.

```
import netCDF4 as nc

dateipfad = "01-daten/LISOTD_HRFC_V2.3.2015.nc"
cdf = nc.Dataset(filename = dateipfad, mode = 'r')
print(f"Dateiversion: {cdf.data_model}\n")
```

Dateiversion: NETCDF4

Die wesentlichen Informationen können mit der print-Funktion ausgegeben werden `print(cdf)`. Die Ausgabe ist jedoch besonders für komplexere Dateien unübersichtlich.

Die Gruppen der Datei können mit dem Attribut `print(cdf.groups)` ausgegeben werden.

```
print(cdf.groups)
```

```
{}
```

Die Ausgabe ist ein Dictionary, das in diesem Fall leer ist. Die Datei verfügt also über keine Unterverzeichnisse (Gruppen).

Die Variablen (die Datensätze) können mit dem Attribut `print(cdf.variables)` ausgegeben werden, die Ausgabe ist ebenfalls ein Dictionary. Die vollständige Ausgabe findet sich im folgenden Beispiel.

```
variables = cdf.variables
for key, value in variables.items():
    print(key)
    print(value, "\n")
    break # Abbruch nach erstem Schlüssel-Wert-Paar
```

```
DE_By_Threshold
<class 'netCDF4.Variable'>
float32 DE_By_Threshold(DE_By_Threshold)
    long_name: By Threshold
    comment: Threshold index for OTD detection efficiency
    units: 1
unlimited dimensions:
current shape = (3,)
filling on, default _FillValue of 9.969209968386869e+36 used
```

i Hinweis 8: vollständige Ausgabe `cdf.variables`

```
variables = cdf.variables
for key, value in variables.items():
    print(key)
    print(value, "\n")
```

```
DE_By_Threshold
<class 'netCDF4.Variable'>
float32 DE_By_Threshold(DE_By_Threshold)
    long_name: By Threshold
    comment: Threshold index for OTD detection efficiency
    units: 1
unlimited dimensions:
```

```

current shape = (3,)
filling on, default _FillValue of 9.969209968386869e+36 used

DE_Local_Hour
<class 'netCDF4.Variable'>
float32 DE_Local_Hour(DE_Local_Hour)
    long_name: Local Hour
    comment: Lightning detection efficiency is the function of local hour. A day is divided
    units: 1
unlimited dimensions:
current shape = (24,)
filling on, default _FillValue of 9.969209968386869e+36 used

DE_LowRes_Latitude
<class 'netCDF4.Variable'>
float32 DE_LowRes_Latitude(DE_LowRes_Latitude)
    long_name: LowRes Latitude
    standard_name: latitude
    axis: Y
    units: degrees_north
unlimited dimensions:
current shape = (72,)
filling on, default _FillValue of 9.969209968386869e+36 used

DE_LowRes_Longitude
<class 'netCDF4.Variable'>
float32 DE_LowRes_Longitude(DE_LowRes_Longitude)
    long_name: LowRes Longitude
    standard_name: longitude
    axis: X
    units: degrees_east
unlimited dimensions:
current shape = (144,)
filling on, default _FillValue of 9.969209968386869e+36 used

HRFC_AREA
<class 'netCDF4.Variable'>
float32 HRFC_AREA(Latitude, Longitude)
    valid_range: [ 13.48325 3090.078 ]
    long_name: Grid Cell Area
    units: km^2

```

```

    _FillValue: 0.0
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_COM_FR
<class 'netCDF4.Variable'>
float32 HRFC_COM_FR(Latitude, Longitude)
    valid_range: [ 0.      201.7618]
    long_name: Combined Flash Rate Climatology
    _FillValue: 0.0
    units: count/km^2/year
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_LIS_DE
<class 'netCDF4.Variable'>
float32 HRFC_LIS_DE(DE_Local_Hour, DE_LowRes_Latitude, DE_LowRes_Longitude)
    valid_range: [ 0.      88.00034]
    long_name: Applied LIS Detection Efficiency
    units: Percent
    _FillValue: 0.0
unlimited dimensions:
current shape = (24, 72, 144)
filling on

HRFC_LIS_FR
<class 'netCDF4.Variable'>
float32 HRFC_LIS_FR(Latitude, Longitude)
    valid_range: [ 0.      5723.275]
    long_name: LIS Flash Rate Climatology
    _FillValue: 0.0
    units: count/km^2/year
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_LIS_RF
<class 'netCDF4.Variable'>
float32 HRFC_LIS_RF(Latitude, Longitude)

```

```

        valid_range: [ 0. 9770.]
        long_name: LIS Raw Flashes
        _FillValue: 0.0
        units: count
    unlimited dimensions:
    current shape = (360, 720)
    filling on

    HRFC_LIS_SF
    <class 'netCDF4.Variable'>
    float32 HRFC_LIS_SF(Latitude, Longitude)
        valid_range: [ 0. 12500.17]
        long_name: LIS Scaled Flashes
        _FillValue: 0.0
        units: count
    unlimited dimensions:
    current shape = (360, 720)
    filling on

    HRFC_LIS_VT
    <class 'netCDF4.Variable'>
    float32 HRFC_LIS_VT(Latitude, Longitude)
        valid_range: [0.000000e+00 4.462968e+09]
        long_name: LIS Viewtime
        units: km^2 sec
        _FillValue: 0.0
    unlimited dimensions:
    current shape = (360, 720)
    filling on

    HRFC_OTD_DE
    <class 'netCDF4.Variable'>
    float32 HRFC_OTD_DE(DE_By_Threshold, DE_Local_Hour, DE_LowRes_Latitude, DE_LowRes_Longitude)
        valid_range: [ 0. 53.6012]
        long_name: Applied OTD Base Detection Efficiency
        units: Percent
        _FillValue: 0.0
    unlimited dimensions:
    current shape = (3, 24, 72, 144)
    filling on

```

```

HRFC_OTD_FR
<class 'netCDF4.Variable'>
float32 HRFC_OTD_FR(Latitude, Longitude)
    valid_range: [ 0.      201.7618]
    long_name: OTD Flash Rate Climatology
    _FillValue: 0.0
    units: count/km^2/year
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_OTD_RF
<class 'netCDF4.Variable'>
float32 HRFC_OTD_RF(Latitude, Longitude)
    valid_range: [ 0. 1298.]
    long_name: OTD Raw Flashes
    _FillValue: 0.0
    units: count
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_OTD_SF
<class 'netCDF4.Variable'>
float32 HRFC_OTD_SF(Latitude, Longitude)
    valid_range: [ 0.      2645.824]
    long_name: OTD Scaled Flashes
    _FillValue: 0.0
    units: count
unlimited dimensions:
current shape = (360, 720)
filling on

HRFC_OTD_VT
<class 'netCDF4.Variable'>
float32 HRFC_OTD_VT(Latitude, Longitude)
    valid_range: [0.000000e+00 1.119883e+09]
    long_name: OTD Viewtime
    units: km^2 sec
    _FillValue: 0.0
unlimited dimensions:

```

```

current shape = (360, 720)
filling on

Latitude
<class 'netCDF4.Variable'>
float32 Latitude(Latitude)
    long_name: Latitude
    standard_name: latitude
    axis: Y
    units: degrees_north
unlimited dimensions:
current shape = (360,)
filling on, default _FillValue of 9.969209968386869e+36 used

Longitude
<class 'netCDF4.Variable'>
float32 Longitude(Longitude)
    long_name: Longitude
    standard_name: longitude
    axis: X
    units: degrees_east
unlimited dimensions:
current shape = (720,)
filling on, default _FillValue of 9.969209968386869e+36 used

lis_rf_data_centered
<class 'netCDF4.Variable'>
float32 lis_rf_data_centered(latitude, longitude)
    description: zentrierte Blitzanzahl
    units: absolute Abweichung vom Mittelwert
unlimited dimensions:
current shape = (360, 720)
filling on, default _FillValue of 9.969209968386869e+36 used

```

Ebenso können die Dimensionen (`cdf.dimensions`) und die globalen Attribute des Datasets (`cdf.__dict__` oder als Liste mit `cdf.ncattrs()`) ausgegeben werden. Ebenso können die Attribute einer Variablen ausgegeben werden. Variablen werden direkt über den Schlüssel `variable` = `cdf['key']` oder mit der Funktion `variable = cdf.variables['key']` abgerufen.

7.4 Dimensionen

```
dimensions = cdf.dimensions
```

```
for key, value in dimensions.items():  
    print(key)  
    print(value, "\n")
```

DE_By_Threshold

```
"<class 'netCDF4.Dimension'>": name = 'DE_By_Threshold', size = 3
```

DE_Local_Hour

```
"<class 'netCDF4.Dimension'>": name = 'DE_Local_Hour', size = 24
```

DE_LowRes_Latitude

```
"<class 'netCDF4.Dimension'>": name = 'DE_LowRes_Latitude', size = 72
```

DE_LowRes_Longitude

```
"<class 'netCDF4.Dimension'>": name = 'DE_LowRes_Longitude', size = 144
```

Latitude

```
"<class 'netCDF4.Dimension'>": name = 'Latitude', size = 360
```

Longitude

```
"<class 'netCDF4.Dimension'>": name = 'Longitude', size = 720
```

latitude

```
"<class 'netCDF4.Dimension'>": name = 'latitude', size = 360
```

longitude

```
"<class 'netCDF4.Dimension'>": name = 'longitude', size = 720
```

7.5 globale Attribute

```
print(cdf.ncattrs(), "\n")
```

```
global_attributes = cdf.__dict__
```

```
for key, value in global_attributes.items():  
    print(key)  
    print(value, "\n")
```

```
['NCProperties', 'OTD_Date_Window_Start', 'OTD_Date_Window_End', 'OTD_Threshold_Level_Used',
```

```
NCProperties
```

```
version=1|netcdflibversion=4.4.1|hdf5libversion=1.10.0
```

```
OTD_Date_Window_Start
```

```
[1995.333 1995.44 1995.55 1996.81 ]
```

```
OTD_Date_Window_End
```

```
[1995.44 1995.55 1996.81 2000.333]
```

```
OTD_Threshold_Level_Used
```

```
[0 2 1 0]
```

```
Conventions
```

```
CF-1.6
```

```
history
```

```
Fri Dec 09 16:42:21 2016: ncks -4 test.nc3 LISOTD_HRFC_V2.3.2014_rename.nc
```

```
Fri Dec 09 16:42:21 2016: ncrename -v DE By Threshold,DE_By_Threshold test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -d DE By Threshold,DE_By_Threshold test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -v DE Local Hour,DE_Local_Hour test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -d DE Local Hour,DE_Local_Hour test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -v DE LowRes Longitude,DE_LowRes_Longitude test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -d DE LowRes Longitude,DE_LowRes_Longitude test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -v DE LowRes Latitude,DE_LowRes_Latitude test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -d DE LowRes Latitude,DE_LowRes_Latitude test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -a global@OTD Threshold Level Used,OTD_Threshold_Level_Used test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -a global@OTD Date Window End,OTD_Date_Window_End test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -a global@OTD Date Window Start,OTD_Date_Window_Start test.nc3
```

```
Fri Dec 09 16:42:21 2016: ncrename -a global@NCProperties,NCProperties test.nc3
```

```
Fri Dec 09 16:42:20 2016: ncks -3 LISOTD_HRFC_V2.3.2014.nc test.nc3
```

```
NCO
```

```
"4.6.0"
```

7.6 Attribute einer Variablen

```
variable = cdf['HRFC_OTD_FR']
# Alternativ:
# variable = cdf.variables['HRFC_OTD_FR']

print("\nAttribute einer Variablen")
print(f"Als Liste mit variable.ncattrs():\n{variable.ncattrs()}\n")

print(f"Als Dictionary mit variable.__dict__:\n{variable.__dict__}\n")
```

Attribute einer Variablen

Als Liste mit `variable.ncattrs()`:

```
['valid_range', 'long_name', '_FillValue', 'units']
```

Als Dictionary mit `variable.__dict__`:

```
{'valid_range': array([ 0.      , 201.7618], dtype=float32), 'long_name': 'OTD Flash Rate Clin
```

7.6.1 Daten in netCDF4-Dateien schreiben

Um Daten in eine netCDF4-Datei zu schreiben, muss diese in einem der Schreibmodi geöffnet werden `Dataset = nc.Dataset('pfad', mode = 'a')`. Um eine neue Variable anzulegen, muss eine entsprechende Dimension angelegt werden. Wenn die Variable in einen noch nicht bestehenden Pfad gespeichert werden soll, sind auch die entsprechenden Gruppen anzulegen.

- Gruppen im Wurzelverzeichnis werden mit der Funktion `Dataset.createGroup("Gruppenname")` angelegt. Unterverzeichnisse werden analog als Pfad angelegt: `Dataset.createGroup("/Gruppenname/Unterverzeichnis")` (führenden '/' beachten).
- Dimensionen beschreiben die Größe einer Variablen und müssen vor der Variablen angelegt werden (Ein Skalar, also ein Einzelwert, hat keine Dimension): `Dataset.createDimension('Name der Dimension', Größe der Dimension als Ganzzahl)`. Durch die Übergabe von `None` oder `0` als Größe, wird eine unbegrenzt große Dimension angelegt (netCDF4-Variablen verhalten sich wie NumPy-Arrays, besitzen aber keine feste Größe. Das bedeutet, es können weitere Daten angehängt werden.). Um beispielsweise eine zweidimensionale Datenstruktur mit 10 Zeilen und 5 Spalten anzulegen, müssen beide Dimensionen separat deklariert werden: `Dataset.createDimension('Dimension1', 10), Dataset.createDimension('Dimension2', 5)`.

- Variablen werden mit der Funktion `Dataset.createVariable('Name oder Pfad', 'Datentypkürzel', ('Name der Dimension', ))`. Die Argumente 'Name oder Pfad' und 'Datentypkürzel' sind Pflichtangaben. Die Dimensionen der Variable wurden zuvor mit `cdf_neu.createDimension('Name der Dimension', Größe der Dimension als Ganzzahl)` definiert und werden als Tupel übergeben. Ein Einzelwert wird erstellt, indem die Angabe der Dimension weggelassen wird. Eine zweidimensionale Datenstruktur lässt sich so anlegen: `Dataset.createVariable('Name oder Pfad der Variablen', 'Datentypkürzel', ('Dimension1', 'Dimension2', ))` [siehe Dokumentation](#).

Datentypkürzel	Datentyp
'f4'	32-bit floating point
'f8'	64-bit floating point
'i4'	32-bit signed integer
'i2'	16-bit signed integer
'i8'	64-bit signed integer
'i1'	8-bit signed integer
'u1'	8-bit unsigned integer
'u2'	16-bit unsigned integer
'u4'	32-bit unsigned integer
'u8'	64-bit unsigned integer
'S1'	single-character string

Im folgenden Code wird das Objekt `abs_time` aus dem vorherigen Abschnitt in einer `netCDF4`-Datei gespeichert. Mit den Attributen `variablename.description`, `variablename.source` und `variablename.units` werden die Metadaten zur Einheit (hier: Millisekunden) hinterlegt. Dazu wird die Anweisung zum Erstellen der Variable einem Objekt `variablename` zugewiesen.

```
# Neues Dataset im Schreibmodus öffnen
cdf_neu = nc.Dataset('01-daten/cdf_neu.nc', mode = 'w')

# Gruppe 'Daten' anlegen
cdf_neu.createGroup("Daten")

# Dimension anlegen
cdf_neu.createDimension('abs_time', abs_time.shape[0])

# Variable anlegen als 'f4' 32-bit float und einem Objekt zuweisen.
variablename = cdf_neu.createVariable('/Daten/abs_time', 'f4', ('abs_time', ))
```

```

## Attribute anlegen
variablename.description = 'sehr wichtige Zeitinformationen'
variablename.source = 'berechnet aus IceBridge ATM L1B Elevation and Return Strength, Version 2'
variablename.units = 'Millisekunden'

# Dataset schließen
cdf_neu.close()

# Kontrolle
cdf_neu = nc.Dataset('01-daten/cdf_neu.nc', mode = 'r')
print(cdf_neu.groups, "\n")

variables = cdf_neu['/Daten'].variables
for key, value in variables.items():
    print(key)
    print(value, "\n")

cdf_neu.close()

```

```

{'Daten': <class 'netCDF4.Group'>
group /Daten:
  dimensions(sizes):
  variables(dimensions): float32 abs_time(abs_time)
  groups: }

abs_time
<class 'netCDF4.Variable'>
float32 abs_time(abs_time)
  description: sehr wichtige Zeitinformationen
  source: berechnet aus IceBridge ATM L1B Elevation and Return Strength, Version 2
  units: Millisekunden
path = /Daten
unlimited dimensions:
current shape = (327285,)
filling on, default _FillValue of 9.969209968386869e+36 used

```

Operationen mit Variablen

Wie bei HDF5-Dateien können Operationen mit Variablen nicht direkt ausgeführt werden.

```

try:
    print(cdf['HRFC_OTD_FR'] - 1)
except TypeError as error:
    print("Der Direktzugriff führt zu der Fehlermeldung:\n", error)

# Mit einer Kopie kann gearbeitet werden
print("\nMit einer Kopie geht es:")
print(cdf['HRFC_OTD_FR'][ :, :])

# Mit Indexbereichen ebenso
print("\nEbenso mit ausgewählten Indexbereichen:")
print(cdf['HRFC_OTD_FR'][30:40, 30:40])

```

Der Direktzugriff führt zu der Fehlermeldung:
 unsupported operand type(s) for -: 'netCDF4._netCDF4.Variable' and 'int'

Mit einer Kopie geht es:

```

[[- -- -- ... -- --]]
[[- -- -- ... -- --]]
[[- -- -- ... -- --]]
...
[[- -- -- ... -- --]]
[[- -- -- ... -- --]]
[[- -- -- ... -- --]]

```

Ebenso mit ausgewählten Indexbereichen:

```

[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]
[[- -- -- -- -- -- -- --]]

```

Am Ende wird die netCDF4-Datei geschlossen.

```

cdf.close()

```

7.6.2 Übung Zugriff auf netCDF-Datasets

Greifen Sie in der Datei unter dem Pfad '01-daten/LISOTD_HRFC_V2.3.2015.nc' auf die Variable 'HRFC_LIS_RF' zu.

- Geben Sie die Attribute der Variablen aus.
- Bestimmen Sie die minimale, maximale und die durchschnittliche Anzahl der Blitze.
- Zentrieren Sie die Daten (Wert - Mittelwert) und hängen Sie eine neue Variable 'HRFC_LIS_RF_centered' an das Dataset an.

Tipp 29

Da die Ausführung des Codes die Datei entsprechend der Aufgabenstellung verändert, ist der Code nicht als Python-Code eingebunden.

```

# Datei im Modus append einlesen
dateipfad = "01-daten/LISOTD_HRFC_V2.3.2015.nc"
cdf = nc.Dataset(filename = dateipfad, mode = 'a')
print(cdf.data_model, "\n")

# Variable einlesen
lis_rf = cdf['HRFC_LIS_RF']

# Attribute der Variablen ausgeben
print("Attribute der Variablen 'HRFC_LIS_RF':", lis_rf.ncattrs(), "\n")

# Daten aus der Variablen auslesen
lis_rf_data = cdf['HRFC_LIS_RF'][:, :]
print(f"min: {lis_rf_data.min()}\tmax: {lis_rf_data.max()}\tmean: {lis_rf_data.mean()}\n")

# Daten zentrieren
# runden wegen interner Darstellung von Gleitkommazahlen - optional
lis_rf_data_centered = lis_rf_data - lis_rf_data.mean()
print(f"min: {lis_rf_data_centered.min()}\tmax: {lis_rf_data_centered.max()}\tmean: {lis_rf_data_centered.mean()}\n")

# Daten an die netCDF4-Datei anhängen

## Dimension anlegen
## latitude und longitude sind die Dimensionen des 2-dimensionalen Arrays
## Code kann nur einmal ausgeführt werden, prüfen mit try: legt die Dimension bereits an
## deshalb Konstruktion mit not in, um zu prüfen, ob Dimension bereits existiert

dimensions = cdf.dimensions

### latitude
DIMENSION = 'latitude'
if DIMENSION not in dimensions:
    print(f"Die Dimension {DIMENSION} existiert nicht und wird angelegt.")
    cdf.createDimension(DIMENSION, lis_rf_data_centered.shape[0])
else:
    print(f"Die Dimension {DIMENSION} existiert bereits.")

### longitude
DIMENSION = 'longitude'
if DIMENSION not in dimensions:
    print(f"Die Dimension {DIMENSION} existiert nicht und wird angelegt.")
    cdf.createDimension(DIMENSION, lis_rf_data_centered.shape[1])
else:
    print(f"Die Dimension {DIMENSION} existiert bereits.")

## Variable 'lis_rf_data_centered' anlegen als 'f4' 32-bit float und dem Objekt variablenanhangen
## latitude und longitude sind die Dimensionen des 2-dimensionalen Arrays
## Code kann nur einmal ausgeführt werden, prüfen mit try: legt die Variable bereits an, da sie bereits existiert
variables = cdf.variables

VARIABLE = 'lis_rf_data_centered'

if VARIABLE not in variables:

```

8 Das Wichtigste

Das Einlesen strukturierter Datensätze mag nach der Bearbeitung dieses Bausteins wie ein undurchdringlicher Dschungel aus erforderlichem Detailwissen scheinen: verschiedene technische Formate, die große Auswahl an Paketen und Funktionen und ein häufig nicht sonderlich intuitiver innerer Aufbau, der aufgeräumt werden muss. Der Erfolg beim Einlesen schwieriger Datensätze liegt aber im strukturierten Vorgehen - dazu mehr in dem folgenden Video:

Zum Schluss noch ein Tipp: Für sehr große Datensätze ist eine visuelle Kontrolle nicht immer praktikabel. Hier ist es hilfreich, sich Testdaten zu schreiben, die die erwartete Struktur des Datensatzes widerspiegeln, um damit die einzelnen Schritte zu programmieren. Vergleichen Sie anschließend das Resultat für die Testdaten mit dem für den eigentlichen Datensatz.

9 Lernzielkontrolle

9.1 Kompetenzquiz

1. Unter dem Dateipfad '01-daten/quiz-aufgabe1.csv' liegt folgender Datensatz.

ID	Name	Geburtsdatum	Gehalt
1	Anna	1986-04-12	55000
2	Bernd	1990-05-23	62000
3	Carla	1982-11-30	71000
4	David	1975-03-15	58000

Jedoch gelingt das Einlesen mit der Pandas-Funktion `pd.read_csv(filepath_or_buffer = dateipfad)` nicht wie gewünscht.

```
import pandas as pd

dateipfad = '01-daten/quiz-aufgabe1.csv'
aufgabe1 = pd.read_csv(filepath_or_buffer = dateipfad)
print(aufgabe1.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4 entries, 0 to 3
Data columns (total 1 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   ID;Name;Geburtsdatum;Gehalt          4 non-null      object
dtypes: object(1)
memory usage: 164.0+ bytes
None
```

Welche Argumente müssen der Pandas-Funktion `pd.read_csv(filepath_or_buffer = dateipfad)` übergeben werden, damit der Datensatz korrekt eingelesen wird?

2. Ein Fehler bei der Datenerhebung soll korrigiert werden. Kennzeichnen Sie alle Beobachtungen für Personen, die vor 1980 geboren wurden als ungültig.
3. Sortieren Sie die Spalte Geburtsdatum aufsteigend (jüngste Person zuerst). Sortieren Sie den gesamten Dataframe aufsteigend.
4. Warum ist das Geburtsdatum der jüngsten Person “größer” als das der nächstälteren Person?
5. In einem Ordner liegen folgende Dateien: ['Datei0.jpg', 'Datei1.csv', 'Datei2.txt', 'Datei3.png']. Sie möchten alle Dateien mit der Endung .csv und .txt mit dem Modul glob einlesen. Wie könnte der Dateipfad im Argument 'pathname' beschrieben werden, um alle Dateien einzulesen `glob.glob(pathname = ordnerpfad + '...')`?
6. Maske aufheben: Das maskierte Array `m_daten` soll demaskiert werden. Jedoch bleibt der Befehl `m_daten.mask = ma.nomask` ohne Erfolg. Was könnte die Ursache sein?

```
print(m_daten, "\n")

m_daten.mask = ma.nomask
print(m_daten, "\n")
```

```
[1 2 -- 4]
```

```
[1 2 -- 4]
```

7. Welche Aussagen treffen zu?
 - A) HDF5 und netCDF4 sind speziell für den Umgang mit großen, komplexen wissenschaftlichen Datensätzen optimiert und unterstützen mehrdimensionale Arrays.
 - B) HDF5 ist eine hierarchische Datenstruktur, deren Aufbau der Verzeichnisstruktur eines Computers gleicht. NetCDF4 ist dagegen eine flache Datenstruktur und unterstützt verzeichnisartige Datenstrukturen nicht.
 - C) Beide Formate, HDF5 und netCDF4, können ausschließlich ein- und zweidimensionale Datensätze speichern.
 - D) Mit HDF5 und netCDF4 können umfangreiche Metadaten hinterlegt werden. Die Formate gelten deshalb als selbstbeschreibend.

Lösungen

Aufgabe 1: `pd.read_csv()`

```
dateipfad = '01-daten/quiz-aufgabe1.csv'
aufgabe1 = pd.read_csv(filepath_or_buffer = dateipfad, sep = ';', parse_dates = ['Geburtsdatum'])
print(aufgabe1.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4 entries, 0 to 3
Data columns (total 4 columns):
#   Column          Non-Null Count  Dtype
---  -
0   ID               4 non-null      int64
1   Name             4 non-null      string
2   Geburtsdatum     4 non-null      datetime64[ns]
3   Gehalt           4 non-null      int64
dtypes: datetime64[ns](1), int64(2), string(1)
memory usage: 260.0 bytes
None
```

Aufgabe 2: Beobachtungen als ungültig markieren

```
bedingung = aufgabe1['Geburtsdatum'].dt.year < 1980
print(bedingung, "\n")

# pd.NA für Zeichenketten und Ganzzahlen
## NumPy-Datentyp int64 führt zur Umwandlung des Datentyps der Spalte Gehalt
aufgabe2 = aufgabe1.copy()
aufgabe2.loc[bedingung, :] = pd.NA
print("NumPy-Datentyp int64 führt zur Umwandlung des Datentyps der Spalte Gehalt")
print(aufgabe2, "\n")
# 3   NaN   <NA>           NaT       NaN

## Pandas-Datentyp Int64 unterstützt fehlende Werte für Ganzzahlen
aufgabe2 = aufgabe1.copy()
aufgabe2['Gehalt'] = aufgabe2['Gehalt'].astype('Int64')
aufgabe2['ID'] = aufgabe2['ID'].astype('Int64')
aufgabe2.loc[bedingung, :] = pd.NA
print("Pandas-Datentyp Int64 unterstützt fehlende Werte für Ganzzahlen")
print(aufgabe2)
# 3   NaN   <NA>           NaT       <NA>

0   False
1   False
2   False
```

```
3      True
Name: Geburtsdatum, dtype: bool
```

NumPy-Datentyp int64 führt zur Umwandlung des Datentyps der Spalte Gehalt

	ID	Name	Geburtsdatum	Gehalt
0	1.0	Anna	1986-04-12	55000.0
1	2.0	Bernd	1990-05-23	62000.0
2	3.0	Carla	1982-11-30	71000.0
3	NaN	<NA>	NaT	NaN

Pandas-Datentyp Int64 unterstützt fehlende Werte für Ganzzahlen

	ID	Name	Geburtsdatum	Gehalt
0	1	Anna	1986-04-12	55000
1	2	Bernd	1990-05-23	62000
2	3	Carla	1982-11-30	71000
3	<NA>	<NA>	NaT	<NA>

Aufgabe 3: datetime aufsteigend sortieren

```
aufgabe3 = aufgabe2.copy()
print(aufgabe3['Geburtsdatum'].sort_values(ascending = False), "\n")

# Sortieren des DataFrames
print(aufgabe3.sort_values(by = 'Geburtsdatum', ascending = False, inplace = True), "\n")
```

```
1    1990-05-23
0    1986-04-12
2    1982-11-30
3           NaT
Name: Geburtsdatum, dtype: datetime64[ns]
```

None

Aufgabe 4: Welches Datum ist größer und warum?

Python zählt die Zeit ausgehend von der sogenannten Epoche `pd.to_datetime(0)`. Jüngere Menschen wurden in größerem Abstand zur Epoche geboren.

```
aufgabe4 = pd.DataFrame({'Geburtsdatum': aufgabe3['Geburtsdatum'].sort_values(ascending = False),
                          'timedelta zur Epoche': aufgabe4['Geburtsdatum'] - pd.to_datetime(0)})

print(aufgabe4)
```

```
Geburtsdatum timedelta zur Epoche
1 1990-05-23          7447 days
0 1986-04-12          5945 days
2 1982-11-30          4716 days
3          NaT          NaT
```

Aufgabe 5: glob

```
glob.glob(pathname = 'ordnerpfad' + '?????[1-2].*') oder
glob.glob(pathname = 'ordnerpfad' + 'Datei[1-2].*') oder
glob.glob(pathname = 'ordnerpfad' + '*[1-2].*')
```

Aufgabe 6: masked Array

Das maskierte Array hat eine hard mask.

```
m_daten.soften_mask()
m_daten.mask = ma.nomask
print(m_daten, "\n")
```

```
[1 2 3 4]
```

Aufgabe 7: HDF5 und netCDF4

Richtige Antworten: A) und D)

9.2 Übungsaufgaben

Ein sehr unordentlicher Datensatz

Das Statistische Amt der Europäischen Union Eurostat führt die amtlichen europäischen Statistiken. In der [bei Eurostatt verfügbaren Datei \(Direktlink auf XLSX-Datei\)](#) sind die Preise für Erdgas für die Mitgliedstaaten und verschiedene mit der Europäischen Union assoziierte Staaten erfasst. Lesen Sie das Tabellenblatt ‘Table 1’ entweder so ein, dass

- alle Werte mit einem sinnvollen numerischen Datentyp eingelesen werden.
- ENTWEDER in einer zweidimensionalen Struktur jede Zeile eine Beobachtung und jede Beobachtung eine Zeile sowie jede Spalte eine Variable und jede Variable eine Spalte ist.
- ODER wählen Sie eine sinnvolle mehrdimensionale Struktur.

Daten	Dateiname
Preise für Erdgas	“01-daten/SE_figures_for_Gas_2023S2_v3.xlsx”

Ein schwieriges Format

Das statistische Bundesamt veröffentlicht eine Statistik der erteilten Baugenehmigungen, die zum Zeitpunkt der Erstellung dieses Bausteins für die Jahre 2015 bis 2023 vorliegt. Die Daten können hier abgerufen werden: <https://www-genesis.destatis.de/datenbank/online/table/31111-0006/sequenz=tabelleErgebnis&selectionname=31111-0006&zeitscheiben=1>.

Laden Sie mindestens zwei Jahrgänge herunter und lesen Sie die Dateien in einem gemeinsamen Datensatz ein. Ordnen Sie jedem Wert das Jahr der Beobachtung zu, indem Sie eine Variable ‘Jahr’ einfügen und den Datensatz entsprechend strukturieren.

- Wie können Sie das Jahr aus dem Datensatz auslesen?
- Liegen alle Variablen in Spalten vor?

Dem Skript liegen die Dateien in folgendem Pfad bei:

Daten	Ordnerpfad
Baugenehmigungen verschiedener Jahre	“01-daten/baugenehmigungen”

Quellen

- Arnold, Simone (2023a). *Datenanalyse mit Python. Funktionen Module Dateien*.
– (2023b). *Datenanalyse mit Python. NumPy und Dateien*.
- Dasu, Tamraparni und Theodore Johnson (2003). *Exploratory Data Mining and Data Cleaning*.
URL: <https://download.e-bookshelf.de/download/0000/5837/88/L-G-0000583788-0002360584.pdf>.
- Wickham, Hadley (2014). *Tidy Data*. DOI: [10.18637/jss.v059.i10](https://doi.org/10.18637/jss.v059.i10). URL: <https://www.jstatsoft.org/article/view/v059i10>.
- Wickham, Hadley, Mine Çetinkaya-Rundel und Garrett Grolemund (2023). *R for data science: Import, tidy, transform, visualize, and model data*. URL: <https://r4ds.hadley.nz/>.
- Ziemann, Mark, Yotam Eren und Assam El-Osta (Dez. 2016). “Gene name errors are widespread in the scientific literature”. In: *Genome Biol.* 17.1.